

Manual avanzado de DEA/EDA para ciencia de datos

Transformaciones, normalización, estandarización y decisiones
multivariadas

Fundamentos de álgebra lineal, probabilidad, estadística robusta y
razonamiento profesional aplicado

Propósito del libro

Construir criterio técnico para decidir *cuándo*, *por qué* y *cómo* transformar variables durante el DEA/EDA, conectando soporte matemático, distribución marginal y conjunta, semántica, tipo de dato, familia de modelos y geometría del espacio de características.

Proyecto editorial integral con datos, tablas, figuras y bibliografía verificada

Versión v2

Marzo de 2026

Prólogo

Este libro fue reescrito como un manual de criterio profesional. El objetivo no es enumerar recetas aisladas, sino volver explícito el razonamiento que hace una científica o un científico de datos senior cuando inspecciona distribuciones, identifica soportes, reconoce artefactos de escala y decide qué estructura debe preservarse y cuál conviene reexpresar. En consecuencia, el texto se organiza en dos niveles.

El primer nivel es teórico. Presenta el DEA/EDA como disciplina de decisión estadística, desarrolla la semántica de variables, revisa fundamentos de álgebra lineal, estadística descriptiva robusta, dependencia multivariada, transformaciones, escalamiento, tratamiento de faltantes, variable objetivo y diseño de pipelines reproducibles.

El segundo nivel es aplicado. Incluye cinco casos reales y extensos, cada uno con dataset claramente identificado, diagnóstico univariado y multivariado, discusión de distribuciones de probabilidad plausibles, justificación formal de las transformaciones candidatas y explicación detallada de las decisiones que cambian según la familia de modelo posterior.

Hipótesis central

No existe una transformación universalmente correcta. Toda decisión de transformación, normalización, estandarización o reducción de dimensión depende de cuatro planos simultáneos: soporte matemático, semántica del dato, geometría multivariada y uso posterior del dato.

Cómo usar este libro

Hay tres rutas de lectura recomendadas.

1. **Ruta completa de formación.** Recorra los capítulos en orden hasta el mapa de casos y luego estudie cada caso aplicado.
2. **Ruta metodológica.** Si ya conoce EDA básico, lea primero los capítulos [4](#), [5](#), [7](#), [8](#) y después vaya a los casos del bloque aplicado.
3. **Ruta docente.** Use los capítulos teóricos como texto base y convierta las actividades finales y los casos en laboratorios o proyectos de curso.

Notación

$X \in \mathbb{R}^{n \times p}$	matriz de datos con n observaciones y p variables.
$x_i^\top$	fila i , correspondiente a la observación i .
$X_{\cdot j}$	columna j , correspondiente a la variable j .
μ_j, s_j	media y desviación estándar de la variable j .
Σ	matriz de covarianza poblacional o muestral, según contexto.
R	matriz de correlaciones.
$H = I_n - \frac{1}{n} \mathbf{1} \mathbf{1}^\top$	matriz de centrado.
$d_M(x)$	distancia de Mahalanobis.
$g(\cdot)$	transformación aplicada a una variable.

Índice general

Prólogo	i
Cómo usar este libro	ii
Notación	iii
I Fundamentos conceptuales y matemáticos	1
1. EDA como disciplina de decisión estadística	2
1.1. Qué es el EDA	2
1.2. Unidad observacional, variables y semántica del dataset	2
1.2.1. Variable predictora y variable objetivo	3
1.3. El pipeline profesional de EDA	3
1.4. Proceso generador de datos	4
1.4.1. Qué preguntas debe hacer el analista	4
1.5. Errores recurrentes en EDA	5
1.6. Qué produce un buen EDA	5
2. Fundamentos de álgebra lineal, probabilidad y escalas de medición	7
2.1. La matriz de datos como objeto geométrico	7
2.1.1. Normas y distancias	7
2.1.2. Producto interno y ángulo	8
2.2. Covarianza, correlación y estructura espectral	8
2.2.1. Descomposición espectral y PCA	8
2.3. Condicionamiento numérico y colinealidad	8
2.4. Variables aleatorias, vectores aleatorios y soporte	8

2.5. Escalas de medición y operaciones permitidas	9
2.5.1. Nominal	9
2.5.2. Ordinal	9
2.5.3. Intervalo	9
2.5.4. Razón	9
2.5.5. Temporal y cíclica	9
2.5.6. Composicional	9
2.6. Invariancia y equivariancia	10
II Distribuciones, transformaciones y escalamiento	12
3. Distribuciones univariadas y estadística descriptiva	13
3.1. Por qué la forma de la distribución cambia las decisiones	13
3.2. Resumen clásico y resumen robusto	13
3.2.1. Asimetría y curtosis	13
3.3. Herramientas visuales	14
3.4. Distribuciones continuas frecuentes y decisiones asociadas	14
3.4.1. Normal	14
3.4.2. Log-normal	14
3.4.3. Exponencial y Gamma	15
3.4.4. Weibull	15
3.4.5. Pareto	15
3.4.6. Cauchy	15
3.5. Distribuciones discretas frecuentes	15
3.5.1. Bernoulli y Binomial	15
3.5.2. Poisson	16
3.5.3. Binomial negativa	16
3.5.4. Multinomial	16
3.6. Variables acotadas: proporciones y tasas	16
3.7. Multimodalidad y mezclas	16
3.8. Tabla de decisión univariada	17
4. Transformaciones de variables numéricas	19

4.1. Qué es transformar una variable	19
4.1.1. Transformaciones monotónicas	19
4.2. Logaritmo y log1p	20
4.3. Raíz cuadrada y transformaciones estabilizadoras de varianza	20
4.4. Transformaciones potencia	20
4.4.1. Box–Cox	20
4.4.2. Yeo–Johnson	21
4.5. Transformaciones para datos firmados y colas pesadas	21
4.6. Transformaciones basadas en cuantiles	21
4.7. Transformaciones de proporciones	22
4.8. Transformaciones del objetivo	22
4.9. Cuándo no transformar	23
4.10. Tabla de selección de transformaciones	23
4.11. Ejemplos de decisión	24
4.11.1. Ingresos	24
4.11.2. Tiempo entre eventos	24
4.11.3. Conteo de incidencias	24
4.11.4. Saldo financiero con positivos y negativos	24
5. Normalización, estandarización y whitening	26
5.1. Transformar no es lo mismo que escalar	26
5.2. Centrado	26
5.3. Estandarización z-score	26
5.3.1. Cuándo es apropiada	27
5.3.2. Cuándo falla	27
5.4. Min–max	27
5.5. Robust scaling	27
5.6. Max–Abs y normalización para matrices dispersas	28
5.7. Normalización a norma unitaria	28
5.8. Whitening	28
5.9. Por qué el algoritmo determina la necesidad de escalar	29
5.9.1. Métodos muy sensibles a escala	29
5.9.2. Métodos relativamente poco sensibles	29

5.10. Escalamiento y fuga de información	29
5.11. Tabla comparativa de métodos de escalamiento	30
5.12. Ejemplo geométrico	31
III Dependencia y estructura multivariada	33
6. Dependencia, correlación y asociación	34
6.1. La dependencia no es un número único	34
6.2. Pearson	34
6.2.1. Sensibilidad	34
6.3. Spearman y Kendall	34
6.3.1. Spearman	35
6.3.2. Kendall	35
6.4. Asociación según tipo de variable	35
6.5. Matriz de correlación y geometría de la covarianza	35
6.6. Multicolinealidad y VIF	36
6.7. Correlación parcial	36
6.8. Dependencia no lineal	36
6.9. Heterocedasticidad	36
6.10. Asociación y causalidad	37
7. Distribuciones multivariadas, outliers y reducción de dimensión	38
7.1. De la marginal a la conjunta	38
7.2. Normal multivariada	38
7.3. Distancia de Mahalanobis	38
7.3.1. Lectura geométrica	39
7.4. Distribuciones elípticas y t multivariada	39
7.5. Mezclas gaussianas y multimodalidad conjunta	39
7.6. Copulas: separar márgenes y dependencia	39
7.7. Outliers multivariados	39
7.7.1. Métodos clásicos	39
7.7.2. Métodos robustos	40
7.7.3. Decisión correcta	40

7.8. Curse of dimensionality	40
7.9. PCA	40
7.10. t-SNE y UMAP	41
7.11. Tabla de decisión multivariada	41
IV Transformaciones por tipo de dato y calidad de datos	43
8. Transformaciones según el tipo de dato	44
8.1. El tipo de dato determina la clase de transformaciones válidas	44
8.2. Conteos y tasas	45
8.3. Proporciones, porcentajes y razones	45
8.4. Variables categóricas	45
8.4.1. Nominales	45
8.4.2. Ordinales	46
8.4.3. Categorías raras	46
8.5. Variables temporales y cíclicas	46
8.6. Variables de texto	47
8.7. Datos composicionales	47
8.7.1. Transformación clr	47
8.7.2. Transformación ilr	47
8.8. Variables espaciales y coordenadas	48
9. Calidad de datos, faltantes y outliers	50
9.1. La calidad de datos precede a la modelación	50
9.2. Valores faltantes	50
9.2.1. Mecanismos de ausencia	50
9.2.2. Estrategias de tratamiento	50
9.3. Detección de outliers univariados	51
9.3.1. Regla IQR	51
9.3.2. z-score clásico	51
9.3.3. z-score robusto	51
9.4. Outliers multivariados	51
9.5. Eliminar, corregir, winsorizar o conservar	51

9.5.1. Winsorización	52
9.6. Duplicados e inconsistencias	52
9.7. Rareza categórica	52
V Interfaz entre EDA y modelado	54
10.Variable objetivo, familias de modelos y métricas	55
10.1. La variable objetivo cambia todo	55
10.2. Objetivos continuos	55
10.2.1. Regresión con objetivo aproximadamente gaussiano	55
10.2.2. Objetivo sesgado o heterocedástico	55
10.3. Objetivos de conteo	56
10.4. Objetivos proporcionales	56
10.5. Clasificación y desbalance	56
10.6. Objetivos temporales y de supervivencia	56
10.7. Métricas y transformaciones	57
10.8. Fuga de información asociada al objetivo	57
10.9. Tabla de decisiones objetivo–modelo	57
11.Pipeline reproducible de EDA y preprocesamiento	59
11.1. Un EDA profesional debe dejar trazabilidad	59
11.2. Orden recomendado de trabajo	59
11.3. Qué puede verse con todo el dataset y qué no	60
11.4. Ficha de decisión por variable	60
11.5. Pipelines con <code>ColumnTransformer</code>	60
11.6. Validación de decisiones de EDA	61
11.7. Errores finales de integración	62
VI Casos reales integrales	64
12.Mapa de los casos integrales	65
12.1. Cómo leer esta parte del libro	65
12.2. Los cinco casos y su razón pedagógica	66
12.2.1. Caso I: Breast Cancer Wisconsin Diagnostic	66

12.2.2. Caso II: Wine Recognition	66
12.2.3. Caso III: Fair Affairs	66
12.2.4. Caso IV: STAR98	67
12.2.5. Caso V: CO2 de Mauna Loa	67
12.3. Mapa de decisiones cruzadas	67
12.4. Qué debe aprender el lector al terminar esta parte	68
12.5. Enlaces internos a los casos	68
13. Caso I. Diagnóstico oncológico con variables morfométricas	69
13.1. La pregunta analítica correcta	69
13.2. Ficha técnica del dataset	70
13.3. Semántica de la matriz de datos	70
13.4. Auditoría inicial de calidad	70
13.5. Diagnóstico univariado: forma marginal, soporte y colas	71
13.5.1. Qué decide una analista senior ante esta evidencia	72
13.5.2. Separación por clase en los márgenes	72
13.6. Diagnóstico multivariado: redundancia, escala y geometría	73
13.6.1. La pregunta PCA no es “sí o no”, sino “sobre qué geometría”	74
13.6.2. Distancia de Mahalanobis y rareza multivariada	75
13.7. Qué transformar, qué escalar y qué no tocar	75
13.7.1. Escenario A: regresión logística penalizada, SVM o kNN	75
13.7.2. Escenario B: árboles, random forest o boosting	76
13.7.3. Escenario C: visualización, compresión y análisis exploratorio de estructura	76
13.8. Errores frecuentes que este caso permite evitar	76
13.9. Protocolo operativo recomendado	76
14. Caso II. Clasificación quimiométrica de vinos	78
14.1. Pregunta analítica	78
14.2. Ficha técnica	79
14.3. Semántica del problema	79
14.4. Diagnóstico univariado	79
14.4.1. Cuándo sí considerar transformación marginal	80
14.5. Diagnóstico multivariado: correlación química y dominancia de escala	81
14.5.1. PCA cruda versus PCA estandarizada	82

14.5.2. Álgebra lineal de la decisión	83
14.6. Qué haría una científica de datos senior	83
14.7. Decisiones dependientes del modelo posterior	83
14.7.1. kNN, clustering, SVM con kernel RBF	83
14.7.2. Regresión lineal, logística multinomial o redes con regularización	83
14.7.3. Árboles y ensamblados	84
14.8. Errores frecuentes	84
14.9. Protocolo operativo	84
15.Caso III. Respuesta semicontinua con masa en cero	86
15.1. Por qué este caso es crucial	86
15.2. Ficha técnica	87
15.3. Auditoría semántica antes de cualquier transformación	87
15.4. Diagnóstico univariado de la variable de interés	87
15.4.1. Por qué $\log 1p$ no resuelve el problema por sí sola	88
15.5. Estructura de predictores y relaciones sustantivas	88
15.6. Diagnóstico multivariado	89
15.6.1. No toda rareza es outlier	90
15.7. El razonamiento mental de una analista senior	91
15.8. Decisiones de transformación y representación	91
15.8.1. Representación de la respuesta	91
15.8.2. Tratamiento de predictores	91
15.8.3. ¿Escalar o no escalar?	92
15.9. Qué familias de modelo se vuelven plausibles	92
15.10 Errores frecuentes	92
15.11 Protocolo operativo recomendado	93
16.Caso IV. Éxitos binomiales, proporciones y denominadores variables	94
16.1. La pregunta correcta	94
16.2. Ficha técnica	95
16.3. Semántica del dataset	95
16.4. Diagnóstico univariado del objetivo	95
16.4.1. Logit empírico como herramienta exploratoria	96
16.5. Diagnóstico univariado de covariables	96

16.6. Relaciones bivariadas instructivas	97
16.7. Diagnóstico multivariado: colinealidad e interacciones	97
16.7.1. Lo que una analista senior ve en estos VIF	99
16.8. Qué hacer con la respuesta: tres niveles de decisión	100
16.8.1. Nivel 1: exploración rápida	100
16.8.2. Nivel 2: modelado respetando el denominador	100
16.8.3. Nivel 3: ingeniería de predictores	100
16.9. Transformaciones y escalamiento de predictores	100
16.10 Heteroscedasticidad: por qué aparece incluso con buenos datos	100
16.11 Errores frecuentes	101
16.12 Protocolo operativo	101
17. Caso V. Serie temporal semanal de CO₂	103
17.1. La pregunta correcta	103
17.2. Ficha técnica	104
17.3. Auditoría inicial: el tiempo como parte de la semántica	104
17.4. Valores faltantes y régimen de observación	104
17.5. Diagnóstico univariado: la escala no es el problema dominante	105
17.5.1. Transformar la dependencia no es lo mismo que transformar la escala	106
17.6. Estacionalidad y codificación cíclica	106
17.7. Qué ve una analista senior en este caso	107
17.8. Decisiones de representación según la tarea	107
17.8.1. Tarea A: visualización histórica	107
17.8.2. Tarea B: modelado de dinámica de corto plazo	108
17.8.3. Tarea C: aprendizaje supervisado con variables temporales	108
17.9. Univariado y multivariado en series temporales	108
17.10 Por qué la normalización estándar puede ser insuficiente	108
17.11 Errores frecuentes	109
17.12 Protocolo operativo	109
A. Compendio de fórmulas útiles	111
A.1. Centrado y escalamiento	111
A.2. Transformaciones	111
A.3. Medidas robustas	112

A.4. Dependencia y multivariado	112
B. Matriz de decisión rápida para EDA	113
B.1. Checklist operativo	113
B.2. Preguntas mínimas antes de aplicar cualquier transformación	113
C. Proyectos integradores y rúbricas de evaluación	115
C.1. Objetivo pedagógico	115
C.2. Proyecto 1: Clasificación biomédica de alta dimensión	115
C.3. Proyecto 2: Conteos, tasas y exposición	116
C.4. Proyecto 3: Datos composicionales	116
C.5. Proyecto 4: Serie temporal multiescala	117
C.6. Rúbrica sugerida	117
C.7. Lista de verificación docente	118
Cierre	121

Índice de figuras

1.1. El DEA/EDA profesional como circuito de decisión. El flujo no es lineal: la semántica, la calidad, el diagnóstico univariado y la estructura multivariada se revisitan a medida que aparecen hallazgos.	4
4.1. Mapa de soporte y transformaciones. La elección correcta depende del dominio de la variable, de la presencia de ceros o signos negativos y de la familia de modelos posterior.	24
7.1. Ejemplo geométrico de whitening. La nube original tiene covarianza anisotrópica; al multiplicar por $\Sigma^{-1/2}$ se obtiene una nube aproximadamente isotrópica. Esta operación es útil cuando la geometría euclidiana debe neutralizar dependencia lineal y escala conjunta.	41
8.1. Codificación cíclica para variables temporales periódicas. La pareja seno/coseno evita el salto artificial entre el último y el primer valor del ciclo.	46
13.1. Distribución de una variable de área antes y después de aplicar $\log 1p$. La transformación no cambia el orden, pero comprime la cola derecha y reduce el dominio de los valores extremos.	72
13.2. Bloque de correlaciones del caso Breast Cancer. Los ejes asociados a tamaño y borde generan subestructuras muy densas.	73
13.3. Comparación entre PCA cruda y PCA con estandarización. La PCA cruda queda dominada por las variables de mayor magnitud; la PCA sobre variables estandarizadas revela una geometría más informativa para fines exploratorios y clasificatorios.	74
14.1. Distribución de <i>proline</i> en escala original y tras transformación logarítmica. La compresión de cola es visible, pero la lección principal del caso sigue siendo la dominancia de escala en el análisis multivariado.	80
14.2. Mapa de correlaciones del caso Wine. Se observan bloques fenol-flavonoides y relaciones negativas con variables de color y acidez.	81

14.3. Comparación entre PCA sobre covarianza cruda y PCA sobre variables estandarizadas. La PCA cruda queda casi completamente dominada por una sola variable de gran magnitud.	82
15.1. Distribución de affairs en escala original y tras $\log(1 + x)$. La transformación comprime la cola positiva, pero no resuelve el hecho de que casi dos tercios de la masa estén exactamente en cero.	88
15.2. La probabilidad de presentar affairs >0 cae fuertemente al aumentar la calificación matrimonial.	89
15.3. Mapa de correlaciones del caso Fair. Destacan las dependencias entre edad, años de matrimonio y presencia de hijos, así como la asociación negativa entre evaluación del matrimonio y affairs	90
16.1. Proporción de éxito en escala original y tras logit empírico. La transformación despega los valores de los bordes, pero no elimina la necesidad de respetar el denominador binomial.	96
16.2. Relación entre LOWINC y la proporción de éxito. La pendiente negativa es marcada, pero la dispersión vertical también sugiere heteroscedasticidad dependiente del tamaño muestral.	97
16.3. Mapa de correlaciones en STAR98 . Los bloques de interacción muestran dependencia casi determinista con sus factores base.	99
17.1. Serie temporal de CO₂ con marcado de faltantes. El problema no es la cantidad aislada de vacíos, sino la existencia de rachas consecutivas.	105
17.2. Comparación visual entre la serie en nivel, la primera diferencia y la diferencia estacional. Las transformaciones temporales alteran la dependencia mucho más que la escala marginal.	106
17.3. Perfil estacional medio por semana del año. La periodicidad anual es una propiedad estructural de la serie.	107

Índice de tablas

12.1. Catálogo de casos incluidos en el libro. Cada uno enfatiza un patrón distinto de soporte, distribución y estructura multivariada.	66
13.1. Ficha técnica resumida del caso Breast Cancer Wisconsin Diagnostic.	70
13.2. Variables con mayor asimetría absoluta y curtosis en el caso Breast Cancer. . .	71
13.3. Pares de variables con mayor correlación absoluta.	73
13.4. Varianza explicada por PCA con datos crudos y con variables estandarizadas. .	74
13.5. Número de observaciones por encima de distintos umbrales de distancia de Mahalanobis.	75
14.1. Ficha técnica del caso Wine Recognition.	79
14.2. Variables con mayor asimetría absoluta en el caso Wine.	80
14.3. Pares de variables con mayor correlación absoluta en el caso Wine.	81
14.4. Varianza explicada por PCA cruda y PCA estandarizada.	82
15.1. Ficha técnica del caso Fair Affairs.	87
15.2. Resumen univariado de la variable affairs	88
15.3. Frecuencia de affairs positiva según la calificación del matrimonio.	89
15.4. Correlaciones más altas entre predictores y respuesta en el caso Fair.	90
16.1. Ficha técnica del caso STAR98.	95
16.2. Resumen de la respuesta derivada SUCCESS_RATE y del tamaño muestral total por distrito.	95
16.3. Variables con mayor asimetría absoluta en el caso STAR98.	96
16.4. Pares de variables con mayor correlación absoluta en STAR98.	98
16.5. Variables con mayor factor de inflación de la varianza (VIF).	98
17.1. Ficha técnica del caso CO ₂ de Mauna Loa.	104

17.2. Rachas más largas de valores faltantes en la serie semanal.	104
17.3. Resumen comparativo entre la serie en nivel interpolado y dos transformaciones temporales simples.	105

Parte I

Fundamentos conceptuales y matemáticos

EDA como disciplina de decisión estadística

1.1 Qué es el EDA

El análisis exploratorio de datos es el proceso sistemático mediante el cual el científico de datos inspecciona la estructura, la calidad, las distribuciones y las relaciones contenidas en un conjunto de datos *antes* de imponer un modelo explicativo o predictivo. La formulación clásica de Tukey puede resumirse así: dejar que los datos hablen antes de obligarlos a entrar en una familia paramétrica [17].

En términos operativos, EDA es una fase de **decisión**. No sólo describe: selecciona tratamientos, descarta representaciones erróneas, detecta supuestos inviables y prepara el terreno del modelado.

Tesis del capítulo

En un proyecto real, casi todas las transformaciones útiles nacen del EDA. Si se transforma sin EDA, se corre el riesgo de blanquear ruido, inducir sesgo o eliminar la señal más valiosa del problema.

1.2 Unidad observacional, variables y semántica del dataset

Antes de cualquier estadística, hay que responder tres preguntas:

- a) ¿Qué representa una fila?
- b) ¿Qué representa una columna?
- c) ¿En qué contexto fueron medidos esos valores?

Si una fila es un cliente, una columna puede ser edad, ingreso o número de compras. Pero si una fila es una transacción, entonces “ingreso” puede dejar de ser atributo individual y pasar a

ser una variable agregada. El error más común al comenzar un EDA es tratar columnas como si su semántica fuese obvia.

1.2.1 Variable predictora y variable objetivo

En aprendizaje supervisado, algunas variables son predictoras y una o varias son objetivo. Esta distinción importa porque:

- la exploración de la **variable objetivo** condiciona la elección de métrica, muestreo y familia de modelos;
- ciertas columnas pueden introducir **fuga de información** si contienen versiones futuras o derivadas del objetivo;
- una transformación aceptable para un predictor puede ser contraproducente para el objetivo.


1.3 El pipeline profesional de EDA

Un flujo profesional puede organizarse en nueve pasos iterativos:

- 1 Comprensión del dataset y de su granularidad.
- 2 Evaluación de calidad de datos.
- 3 Estadísticas descriptivas básicas y robustas.
- 4 Análisis de distribuciones marginales.
- 5 Análisis de dependencia y correlación.
- 6 Detección e interpretación de outliers.
- 7 Estudio de estructura multivariada.
- 8 Exploración de la variable objetivo.
- 9 Generación de hipótesis y decisiones para modelado.

No es un pipeline lineal. Es un circuito. El análisis de outliers puede obligar a revisar la calidad; una multimodalidad puede exigir segmentar la muestra; una mala calibración del modelo puede devolvernos al análisis de distribuciones.

DEA/EDA como proceso profesional de decisión



El flujo es iterativo: las decisiones sobre soporte, distribución y geometría se revisitan a medida que aparecen hallazgos.

Figura 1.1: El DEA/EDA profesional como circuito de decisión. El flujo no es lineal: la semántica, la calidad, el diagnóstico univariado y la estructura multivariada se revisitan a medida que aparecen hallazgos.

1.4 Proceso generador de datos

Todo dataset es el residuo observable de un mecanismo subyacente. Llamaremos **proceso generador de datos** (PGD) al sistema físico, biológico, social, económico o computacional que produce las observaciones.

Definición 1.1. Sea X una variable aleatoria observada en un dataset. El PGD es el conjunto de mecanismos, restricciones, instrumentos de medición, reglas de muestreo y condiciones contextuales que inducen la distribución de X y sus dependencias con otras variables.

Pensar en PGD evita errores conceptuales. Un tiempo entre fallas puede parecer simplemente “numérico positivo”, pero en realidad surge de un mecanismo de confiabilidad; un conteo de clics puede obedecer a una mezcla de Poisson con sobre-dispersión; una proporción presupuestal vive en un simplex y no en un espacio euclidiano libre.

1.4.1 Qué preguntas debe hacer el analista

- ¿El muestreo fue aleatorio, estratificado, oportunista o censurado?
- ¿Hubo límites instrumentales, redondeo, truncamiento o saturación?
- ¿La distribución observada refleja la población o una política de recolección?
- ¿Existen subpoblaciones latentes mezcladas en el mismo dataset?
- ¿El tiempo afecta la estabilidad del fenómeno?

1.5 Errores recurrentes en EDA

Errores metodológicos frecuentes

1. Confundir una columna identificadora con una variable explicativa.
2. Aplicar estandarización a variables categóricas codificadas arbitrariamente.
3. Eliminar outliers sin distinguir entre error de captura y señal rara pero real.
4. Escalar con todo el dataset antes de separar entrenamiento y validación.
5. Inferir causalidad a partir de correlación.
6. Usar una transformación porque “siempre funciona”, sin justificarla desde el PGD.

1.6 Qué produce un buen EDA

El producto final del EDA no es un conjunto de gráficos. Es un **mapa de decisiones**:

- qué columnas conservar;
- qué columnas transformar;
- qué escalamiento usar;
- qué supuestos parecen razonables o inaceptables;
- qué sesgos de muestreo o medición deben documentarse;
- qué familias de modelos son plausibles.

Síntesis del capítulo

Resumen

EDA es una disciplina de traducción: toma datos crudos y los convierte en una representación estadística inteligible y utilizable por modelos. Su núcleo es decidir, no decorar.

Ejercicios teóricos

1. Defina con precisión la diferencia entre *variable*, *feature*, *predictor* y *objetivo*. Dé un ejemplo donde la misma columna cambie de rol según la unidad observacional.
2. Construya un argumento de una página explicando por qué el PGD es indispensable para interpretar outliers.

3. Describa dos ejemplos de fuga de información originados en una comprensión deficiente de la semántica del dato.

Actividades aplicadas

Actividad 1: auditoría semántica

Elija un dataset real. Construya un diccionario de datos con las columnas: nombre de variable, tipo de dato bruto, escala de medición, unidad, significado de negocio, posible PGD, riesgo de fuga, tratamiento inicial sugerido.

Actividad 2: mapa de riesgos de EDA

Para el mismo dataset, elabore una matriz con cuatro filas: calidad, distribución, dependencia y objetivo. En cada fila escriba qué fallas del dataset podrían invalidar un modelo.

Navegación

[Volver al índice general](#)

[Ir al siguiente capítulo: Fundamentos de álgebra lineal, probabilidad y escalas de medición](#)

[Saltar al capítulo de pipeline reproducible](#)

Fundamentos de álgebra lineal, probabilidad y escalas de medición

2.1 La matriz de datos como objeto geométrico

Sea $X \in \mathbb{R}^{n \times p}$ la matriz de datos. Cada fila $x_i^\top$ es una observación en un espacio de características de dimensión p , y cada columna $X_{\cdot j}$ es una variable observada sobre n unidades.

Esta notación permite expresar casi todas las transformaciones de EDA de forma compacta. Por ejemplo:

$$X_c = HX, \quad H = I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top,$$

donde X_c es la matriz centrada por columnas. La matriz H es simétrica e idempotente: $H^\top = H$ y $H^2 = H$.

Proposición 2.1. La suma de cada columna de X_c es cero.

Demostración. Se tiene $\mathbf{1}^\top H = \mathbf{1}^\top - \frac{1}{n}\mathbf{1}^\top \mathbf{1}\mathbf{1}^\top = \mathbf{1}^\top - \mathbf{1}^\top = \mathbf{0}^\top$. Por tanto, $\mathbf{1}^\top X_c = \mathbf{1}^\top HX = \mathbf{0}^\top X = \mathbf{0}^\top$. $\square$

2.1.1 Normas y distancias

Tres normas aparecen con frecuencia:

$$\|x\|_1 = \sum_{j=1}^p |x_j|, \quad \|x\|_2 = \left(\sum_{j=1}^p x_j^2 \right)^{1/2}, \quad \|x\|_\infty = \max_j |x_j|.$$

Estas normas inducen geometrías diferentes. Si una variable tiene escala miles de veces mayor que otra, la distancia euclidiana estará dominada por ella. Ese hecho, aparentemente trivial, es la razón matemática por la que k-means, k-NN, SVM con kernel radial y PCA suelen requerir escalamiento.

2.1.2 Producto interno y ángulo

El producto interno $x^\top y$ define ángulos y proyecciones. La correlación entre dos variables centradas y estandarizadas es exactamente su producto interno normalizado. Por eso una matriz de correlación también puede interpretarse como una matriz de cosenos entre columnas z-score.

2.2 Covarianza, correlación y estructura espectral

Si X_c está centrada, la matriz de covarianza muestral es

$$S = \frac{1}{n-1} X_c^\top X_c.$$

Es una matriz simétrica semidefinida positiva. Sus autovectores describen direcciones principales de variación y sus autovalores cuantifican la varianza asociada a cada dirección.

La matriz de correlación es

$$R = D_s^{-1} S D_s^{-1},$$

donde $D_s = \text{diag}(s_1, \dots, s_p)$ contiene las desviaciones estándar muestrales. Cuando las variables tienen unidades diferentes, R suele ser más informativa que S para estudiar estructura conjunta.

2.2.1 Descomposición espectral y PCA

Si $S = Q\Lambda Q^\top$, con $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ y Q ortogonal, entonces los vectores columna de Q son los ejes principales. El PCA no es una técnica mágica: es simplemente la diagonalización de la forma cuadrática asociada a la covarianza.

Observación 2.2. PCA sobre covarianza y PCA sobre correlación responden a preguntas distintas. El primero conserva la escala física; el segundo neutraliza diferencias de varianza entre variables. No hay una opción universalmente correcta.

2.3 Condicionamiento numérico y colinealidad

El número de condición de una matriz A en norma 2 es

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2.$$

Cuando κ_2 es grande, pequeños errores de medición o redondeo pueden producir grandes cambios en los coeficientes estimados. En regresión lineal, una matriz de diseño mal condicionada suele reflejar colinealidad o escalas muy desbalanceadas.

2.4 Variables aleatorias, vectores aleatorios y soporte

Una variable aleatoria no es sólo un conjunto de números. Es un mapeo con **soporte**, distribución y momentos potencialmente restringidos. En EDA, el soporte es crucial:

- una variable de soporte $(0, \infty)$ admite logaritmo y Box-Cox;
- una proporción en $[0, 1]$ admite logit sólo con manejo de fronteras;
- una cuenta en $\mathbb{N}_0$ no debería tratarse como una variable continua sin justificación;
- una composición vive en el simplex $\mathcal{S}^D = \{x_i > 0, \sum_i x_i = 1\}$.

2.5 Escalas de medición y operaciones permitidas

El tipo de dato no es una etiqueta informática; es una restricción matemática sobre las operaciones válidas.

2.5.1 Nominal

Sólo admite igualdad/desigualdad. No tiene sentido centrar, promediar ni estandarizar una etiqueta nominal codificada como 1, 2, 3.

2.5.2 Ordinal

Existe orden, pero las diferencias entre niveles no tienen interpretación métrica garantizada. Una codificación 1, 2, 3, 4 puede servir para ciertos algoritmos monotónicos, pero asumir distancia euclidiana entre categorías suele ser indebido.

2.5.3 Intervalo

Las diferencias son interpretables, pero el cero es arbitrario. Temperatura en Celsius es el ejemplo clásico. Multiplicar o dividir razones carece de interpretación directa.

2.5.4 Razón

Existe cero absoluto y relaciones multiplicativas significativas. Ingreso, peso, tiempo y longitud pertenecen a esta categoría. Aquí sí tienen sentido logaritmos, coeficientes de variación y comparaciones relativas.

2.5.5 Temporal y cíclica

Fechas y marcas de tiempo poseen estructura de orden, duración y periodicidad. La hora del día no es lineal en el sentido habitual: 23:59 y 00:01 están muy cerca, aunque sus códigos numéricos sean extremos.

2.5.6 Composicional

Vectores de proporciones que suman uno. La restricción de suma induce dependencia espuria si se analizan directamente en espacio euclidiano. Para estos datos se usan transformaciones

log-ratio.

2.6 Invariancia y equivariancia

Un principio útil es preguntarse: *¿qué estructura quiero preservar?*

- La estandarización preserva orden y transforma la escala.
- Una transformación monotónica preserva rangos, pero no diferencias ni varianzas.
- La normalización a norma unitaria preserva dirección, pero no magnitud.
- Una codificación one-hot preserva identidad categórica, pero cambia la geometría del espacio.

Principio rector

No toda transformación admisible algebraicamente es admisible científicamente. El criterio no es “si se puede hacer”, sino “si la estructura preservada sigue siendo la relevante para el problema”.

Síntesis del capítulo

La matriz de datos es un objeto geométrico. Transformar datos equivale a aplicar operadores sobre un espacio con restricciones de soporte, escala y significado. El buen EDA exige conocer esas restricciones antes de usar un solo escalador.

Ejercicios teóricos

1. Demuestre que $S = \frac{1}{n-1} X_c^\top X_c$ es semidefinida positiva.
2. Suponga que $Z = X_c D^{-1}$, donde D es diagonal con entradas positivas. Derive la matriz de covarianza de Z en términos de S y D .
3. Dé un ejemplo donde el uso de la matriz de correlación en lugar de la de covarianza destruya información científicamente relevante.
4. Justifique por qué una hora del día debe codificarse preferiblemente con funciones trigonométricas y no con un entero entre 0 y 23.

Actividades aplicadas

Actividad 1: inventario geométrico del dataset

Tome un dataset con al menos 10 variables. Clasifique cada una según su escala de medición y escriba qué operaciones son válidas: media, varianza, log, estandarización, distancia euclidiana, codificación one-hot, log-ratio, seno/coseno.

Actividad 2: condicionamiento

Simule dos variables numéricas, una con rango $[0, 1]$ y otra con rango $[0, 10^6]$. Muestre cómo cambian las distancias euclidianas entre observaciones antes y después de aplicar z-score.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: EDA como disciplina de decisión estadística](#)

[Ir al siguiente capítulo: Distribuciones univariadas y estadística descriptiva](#)

[Saltar al capítulo de escalamiento y estandarización](#)

Parte II

Distribuciones, transformaciones y escalamiento

Distribuciones univariadas y estadística descriptiva

3.1 Por qué la forma de la distribución cambia las decisiones

Dos variables pueden tener la misma media y la misma desviación estándar, pero requerir decisiones radicalmente distintas si una es aproximadamente normal y la otra es fuertemente asimétrica con colas pesadas. El EDA univariado no termina en resumir; debe caracterizar forma, soporte, asimetría, colas, multimodalidad y estabilidad de momentos.

3.2 Resumen clásico y resumen robusto

Las medidas clásicas incluyen media, varianza y desviación estándar:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Las medidas robustas incluyen mediana, rango intercuartílico y MAD:

$$\text{med}(x), \quad \text{IQR} = Q_3 - Q_1, \quad \text{MAD} = \text{med}(|x_i - \text{med}(x)|).$$

Observación 3.1. Si la distribución tiene colas muy pesadas o incluso no posee momentos finitos, el resumen clásico puede ser inestable o conceptualmente inválido. La distribución de Cauchy es el ejemplo paradigmático: no tiene media ni varianza definidas.

3.2.1 Asimetría y curtosis

Sea $m_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$. Entonces:

$$\text{skewness} = \frac{m_3}{m_2^{3/2}}, \quad \text{kurtosis} = \frac{m_4}{m_2^2}.$$

Estas cantidades orientan, pero no deben interpretarse mecánicamente. Una mezcla de dos normales puede tener skewness cercano a cero y aun así ser claramente multimodal.

3.3 Herramientas visuales

Las herramientas mínimas del análisis univariado son:

- histograma,
- curva de densidad o estimación kernel,
- boxplot,
- violin plot,
- QQ-plot frente a una distribución de referencia,
- gráfico de barras o Pareto para variables categóricas.

El QQ-plot es especialmente útil para distinguir si una desviación respecto de la normalidad ocurre en colas, en el centro o de manera sistemática.

3.4 Distribuciones continuas frecuentes y decisiones asociadas

3.4.1 Normal

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, la variable es simétrica, unimodal y sus colas decrecen rápidamente. Muchas técnicas lineales y pruebas clásicas se comportan bien en este régimen.

Decisiones típicas:

- la estandarización z-score suele ser natural;
- la media y la desviación estándar son resúmenes informativos;
- los outliers pueden diagnosticarse inicialmente mediante z-score, con cautela.

3.4.2 Log-normal

Si $\log X \sim \mathcal{N}(\mu, \sigma^2)$, entonces X es positiva y fuertemente asimétrica a la derecha. Ingresos, tamaños, tiempos de permanencia y montos monetarios suelen aproximarse a esta familia.

Implicación: el logaritmo suele convertir un modelo multiplicativo en aditivo. Si

$$X = \exp(\mu + \sigma Z),$$

entonces

$$\log X = \mu + \sigma Z,$$

lo cual simplifica análisis, modelado y homocedasticidad.

3.4.3 Exponencial y Gamma

Variables de tiempo entre eventos o acumulación de tiempos suelen mostrar soporte positivo y sesgo fuerte. La exponencial tiene propiedad de falta de memoria; la Gamma generaliza ese patrón permitiendo mayor flexibilidad en forma y varianza.

Implicación: no siempre conviene “forzar normalidad”. En muchos casos es preferible usar modelos coherentes con el soporte positivo, como GLM Gamma o análisis de supervivencia.

3.4.4 Weibull

Frecuente en confiabilidad y supervivencia. Su forma puede parecer exponencial, casi log-normal o más concentrada según el parámetro de forma. Una mala decisión común es aplicar transformaciones sin considerar si el problema es, en realidad, de duración o tiempo hasta evento.

3.4.5 Pareto

Modela colas pesadas y fenómenos tipo 80/20. Si $X \sim \text{Pareto}(x_m, \alpha)$, entonces:

$$\mathbb{E}[X] < \infty \iff \alpha > 1, \quad \text{Var}(X) < \infty \iff \alpha > 2.$$

Por tanto, hay situaciones en las que la media existe pero la varianza no, y otras donde ni siquiera la media es finita.

Implicación: z-score y varianza dejan de ser criterios robustos. Conviene usar estadísticas de orden, cuantiles, cola superior e incluso modelado extremo.

3.4.6 Cauchy

Su densidad tiene colas tan pesadas que ni la media ni la varianza existen. Si una variable muestra comportamiento cercano a Cauchy o a una t multivariada con muy pocos grados de libertad, la estandarización clásica puede ser engañosa.

3.5 Distribuciones discretas frecuentes

3.5.1 Bernoulli y Binomial

Variables binarias, respuestas sí/no y conteos de éxitos sobre un número fijo de ensayos. En una Bernoulli con parámetro p , la varianza es $p(1-p)$. Esto significa que la dispersión depende del nivel medio.

Implicación: no se transforman como variables continuas. Se analizan mediante proporciones, tablas de contingencia, razón de momios, calibración y métricas de clasificación.

3.5.2 Poisson

Si $X \sim \text{Poisson}(\lambda)$, entonces $\mathbb{E}[X] = \text{Var}(X) = \lambda$. Esta igualdad media-varianza es una firma del proceso de conteo Poisson.

Implicación:

- si la varianza empírica excede mucho la media, puede haber sobredispersión;
- una transformación de raíz cuadrada o Anscombe puede estabilizar la varianza;
- también puede ser preferible un modelo de regresión Poisson o Binomial Negativa.

3.5.3 Binomial negativa

Útil cuando los conteos muestran sobredispersión:

$$\text{Var}(X) = \mu + \frac{\mu^2}{k},$$

donde k controla el exceso de variación.

3.5.4 Multinomial

Para conteos categóricos en varias clases. Es la base de muchas tablas de frecuencia, perfiles de categorías y modelos para targets multiclase.

3.6 Variables acotadas: proporciones y tasas

Una proporción vive en $[0, 1]$. Esto invalida un tratamiento gaussiano ingenuo cuando hay asimetría, amontonamiento cerca de 0 o 1, o varianza dependiente del nivel medio.

Opciones frecuentes:

- análisis directo como proporción si la interpretación es suficiente;
- transformación logit si los valores están en $(0, 1)$;
- modelos Beta o cuasi-binomial;
- correcciones con ε cuando existen ceros o unos exactos.

3.7 Multimodalidad y mezclas

Una distribución con varios picos sugiere mezcla de subpoblaciones o regímenes distintos. Transformar sin segmentar puede ocultar la estructura más importante del problema.

Ejemplo 3.2. Supóngase que el salario de un dataset mezcla pasantes, analistas y directivos. El histograma global puede ser claramente multimodal. Aplicar sólo logaritmo puede reducir el sesgo, pero no resuelve que hay grupos con medias y varianzas distintas. La decisión correcta podría ser segmentar por cargo o incorporar esa variable en el análisis multivariado.

3.8 Tabla de decisión univariada

Patrón observado	Lectura estadística	Decisiones plausibles
Aproximadamente normal	Simetría y colas moderadas	z-score, media/desviación estándar, modelos lineales si el resto de supuestos acompaña.
Sesgo positivo fuerte	Posible proceso multiplicativo o soporte positivo	log, log1p, Box–Cox, Yeo–Johnson, GLM Gamma, cuantiles robustos.
Conteos con media similar a varianza	Mecanismo de conteo Poisson plausible	raíz cuadrada, Anscombe, Poisson regression, análisis por tasa si hay exposición.
Conteos con sobre-dispersión	Heterogeneidad no explicada o dependencia temporal	log1p con cautela, Binomial Negativa, segmentación por exposición o grupos.
Proporciones pegadas a 0 o 1	Soporte acotado y posible inflación en fronteras	logit con suavizado, Beta, análisis de fronteras por separado.
Colas pesadas extremas	Pareto, Cauchy, mezcla o outliers reales	robust scaling, cuantiles, winsorización documentada, modelos robustos.
Multimodalidad	Subpoblaciones o mezcla	clustering exploratorio, estratificación, modelado jerárquico, no resumir con una sola media.

Síntesis del capítulo

La distribución univariada condiciona toda decisión posterior. “Normalizar” sin identificar soporte, sesgo, colas, multimodalidad y tipo de variable es un error técnico.

Ejercicios teóricos

1. Demuestre que si X es log-normal, entonces $\log X$ es normal y calcule $\mathbb{E}[X]$ y $\text{Var}(X)$.
2. Explique por qué el z-score deja de ser fiable si la variable sigue una distribución de Cauchy.

3. Compare Poisson y Binomial Negativa desde el punto de vista de la relación media-varianza.
4. Dé un ejemplo real donde una distribución multimodal no deba ser “corregida” sino interpretada.

Actividades aplicadas

Actividad 1: diagnóstico univariado completo

Para cada variable numérica de un dataset real, construya una ficha con: histograma, boxplot, QQ-plot, media, mediana, desviación estándar, IQR, skewness, kurtosis y una recomendación de transformación o no transformación.

Actividad 2: comparación clásico vs robusto

Simule 1000 observaciones normales y luego contamine el 5% con valores extremos. Compare media, mediana, desviación estándar e IQR antes y después de la contaminación.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Fundamentos de álgebra lineal, probabilidad y escalas de medición](#)

[Ir al siguiente capítulo: Transformaciones de variables numéricas](#)

[Saltar al capítulo de distribuciones multivariadas](#)

Transformaciones de variables numéricas

4.1 Qué es transformar una variable

Una transformación es una función

$$g : \mathcal{X} \rightarrow \mathcal{Z},$$

aplicada a una variable para modificar su representación sin cambiar la identidad de las observaciones. En EDA, transformamos para:

1. reducir asimetría;
2. estabilizar varianza;
3. linealizar relaciones;
4. comprimir colas pesadas;
5. adaptar el soporte a un modelo;
6. mejorar interpretabilidad de efectos relativos.

4.1.1 Transformaciones monotónicas

Si g es estrictamente creciente, preserva el orden:

$$x_i < x_j \implies g(x_i) < g(x_j).$$

Esto es valioso cuando los rangos son la estructura importante, como en correlaciones de Spearman o modelos basados en orden.

Principio

Una transformación monotónica preserva orden, pero no preserva diferencias, distancias ni correlaciones lineales.

4.2 Logaritmo y log1p

Para variables positivas, el logaritmo es la transformación más influyente del análisis de datos:

$$z = \log x.$$

Reduce asimetría a la derecha, comprime colas y convierte relaciones multiplicativas en aditivas.

Ejemplo 4.1. Si el costo de un cliente es multiplicativo, por ejemplo

$$Y = \beta_0 X_1^{\beta_1} X_2^{\beta_2} \varepsilon,$$

entonces

$$\log Y = \log \beta_0 + \beta_1 \log X_1 + \beta_2 \log X_2 + \log \varepsilon.$$

Esto no sólo facilita el ajuste; cambia la interpretación del modelo a elasticidades.

Cuando existen ceros, se utiliza con frecuencia

$$z = \log(1 + x) = \log 1p(x).$$

Es útil para conteos escasos y montos con muchos ceros, aunque no debe confundirse con una solución universal. Si el cero tiene significado estructural fuerte, conviene analizarlo explícitamente.

4.3 Raíz cuadrada y transformaciones estabilizadoras de varianza

Para conteos Poisson, una transformación de raíz cuadrada puede reducir la dependencia entre media y varianza. Por el método delta, si $X \sim \text{Poisson}(\lambda)$ y $g(x) = 2\sqrt{x}$, entonces aproximadamente

$$\text{Var}(g(X)) \approx (g'(\lambda))^2 \text{Var}(X) = \left(\frac{1}{\sqrt{\lambda}}\right)^2 \lambda = 1.$$

Una forma refinada es la transformación de Anscombe:

$$z = 2\sqrt{x + \frac{3}{8}}.$$

4.4 Transformaciones potencia

4.4.1 Box-Cox

Para $x > 0$:

$$g_\lambda(x) = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log x, & \lambda = 0. \end{cases}$$

El parámetro λ suele estimarse maximizando una log-verosimilitud bajo normalidad aproximada de la variable transformada, siguiendo la propuesta clásica de Box y Cox [3].

Ventajas:

- flexibilidad entre logaritmo, raíz, identidad e inversiones suaves;
- capacidad para reducir sesgo y heterocedasticidad.

Limitación: requiere positividad estricta.

4.4.2 Yeo–Johnson

Extiende Box–Cox a valores cero y negativos:

$$g_{\lambda}(x) = \begin{cases} \frac{(x+1)^{\lambda} - 1}{\lambda}, & x \geq 0, \lambda \neq 0, \\ \log(x+1), & x \geq 0, \lambda = 0, \\ -\frac{(-x+1)^{2-\lambda} - 1}{2-\lambda}, & x < 0, \lambda \neq 2, \\ -\log(-x+1), & x < 0, \lambda = 2. \end{cases}$$

Observación 4.2. Yeo–Johnson es útil cuando una variable puede ser negativa pero sigue mostrando sesgo fuerte. Por ejemplo, diferencias de inventario, retornos con masa en cero o saldos.

4.5 Transformaciones para datos firmados y colas pesadas

Para variables con signo y colas largas:

- **signed log:** $z = \text{sign}(x) \log(1 + |x|)$;
- **asinh:** $z = \text{asinh}(x)$;
- **modulus transform:** familia útil para datos positivos y negativos.

La transformación asinh es especialmente práctica cuando se desea un comportamiento logarítmico para magnitudes grandes, pero aproximadamente lineal alrededor de cero:

$$\text{asinh}(x) = \log\left(x + \sqrt{x^2 + 1}\right).$$

4.6 Transformaciones basadas en cuantiles

Si $\hat{F}$ es la CDF empírica, una transformación basada en cuantiles puede llevar una variable a distribución aproximadamente uniforme:

$$u_i = \hat{F}(x_i),$$

o a distribución aproximadamente normal:

$$z_i = \Phi^{-1}(u_i),$$

donde Φ es la CDF normal estándar.

Ventajas:

- reduce efectos de cola y asimetría extrema;
- alinea distribuciones muy distintas en una escala común.

Costos:

- distorsiona diferencias relativas originales;
- puede producir artefactos si se aplica fuera de muestra sin una estrategia consistente;
- complica interpretación causal y económica.

4.7 Transformaciones de proporciones

Para $p \in (0, 1)$:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right).$$

La transformación es útil cuando interesa modelar efectos lineales en odds. Sin embargo, si hay ceros o unos exactos, se requiere suavizado, por ejemplo:

$$\tilde{p} = \frac{p(n-1) + 0,5}{n},$$

o una corrección por ε .

La transformación arco seno de la raíz cuadrada

$$z = \arcsin(\sqrt{p})$$

fue popular históricamente como estabilizadora para proporciones binomiales, pero hoy suele preferirse una modelación más directa mediante logit, Beta o cuasi-verosimilitud, salvo contextos específicos.

4.8 Transformaciones del objetivo

Transformar el predictor y transformar la variable objetivo son operaciones diferentes. Si se modela

$$\log Y = X\beta + \varepsilon,$$

la predicción natural vive en escala logarítmica. Al volver a escala original no basta aplicar exponencial al valor esperado condicional:

$$\mathbb{E}[Y \mid X] \neq \exp(\mathbb{E}[\log Y \mid X]).$$

Con ruido normal aditivo en log-escala, aparece un factor de sesgo:

$$\mathbb{E}[Y \mid X] = \exp(X\beta + \sigma^2/2).$$

En situaciones no gaussianas, puede usarse el *smearing estimator* de Duan.

4.9 Cuándo no transformar

No transformar también es una decisión técnica

No transforme cuando:

1. la variable ya tiene una escala científicamente interpretable que el usuario final necesita;


2. el algoritmo es relativamente invariante a transformaciones monotónicas y la interpretación prima sobre la simetría;

3. la aparente asimetría es, en realidad, la firma natural del PGD;

4. la transformación rompería restricciones semánticas importantes.

4.10 Tabla de selección de transformaciones

Situación	Transformaciones candidatas	Comentario
Variable positiva con sesgo fuerte	log, Box–Cox, Yeo–Johnson	Buena elección si el mecanismo es multiplicativo.
Conteos bajos o moderados	$\sqrt{x}$, Anscombe, $\log 1p$	Revisar si conviene un GLM en lugar de OLS transformado.
Variable con signo y colas pesadas	asinh, signed log, Yeo–Johnson	Preservan el signo y comprimen extremos.
Proporciones internas en $(0, 1)$	logit, Beta transformaciones auxiliares	Manejar fronteras con suavizado.
Multimodalidad genuina	ninguna transformación simple basta	Segmentar o modelar mezcla.



La transformación correcta depende de soporte, semántica y familia de modelos posterior.

Figura 4.1: Mapa de soporte y transformaciones. La elección correcta depende del dominio de la variable, de la presencia de ceros o signos negativos y de la familia de modelos posterior.

4.11 Ejemplos de decisión

4.11.1 Ingresos

Patrón habitual: soporte positivo, fuerte sesgo a la derecha, heterocedasticidad. **Decisión:** log o Box-Cox. Interpretación posterior en términos relativos.

4.11.2 Tiempo entre eventos

Patrón habitual: positivo, asimétrico, posiblemente exponencial o Weibull. **Decisión:** analizar soporte y mecanismo primero; considerar log si el objetivo es aproximar simetría, pero no sustituir indebidamente un enfoque de supervivencia.

4.11.3 Conteo de incidencias

Patrón habitual: enteros no negativos, masa en cero, posible sobredispersión. **Decisión:** log 1p o $\sqrt{\cdot}$ para exploración; Poisson o Binomial Negativa para modelado.

4.11.4 Saldo financiero con positivos y negativos

Patrón habitual: distribución centrada, colas muy largas y muchos ceros. **Decisión:** asinh o Yeo-Johnson.

Síntesis del capítulo

Transformar no es “embellecer” una variable. Es imponer una nueva geometría y una nueva escala de interpretación. La elección correcta depende del soporte, del PGD y del uso posterior de la variable.

Ejercicios teóricos

1. Pruebe, usando el método delta, por qué la raíz cuadrada estabiliza aproximadamente la varianza de una Poisson.
2. Compare Box–Cox y Yeo–Johnson desde el punto de vista de soporte y flexibilidad.
3. Explique por qué una transformación basada en cuantiles puede perjudicar la interpretabilidad económica.
4. Derive la relación entre un modelo lineal en escala logarítmica y la interpretación en elasticidades.

Actividades aplicadas

Actividad 1: laboratorio de transformaciones

Tome cuatro variables con formas diferentes: aproximadamente normal, log-normal, conteo sobredisperso y variable firmada con colas largas. Aplique transformaciones candidatas y documente cuál reduce mejor asimetría, curtosis excesiva y heterocedasticidad.

Actividad 2: informe crítico

Elabore un informe comparando dos estrategias para una variable positiva sesgada: transformar con logaritmo versus modelar directamente con una familia Gamma. Discuta ventajas inferenciales, interpretativas y predictivas.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Distribuciones univariadas y estadística descriptiva](#)

[Ir al siguiente capítulo: Normalización, estandarización y whitening](#)

[Saltar al capítulo de transformaciones por tipo de dato](#)

Normalización, estandarización y whitening

5.1 Transformar no es lo mismo que escalar

Una **transformación** altera la forma funcional de una variable: logaritmo, Box–Cox, logit. Un **escalamiento** modifica posición y/o escala sin cambiar esencialmente la forma: centrar, dividir por desviación estándar, reescalar a $[0, 1]$, normalizar a norma unitaria.

Esta distinción es fundamental. Un histograma sesgado sigue sesgado después de min–max; simplemente ocupa otro intervalo.

5.2 Centrado

El centrado por columnas se define como

$$Z = X - \mathbf{1}\mu^\top = HX,$$

donde $\mu = (\mu_1, \dots, \mu_p)^\top$ es el vector de medias. El centrado hace que cada variable tenga media cero.

Utilidad:

- simplifica interpretación de interacciones y efectos;
- es requisito práctico para PCA y muchos métodos basados en covarianza;
- mejora la estabilidad numérica de optimización.

5.3 Estandarización z-score

La estandarización clásica por columnas es

$$Z = X_c D_s^{-1},$$

donde $D_s = \text{diag}(s_1, \dots, s_p)$ y s_j es la desviación estándar de la columna j . Entonces cada variable tiene media cero y desviación estándar uno.

Si S es la covarianza de X , la covarianza de Z es

$$\text{Cov}(Z) = D_s^{-1} S D_s^{-1} = R.$$

Es decir, estandarizar convierte la covarianza en correlación.

5.3.1 Cuándo es apropiada

- cuando las unidades difieren fuertemente;
- cuando el método depende de distancias o regularización;
- cuando interesa comparar variables en desviaciones estándar.

5.3.2 Cuándo falla

- presencia de outliers fuertes, porque media y desviación estándar son sensibles;
- colas muy pesadas o momentos inestables;
- variables donde la magnitud física absoluta es relevante.

5.4 Min-max

Para una variable x ,

$$z = \frac{x - \min(x)}{\max(x) - \min(x)}.$$

Generaliza a un intervalo $[a, b]$ por una transformación afín posterior.

Ventajas:

- útil cuando un algoritmo o interfaz exige valores acotados;
- conserva el orden y la forma relativa.

Desventajas:

- extremadamente sensible a outliers;
- el rango cambia si aparecen nuevos valores fuera de muestra.

5.5 Robust scaling

Una alternativa robusta es

$$z = \frac{x - \text{med}(x)}{\text{IQR}(x)} \quad \text{o} \quad z = \frac{x - \text{med}(x)}{\text{MAD}(x)}.$$

También se emplea el z-score robusto:

$$z^{\text{rob}} = 0,6745 \frac{x - \text{med}(x)}{\text{MAD}(x)}.$$

Ventaja clave: conserva una noción de escala comparable sin quedar secuestrado por unos pocos extremos.

5.6 Max–Abs y normalización para matrices dispersas

El escalamiento Max–Abs usa

$$z = \frac{x}{\max_i |x_i|}.$$

Es útil cuando se desea mantener la dispersión o esparsidad, por ejemplo en matrices de texto o conteos muy dispersos.

5.7 Normalización a norma unitaria

Aquí la operación se aplica sobre filas u observaciones:

$$\tilde{x}_i = \frac{x_i}{\|x_i\|_2}.$$

Esto preserva dirección y destruye magnitud. Es apropiado cuando el ángulo entre vectores importa más que su longitud, como en recuperación de información o comparación de perfiles de consumo relativos.

Cuidado conceptual

Normalizar a norma unitaria una fila de variables económicas puede eliminar precisamente la magnitud que distingue a un gran cliente de uno pequeño. No es una operación inocua.

5.8 Whitening

Sea Σ una matriz de covarianza positiva definida. Una transformación de whitening busca

$$Z = X_c \Sigma^{-1/2},$$

de modo que

$$\text{Cov}(Z) = I.$$

Esto no sólo estandariza varianzas; también elimina correlaciones lineales.

Hay varias versiones:

- **PCA whitening:** rota al sistema de autovectores y reescala por los autovalores.

- **ZCA whitening:** produce una representación “lo más cercana posible” en sentido euclidiano a la original, pero con covarianza identidad.

Uso típico: preprocesamiento para ciertos métodos de señal, visión por computador o análisis exploratorio donde interesa neutralizar covarianza lineal.

5.9 Por qué el algoritmo determina la necesidad de escalar

5.9.1 Métodos muy sensibles a escala

- k-NN, k-means y clustering basado en distancias;
- SVM con kernels basados en distancia;
- PCA y métodos espectrales;
- regresión penalizada (Lasso, Ridge, Elastic Net);
- redes neuronales y métodos con gradiente.

5.9.2 Métodos relativamente poco sensibles

- árboles de decisión, random forest y gradient boosting con árboles;
- reglas basadas en umbrales sobre una sola variable;
- algunos modelos bayesianos con escalas internas adaptativas.

Observación 5.1. Que un método sea “insensible” a escala no significa que el EDA pueda ignorarla. La escala sigue afectando interpretabilidad, detección de anomalías, visualización y estabilidad numérica en análisis auxiliares.

5.10 Escalamiento y fuga de información

Los parámetros de escalamiento deben estimarse **sólo en el conjunto de entrenamiento**. Si se usan media, desviación o cuantiles de todo el dataset antes de dividir, se filtra información de validación al entrenamiento.

Listing 5.1: Patrón correcto con `scikit-learn`

```
from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, RobustScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression

num_cols = ["edad", "ingreso", "gasto_mensual"]
cat_cols = ["ciudad", "segmento"]
```

```

numeric_pipe = Pipeline([
    ("imputer", SimpleImputer(strategy="median")),
    ("scaler", RobustScaler())
])

categorical_pipe = Pipeline([
    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("onehot", OneHotEncoder(handle_unknown="ignore"))
])

preprocess = ColumnTransformer([
    ("num", numeric_pipe, num_cols),
    ("cat", categorical_pipe, cat_cols)
])

model = Pipeline([
    ("preprocess", preprocess),
    ("clf", LogisticRegression(max_iter=2000))
])

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

model.fit(X_train, y_train)

```

5.11 Tabla comparativa de métodos de escalamiento

Método	Definición	Robustez outliers	a	Uso típico
Centrado	$x - \bar{x}$	Baja		PCA, regresión con interacciones, análisis de covarianza.
z-score	$(x - \bar{x})/s$	Baja		Métodos basados en distancia y regularización.
Min-max	$(x - \text{mín})/(\text{máx} - \text{mín})$	Muy baja		Redes con entradas acotadas, visualización, algunos modelos ad hoc.
Robust scaling	$(x - \text{med})/\text{IQR}$ o $(x - \text{med})/\text{MAD}$	Alta		Colas pesadas, datasets con valores extremos reales.

Método	Definición	Robustez a outliers	Uso típico
Max–Abs	$x / \max x $	Baja a media	Matrices dispersas, texto, conteos esparsos.
Norma unitaria	$x / \ x\ $ por fila	Media	Similitud angular, perfiles relativos, texto.
Whitening	$X_c \Sigma^{-1/2}$	Baja si Σ no es robusta	Señal, visión, análisis espectral.

5.12 Ejemplo geométrico

Considere dos variables: edad en años e ingreso anual en dólares. En la métrica euclidiana sin escalar, una diferencia de 10 000 dólares eclipsa una diferencia de 5 años. Si el objetivo del algoritmo es medir cercanía entre perfiles, el espacio está mal condicionado. Con z-score, ambas variables pasan a medirse en unidades de desviación estándar. Con robust scaling, se evita que unos pocos multimillonarios definan la noción de distancia.

Síntesis del capítulo

Escalar es elegir una métrica práctica para el espacio de variables. La elección correcta depende de la geometría que el algoritmo utilizará y de la estabilidad estadística de los parámetros de escala.

Ejercicios teóricos

1. Pruebe que la covarianza de la matriz z-score es la matriz de correlación.
2. Explique por qué min–max es especialmente frágil en presencia de un único outlier extremo.
3. Derive la covarianza de $Z = X_c \Sigma^{-1/2}$ y explique cuándo existe $\Sigma^{-1/2}$.
4. Dé un ejemplo donde la normalización a norma unitaria destruya información crucial.

Actividades aplicadas

Actividad 1: impacto sobre k-means

Ejecute k-means sobre un dataset con variables en escalas muy distintas. Compare resultados sin escalamiento, con z-score y con robust scaling. Analice desplazamiento de centroides, inercia y estabilidad de clusters.

Actividad 2: PCA sobre covarianza vs correlación

Tome un dataset multivariado real. Ejecute PCA una vez sobre la covarianza original y otra sobre variables estandarizadas. Compare autovalores, cargas y explicabilidad de los componentes.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Transformaciones de variables numéricas](#)

[Ir al siguiente capítulo: Dependencia, correlación y asociación](#)

[Saltar al capítulo de distribuciones multivariadas](#)

Parte III

Dependencia y estructura multivariada

Dependencia, correlación y asociación

6.1 La dependencia no es un número único

En EDA multivariado, el objetivo no es sólo medir si dos variables se mueven juntas. Es determinar **cómo** se relacionan: linealmente, monótonamente, por concordancia ordinal, por asociación categórica, por dependencia no lineal o por estructura condicionada a otras variables.

6.2 Pearson

Para dos variables numéricas X e Y :

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

En muestra:

$$r_{XY} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}.$$

Interpretación correcta: Pearson mide asociación lineal. No detecta dependencias no lineales simétricas complejas.

6.2.1 Sensibilidad

Pearson es sensible a outliers, heterocedasticidad y mezclas de subpoblaciones. Dos grupos con pendientes opuestas pueden producir correlación cercana a cero en agregado.

6.3 Spearman y Kendall

6.3.1 Spearman

Es la correlación de Pearson aplicada a rangos. Mide asociación monotónica:

$$\rho_s = \text{Corr}(\text{rank}(X), \text{rank}(Y)).$$

6.3.2 Kendall

Basada en pares concordantes y discordantes. Es útil con variables ordinales o muestras moderadas donde interesa una interpretación de concordancia.

6.4 Asociación según tipo de variable

Tipo de variables	Medidas sugeridas	Comentario
Numérica – Numérica	Pearson, Spearman, Kendall, información mutua	Elegir según linealidad, monotonicidad y robustez.
Binaria – Numérica	Correlación punto-biserial, diferencia de medias, AUC	El punto-biserial es un caso particular de Pearson.
Nominal – Nominal	χ^2 , V de Cramér, razón de verosimilitud	No tiene sentido usar Pearson sobre códigos arbitrarios.
Ordinal – Ordinal	Kendall, Spearman, gamma de Goodman–Kruskal	Preservan estructura de orden.
Nominal – Numérica	ANOVA, eta-cuadrado, razón de correlación η^2	Evalúa cuánto de la variación numérica explica la partición categórica.

6.5 Matriz de correlación y geometría de la covarianza

Una matriz de correlación no es sólo una tabla: es una representación compacta de la orientación relativa de las variables en el espacio estandarizado. Si varias columnas muestran correlaciones altas, hay redundancia direccional. Eso puede afectar:

- interpretabilidad de coeficientes lineales,
- estabilidad numérica,
- selección de variables,
- separabilidad en PCA.

6.6 Multicolinealidad y VIF

Sea R_j^2 el coeficiente de determinación de la regresión de la variable X_j sobre el resto de predictores. El factor de inflación de varianza es

$$\text{VIF}_j = \frac{1}{1 - R_j^2}.$$

Valores altos indican que X_j es casi combinación lineal de otras variables.

Observación 6.1. La multicolinealidad no necesariamente daña la predicción, pero sí puede volver inestables e ininterpretables los coeficientes.

6.7 Correlación parcial

La correlación parcial entre X e Y dado Z busca aislar la asociación residual una vez descontado el efecto lineal de Z . Es útil para distinguir asociaciones directas de asociaciones espurias debidas a una tercera variable.

6.8 Dependencia no lineal

Variables pueden ser fuertemente dependientes y tener correlación lineal casi cero. Ejemplo clásico:

$$Y = X^2, \quad X \sim \mathcal{N}(0, 1).$$

Entonces $\text{Corr}(X, Y) = 0$, aunque Y depende determinísticamente de X .

En EDA, esto obliga a complementar correlaciones con:

- diagramas de dispersión,
- suavizadores locales,
- información mutua,
- gráficos por estratos o facetas.

6.9 Heterocedasticidad

La dispersión de Y puede cambiar con el nivel de X . Esto es importante porque:

- sugiere transformaciones de varianza;
- puede invalidar inferencia homocedástica clásica;
- afecta la calibración de intervalos de predicción.

6.10 Asociación y causalidad

Advertencia epistemológica

Correlación no implica causalidad. Una asociación fuerte puede provenir de confusión, selección, estacionalidad, variables omitidas o simple mezcla de subpoblaciones.

Síntesis del capítulo

Elegir una medida de dependencia depende del tipo de dato y de la estructura que se desea capturar. Pearson, Spearman, Kendall, V de Cramér e información mutua no compiten entre sí; responden a preguntas distintas.

Ejercicios teóricos

1. Demuestre que la correlación punto-biserial es una instancia de Pearson cuando una variable es binaria.
2. Dé un ejemplo donde la correlación de Pearson sea cero pero exista dependencia determinística.
3. Interprete VIF desde la perspectiva del espacio columna de la matriz de diseño.
4. Explique por qué usar Pearson sobre códigos nominales arbitrarios es un error.

Actividades aplicadas

Actividad 1: mapa de dependencias por tipo

En un dataset mixto, construya una matriz ampliada donde cada par de variables se analice con la medida de asociación adecuada. Documente por qué no usó la misma medida en todos los casos.

Actividad 2: dependencia no lineal

Simule una relación no lineal con correlación lineal cercana a cero. Muestre cómo cambian las conclusiones al usar Pearson, Spearman y un gráfico de dispersión con suavizado.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Normalización, estandarización y whitening](#)

[Ir al siguiente capítulo: Distribuciones multivariadas, outliers y reducción de dimensión](#)

[Saltar al capítulo de transformaciones por tipo de dato](#)

Distribuciones multivariadas, outliers y reducción de dimensión

7.1 De la marginal a la conjunta

Saber que cada variable por separado es aproximadamente normal no implica que el vector conjunto sea multivariado normal. La información multivariada reside en la dependencia, no sólo en los márgenes.

7.2 Normal multivariada

Un vector $X \in \mathbb{R}^p$ sigue una normal multivariada si su densidad es

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right\}.$$

Sus contornos de igual densidad son elipsoides centrados en μ .

Consecuencias útiles:

- toda combinación lineal $a^\top X$ es normal;
- la covarianza contiene toda la dependencia lineal;
- la distancia natural es la de Mahalanobis.

7.3 Distancia de Mahalanobis

$$d_M(x) = \sqrt{(x - \mu)^\top \Sigma^{-1} (x - \mu)}.$$

A diferencia de la distancia euclidiana, esta métrica corrige por escala y correlación. Si el conjunto sigue una normal multivariada, entonces d_M^2 se compara naturalmente con una distribución χ_p^2 .

7.3.1 Lectura geométrica

Una observación puede parecer extrema en una coordenada y no serlo multivariadamente, o al revés. El outlier multivariado es una observación lejana del *centro elíptico* del conjunto, no necesariamente extrema en una variable aislada.

7.4 Distribuciones elípticas y t multivariada

La t multivariada generaliza la normal introduciendo colas más pesadas. Esto es importante en finanzas, señales con perturbaciones extremas y datasets contaminados.

Implicación: usar covarianza clásica para detectar anomalías puede sobre-reaccionar o sub-reaccionar según el grado de contaminación. A menudo conviene una covarianza robusta.

7.5 Mezclas gaussianas y multimodalidad conjunta

Una mezcla de gaussianas produce clusters con centros y covarianzas distintos. En este contexto:

- un outlier global puede ser un punto perfectamente típico dentro de un cluster pequeño;
- estandarizar globalmente puede ocultar la estructura local;
- conviene combinar análisis de densidad, clustering y visualización.

7.6 Copulas: separar márgenes y dependencia

Una idea avanzada pero muy útil es que la distribución conjunta puede descomponerse en márgenes y copula:

$$F(x_1, \dots, x_p) = C(F_1(x_1), \dots, F_p(x_p)).$$

Esto significa que dos datasets pueden tener márgenes normalizados idénticos y aun así depender de forma distinta. Por eso “gaussianizar” cada variable por separado no garantiza un espacio conjunto gaussiano.

7.7 Outliers multivariados

7.7.1 Métodos clásicos

- distancia de Mahalanobis con covarianza clásica;
- inspección en PCA;
- reglas sobre puntuaciones principales.

7.7.2 Métodos robustos

- Minimum Covariance Determinant (MCD),
- robust Mahalanobis distance,
- Local Outlier Factor,
- Isolation Forest.

7.7.3 Decisión correcta

No todo outlier se elimina. En fraude, mantenimiento predictivo o medicina, la región rara del espacio puede ser el objetivo del proyecto.

7.8 Curse of dimensionality

En alta dimensión, las distancias tienden a concentrarse. Consecuencias:

- la noción intuitiva de “vecino cercano” se degrada;
- la densidad local es difícil de estimar;
- el escalamiento y la selección de variables se vuelven críticos.

7.9 PCA

Sea $S = Q\Lambda Q^\top$ la covarianza o correlación. Las puntuaciones principales son

$$T = X_c Q.$$

PCA permite [10, 11]:

- detectar direcciones dominantes de varianza;
- revelar redundancia;
- construir visualizaciones bidimensionales;
- apoyar detección de anomalías.

Decisión clave: si las variables tienen unidades heterogéneas, PCA suele hacerse sobre variables estandarizadas. Si las unidades son homogéneas y la magnitud absoluta importa, puede ser preferible trabajar sobre covarianza sin estandarizar.

7.10 t-SNE y UMAP

Estas técnicas no lineales ayudan a visualizar estructura local en alta dimensión. Sin embargo:

- no conservan métricas globales de manera fiable;
- pueden sugerir clusters que dependen fuertemente de hiperparámetros;
- son herramientas exploratorias, no pruebas formales.




Figura 7.1: Ejemplo geométrico de whitening. La nube original tiene covarianza anisotrópica; al multiplicar por $\Sigma^{-1/2}$ se obtiene una nube aproximadamente isotrópica. Esta operación es útil cuando la geometría euclidiana debe neutralizar dependencia lineal y escala conjunta.

7.11 Tabla de decisión multivariada

Patrón multivariado	Lectura	Decisión
Elipsoides aproximadamente homogéneos	Dependencia lineal compatible con normalidad elíptica	Mahalanobis, PCA, z-score y métodos lineales razonables.
Colas pesadas multivariadas	Normalidad insuficiente	robust covariance, robust scaling, t multivariada, métodos resistentes.
Clusters bien separados	Mezcla de subpoblaciones	clustering, segmentación, modelos por grupo o mezcla.
Dependencia no lineal	Correlación insuficiente	kernel methods, features no lineales, visualización local, información mutua.
Alta colinealidad	Redundancia direccional	PCA, regularización, eliminación o agrupación de variables.

Síntesis del capítulo

La estructura multivariada decide qué significa cercanía, rareza y redundancia. Estandarizar márgenes es apenas el inicio; la geometría conjunta puede cambiar completamente la estrategia.

Ejercicios teóricos

1. Demuestre que si $X \sim \mathcal{N}_p(\mu, \Sigma)$, entonces $d_M^2(X)$ sigue una χ_p^2 .
2. Explique por qué marginales gaussianos no implican normalidad multivariada.
3. Compare conceptualmente PCA y whitening.
4. Discuta por qué un outlier multivariado puede no ser un outlier univariado.

Actividades aplicadas

Actividad 1: outliers multivariados

En un dataset con al menos 5 variables numéricas, detecte anomalías usando distancia de Mahalanobis clásica, MCD e Isolation Forest. Compare coincidencias y discrepancias.

Actividad 2: estructura latente

Ejecute PCA y, si es posible, UMAP o t-SNE. Discuta qué estructuras son estables y cuáles podrían ser artefactos de visualización.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Dependencia, correlación y asociación](#)

[Ir al siguiente capítulo: Transformaciones según el tipo de dato](#)

[Saltar al capítulo de variable objetivo y modelado](#)

Parte IV

Transformaciones por tipo de dato y calidad de datos

Transformaciones según el tipo de dato

8.1 El tipo de dato determina la clase de transformaciones válidas

La pregunta correcta no es “¿qué escalador me falta aplicar?”, sino “¿qué clase de objeto matemático tengo delante?”. La tabla siguiente resume decisiones por tipo de dato.

Tipo de dato	Riesgo habitual	Transformaciones candidatas	Observación clave
Continuo aproximadamente simétrico	Escala desbalanceada	centrado, z-score	No transformar por costumbre si la interpretación original es útil.
Continuo positivo sesgado	Asimetría y heterocedasticidad	log, Box–Cox, Yeo–Johnson, robust scaling	Suelen corresponder a procesos multiplicativos.
Conteos	Media-varianza acopladas, masa en cero	raíz, Anscombe, log1p, tasas por exposición	A veces conviene GLM Poisson/NegBin en vez de transformar.
Proporciones y tasas	Fronteras en 0/1, varianza dependiente de media	logit con suavizado, Beta, razón sobre exposición	La tasa exige considerar el denominador.
Binaria	Desbalance de clases	no escalar, coding 0/1, pesos de clase	La “normalización” no tiene sentido aquí.
Ordinal	Distancias artificiales	codificación ordinal cuidadosa, efectos monotónicos	No asumir equidistancia sin justificación.
Nominal	Geometría arbitraria si se codifica 1,2,3	one-hot, rare-level pooling, frequency encoding	El entero arbitrario es una falsa métrica.

Tipo de dato	Riesgo habitual	Transformaciones candidatas	Observación clave
Temporal	Tendencias, estacionalidad, fuga temporal	lags, diferencias, rolling stats, seno/coseno para ciclos	Separar fecha absoluta, duración y componente cíclica.
Texto	Alta dimensionalidad, esparsidad	TF-IDF, embeddings, conteos, longitudes	EDA requiere resumen agregado, no sólo vectorización.
Composicional	Dependencia por suma constante	clr, alr, ilr	No usar correlaciones directas sobre porcentajes crudos.

8.2 Conteos y tasas

Una cuenta no es un continuo redondeado. Está definida en $\mathbb{N}_0$ y suele depender de una **exposición**. Diez clics en una hora no significan lo mismo que diez clics en un minuto. Por eso muchas veces la variable relevante no es el conteo bruto sino la tasa:

$$\text{tasa} = \frac{\text{conteo}}{\text{exposición}}.$$

Observación 8.1. Transformar un conteo sin incorporar exposición puede ocultar la verdadera variabilidad del proceso.

8.3 Proporciones, porcentajes y razones

Proporciones y razones comparten valores numéricos similares, pero son entidades distintas:

- una **proporción** está acotada entre 0 y 1 y suele tener denominador natural;
- una **razón** puede ser positiva sin cota superior;
- un **porcentaje** es sólo una reexpresión de la proporción.

Si la variable representa tasa de conversión, puede haber inflación en cero; si representa participación de presupuesto, puede formar parte de una composición.

8.4 Variables categóricas

8.4.1 Nominale

Tratamiento típico: one-hot encoding, agrupación de categorías raras, frecuencias, embeddings categóricos si el contexto lo permite. Nunca debe aplicarse z-score sobre códigos arbitrarios 1, 2, 3.

8.4.2 Ordinales

Si el orden es real pero las distancias no, puede usarse una codificación ordinal con modelos que respeten monotonicidad. En otros casos conviene one-hot para evitar una métrica no justificada.

8.4.3 Categorías raras

Las categorías con muy pocos casos generan alta varianza. Estrategias:

- agrupar en “otros” si tiene sentido semántico;
- usar codificación por frecuencia;
- aplicar regularización o codificación supervisada con cuidado extremo para evitar fuga.

8.5 Variables temporales y cíclicas

La fecha contiene varias capas:

- orden temporal,
- tendencia,
- periodicidad,
- duración desde un evento,
- posible estacionalidad.

Para ciclos de periodo T :

$$x_{\sin} = \sin\left(2\pi\frac{t}{T}\right), \quad x_{\cos} = \cos\left(2\pi\frac{t}{T}\right).$$

Esta codificación evita el falso salto entre el final y el inicio del ciclo.




Figura 8.1: Codificación cíclica para variables temporales periódicas. La pareja seno/coseno evita el salto artificial entre el último y el primer valor del ciclo.

Ejemplo 8.2. La hora 23 y la hora 0 están muy cerca en tiempo, pero muy lejos si se representan como enteros. El par seno/coseno corrige ese problema.

8.6 Variables de texto

El EDA de texto rara vez comienza por embeddings profundos. Conviene analizar primero:

- longitudes de documento,
- vocabulario,
- frecuencia de tokens,
- porcentaje de caracteres especiales,
- idioma, duplicados y plantillas repetidas.

Luego pueden emplearse representaciones como TF-IDF o embeddings. El preprocesamiento elegido cambia la geometría del espacio y, por tanto, la interpretación de similitud.

8.7 Datos composicionales

Sea $x = (x_1, \dots, x_D)$ un vector con $x_i > 0$ y $\sum_i x_i = 1$. Estos datos viven en un simplex. Las correlaciones directas sobre porcentajes crudos pueden ser espurias por la restricción de suma.

8.7.1 Transformación clr

La centered log-ratio es [2]:

$$\text{clr}(x)_i = \log\left(\frac{x_i}{g(x)}\right), \quad g(x) = \left(\prod_{i=1}^D x_i\right)^{1/D},$$

donde $g(x)$ es la media geométrica.

8.7.2 Transformación ilr

La isometric log-ratio construye coordenadas ortonormales en el simplex [4]. Es preferible cuando se desea una representación euclidiana rigurosa para modelado y PCA.

Error frecuente

Estandarizar porcentajes que suman 100 sin antes reconocer que son composiciones puede inducir conclusiones falsas sobre correlaciones y clusters.

8.8 Variables espaciales y coordenadas

Latitud y longitud no forman un espacio cartesiano euclidiano simple a escala global. Según el problema puede requerirse:

- proyección cartográfica adecuada,
- cálculo de distancias geodésicas,
- agregación por zonas,
- extracción de vecindad o densidad local.

Síntesis del capítulo

El tipo de dato determina la familia de transformaciones razonables. Tratar categorías, composiciones, ciclos y cuentas como si fueran sólo “números” es perder la estructura que hace informativo al dato.

Ejercicios teóricos

1. Explique por qué la transformación clr produce coordenadas cuya suma es cero.
2. Justifique por qué un entero ordinal no debe interpretarse necesariamente con distancia euclidiana.
3. Demuestre que la codificación seno/coseno para ciclos sitúa puntos de tiempos cercanos con distancia angular pequeña.
4. Distinga formalmente entre conteo, tasa y proporción.

Actividades aplicadas

Actividad 1: matriz de decisión por tipo

Construya una matriz de variables de un dataset mixto y, para cada columna, indique tipo de dato, soporte, riesgo principal, transformación o codificación recomendada y justificación estadística.

Actividad 2: caso composicional

Consiga un dataset de presupuestos, nutrientes, participaciones de mercado o mezcla de componentes. Compare correlaciones y PCA antes y después de aplicar una transformación log-ratio.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Distribuciones multivariadas, outliers y reducción de dimensión](#)

[Ir al siguiente capítulo: Calidad de datos, faltantes y outliers](#)

[Saltar al capítulo de transformaciones numéricas](#)

Calidad de datos, faltantes y outliers

9.1 La calidad de datos precede a la modelación

Antes de transformar, hay que verificar si el dato merece ser transformado. Valores imposibles, duplicados, cambios de unidad, categorías mal escritas y registros inconsistentes son problemas de calidad, no de escalamiento.

9.2 Valores faltantes

9.2.1 Mecanismos de ausencia

- **MCAR**: Missing Completely At Random.
- **MAR**: Missing At Random condicionado a observables.
- **MNAR**: Missing Not At Random.

Cada mecanismo induce decisiones distintas. Imputar una variable MNAR con la media puede introducir sesgo severo y borrar un patrón informativo.

9.2.2 Estrategias de tratamiento

- eliminación si la pérdida de información es pequeña y el mecanismo lo justifica;
- imputación simple: media, mediana, moda;
- imputación por modelo: KNN, MICE, regresión;
- indicador de faltante cuando la ausencia tiene valor predictivo.

Observación 9.1. La imputación debe incorporarse al pipeline y ajustarse sólo en entrenamiento, igual que el escalamiento.

9.3 Detección de outliers univariados

9.3.1 Regla IQR

Se consideran atípicos valores por debajo de

$$Q_1 - 1,5 \text{ IQR}$$

o por encima de

$$Q_3 + 1,5 \text{ IQR}.$$

9.3.2 z-score clásico

$$z_i = \frac{x_i - \bar{x}}{s}.$$

Es razonable sólo bajo colas moderadas y escala bien definida.

9.3.3 z-score robusto

$$z_i^{\text{rob}} = 0,6745 \frac{x_i - \text{med}(x)}{\text{MAD}(x)}.$$

Más estable ante colas pesadas y contaminación.

9.4 Outliers multivariados

Los métodos del **Capítulo 7** son esenciales cuando la rareza emerge de la combinación de variables. Un cliente puede no ser extremo ni en edad ni en gasto, pero sí en la combinación edad–gasto–frecuencia de compra.

9.5 Eliminar, corregir, winsorizar o conservar

Situación	Tratamiento razonable
Error de captura evidente	Corregir o excluir, documentando la regla.
Cambio de unidad o escala	Reparar mediante validación de dominio.
Evento raro pero real	Conservar; posiblemente usar métodos robustos o segmentar.
Valor extremo que domina el escalamiento	Robust scaling, winsorización justificada o modelado de colas.

9.5.1 Winsorización

Consiste en truncar valores extremos a cuantiles predefinidos. Puede estabilizar modelos sensibles, pero modifica la distribución y puede ocultar señales críticas. Debe documentarse rigurosamente.

9.6 Duplicados e inconsistencias

Un duplicado no siempre es un error. Puede representar:

- una repetición real de evento,
- un problema de integración,
- un cambio temporal no capturado por la clave primaria.

La deduplicación sin criterio semántico puede destruir eventos legítimos.

9.7 Rareza categórica

Las categorías raras influyen en codificaciones y escalamiento posteriores. Agruparlas puede reducir varianza, pero fusionar categorías semánticamente distintas puede destruir señal causal o predictiva.

Síntesis del capítulo

La limpieza no es una operación cosmética. Es una intervención estadística que puede alterar sesgos, varianzas, colas y significado. Toda depuración debe quedar registrada como decisión científica.

Ejercicios teóricos

1. Distinga conceptualmente MCAR, MAR y MNAR con un ejemplo para cada caso.
2. Compare IQR y z-score robusto como herramientas de detección de outliers.
3. Explique por qué la winsorización puede mejorar métricas predictivas y, al mismo tiempo, perjudicar la inferencia sobre extremos.
4. Dé un ejemplo donde un duplicado sea una observación legítima.

Actividades aplicadas

Actividad 1: auditoría de calidad

Diseñe una batería de reglas de validación para un dataset real: rangos admisibles, consistencia entre columnas, duplicados, faltantes por variable, porcentajes de categorías raras y outliers univariados/multivariados.

Actividad 2: experimento de imputación

Compare, en un problema predictivo, imputación por media, mediana, KNN y MICE. Evalúe no sólo la métrica del modelo, sino también el cambio en distribuciones y correlaciones.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Transformaciones según el tipo de dato](#)

[Ir al siguiente capítulo: Variable objetivo, familias de modelos y métricas](#)

[Saltar al capítulo de pipeline reproducible](#)

Parte V

Interfaz entre EDA y modelado

Variable objetivo, familias de modelos y métricas

10.1 La variable objetivo cambia todo

La misma matriz de predictores puede requerir estrategias completamente distintas según el tipo de objetivo:

- clasificación binaria o multiclase,
- regresión continua,
- conteo,
- proporción,
- supervivencia,
- ranking o recomendación.

10.2 Objetivos continuos

10.2.1 Regresión con objetivo aproximadamente gaussiano

En este caso un modelo lineal puede ser razonable si las relaciones son aproximadamente lineales y el ruido tiene varianza estable.

10.2.2 Objetivo sesgado o heterocedástico

Si Y es positivo y sesgado, transformar el objetivo con logaritmo puede estabilizar la varianza y facilitar la linealidad. Pero siempre debe pensarse en la escala final donde se tomarán decisiones.

10.3 Objetivos de conteo

Un objetivo de conteo con soporte en enteros no negativos rara vez se beneficia de una regresión lineal directa. Las familias Poisson o Binomial Negativa respetan soporte y estructura media-varianza. Transformar con $\log 1p$ y ajustar OLS puede funcionar como aproximación, pero no sustituye el razonamiento probabilístico.

10.4 Objetivos proporcionales

Si el target está en $(0, 1)$, se puede pensar en:

- regresión Beta,
- logística fraccional,
- transformación logit y modelo lineal si la situación lo justifica.

10.5 Clasificación y desbalance

En clasificación, el primer EDA del objetivo es su prevalencia:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Si una clase es muy rara, la exactitud puede ser un engaño. Deben considerarse:

- *precision*, *recall*, F1,
- curva ROC y PR,
- pesos de clase,
- remuestreo,
- calibración de probabilidades.

10.6 Objetivos temporales y de supervivencia

Cuando el objetivo es tiempo hasta evento y hay censura, transformar la variable no resuelve el problema principal. Se requiere un marco de supervivencia. El EDA debe estudiar:

- tasa de censura,
- distribución del tiempo observado,
- covariables dependientes del tiempo,
- riesgos competitivos si existen.

10.7 Métricas y transformaciones

La transformación del objetivo altera el significado de la función de pérdida. Minimizar MSE en log-escala no equivale a minimizar error cuadrático absoluto en escala original. En problemas de negocio esto puede ser decisivo.

Ejemplo 10.1. Si se predice demanda con log-transformación, el modelo tenderá a optimizar error relativo más que error absoluto en unidades originales. Esto puede ser deseable para series muy heterocedásticas, pero no si el costo económico está en unidades absolutas.

10.8 Fuga de información asociada al objetivo

Toda decisión de preprocesamiento que use directamente la variable objetivo debe extremar cuidado:

- target encoding sin validación anidada induce fuga;
- selección de variables sobre todo el dataset antes del split genera optimismo;
- imputaciones que usan el target pueden contaminar evaluación.

10.9 Tabla de decisiones objetivo–modelo

Tipo de objetivo	Señales a inspeccionar en EDA	Decisiones frecuentes
Continuo aproximadamente simétrico	rango, outliers, linealidad, heterocedasticidad	OLS, Ridge, árboles, estandarización según algoritmo.
Continuo positivo sesgado	soporte, colas, varianza creciente	log-target, Gamma GLM, quantile regression.
Binario desbalanceado	prevalencia, separabilidad, costos de error	pesos de clase, métricas PR, calibración, umbral óptimo.
Conteo	media-varianza, ceros, exposición	Poisson, NegBin, offsets, log1p como exploración.
Proporción	masa en 0/1, forma, denominador	Beta, logística fraccional, logit con suavizado.
Supervivencia	censura, tiempo al evento, truncamiento	Kaplan–Meier, Cox, AFT, no tratar como regresión ordinaria.

Síntesis del capítulo

EDA no termina en los predictores. La variable objetivo define la pérdida, la métrica, la evaluación y, en muchos casos, la transformación más importante del proyecto.

Ejercicios teóricos

1. Explique por qué minimizar MSE sobre $\log Y$ no equivale a minimizar MSE sobre Y .
2. Compare regresión Poisson y OLS sobre $\log(1 + Y)$ para un objetivo de conteo.
3. Describa dos efectos del desbalance de clases sobre la evaluación.
4. Justifique por qué un problema con censura no debe tratarse como regresión estándar.

Actividades aplicadas

Actividad 1: perfil completo del objetivo

Tome un problema supervisado real. Elabore una ficha del target con distribución, balance, outliers, estabilidad temporal y relación bivariada con al menos cinco predictores.

Actividad 2: experimento de transformación del objetivo

Compare el desempeño de un modelo para predecir una variable continua positiva usando: (i) objetivo original, (ii) log-objetivo, (iii) modelo Gamma si es viable. Discuta métricas en ambas escalas.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Calidad de datos, faltantes y outliers](#)

[Ir al siguiente capítulo: Pipeline reproducible de EDA y preprocesamiento](#)

[Saltar al capítulo de casos integrales](#)

Pipeline reproducible de EDA y preprocesamiento

11.1 Un EDA profesional debe dejar trazabilidad

Toda transformación aplicada a una variable debe responder, por escrito, a cuatro preguntas:

1. ¿Qué patrón empírico se observó?
2. ¿Qué hipótesis sobre el PGD justifica la decisión?
3. ¿Qué operación concreta se aplicará?
4. ¿Cómo se validará que la decisión mejora la representación sin dañar la interpretación?

11.2 Orden recomendado de trabajo

1. Separar conjuntos de entrenamiento, validación y prueba según el diseño del problema.
2. Construir diccionario de datos y clasificar variables por tipo.
3. Auditar calidad: faltantes, duplicados, dominios inválidos, rareza categórica.
4. Estudiar distribuciones marginales y proponer transformaciones.
5. Analizar asociaciones y estructura multivariada.
6. Revisar la variable objetivo.
7. Diseñar pipeline de preprocesamiento reproducible.
8. Evaluar impacto del preprocesamiento sobre el modelo.

11.3 Qué puede verse con todo el dataset y qué no

En la práctica conviene distinguir:

- **inspección estructural** del esquema, nombres, tipos y dominios: puede hacerse sobre el dataset disponible;
- **estimación de parámetros de preprocesamiento** (medias, desviaciones, cuantiles, imputadores): debe hacerse sólo sobre entrenamiento;
- **análisis del target con fines de decisión modelística**: idealmente guiado por entrenamiento, especialmente en contextos con alta sensibilidad a fuga.

11.4 Ficha de decisión por variable

Una plantilla operativa puede contener:

Campo	Contenido
Nombre	Identificador de la variable.
Tipo / escala	Numérica continua, cuenta, ordinal, composición, etc.
PGD plausible	Medición física, conteo de eventos, ratio financiera, etc.
Hallazgos univariados	Sesgo, colas, outliers, multimodalidad.
Hallazgos multivariados	Correlaciones, redundancia, dependencia no lineal.
Problemas de calidad	Faltantes, unidades inconsistentes, rareza.
Tratamiento propuesto	Imputación, transformación, escalamiento, codificación, exclusión.
Justificación	Argumento estadístico y de negocio.
Validación	Métrica, gráfico o comparación para verificar la decisión.

11.5 Pipelines con ColumnTransformer

El principio es separar el preprocesamiento por tipo de variable, y dejar que cada operación se ajuste sólo con datos de entrenamiento.

Listing 11.1: Esqueleto de pipeline reproducible

```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import (
    StandardScaler, RobustScaler, OneHotEncoder,
    PowerTransformer, QuantileTransformer
)
from sklearn.impute import SimpleImputer
from sklearn.linear_model import Ridge
```

```

numeric_skewed = ["ingreso", "monto_siniestro"]
numeric_regular = ["edad", "antiguedad"]
counts = ["num_reclamos"]
categorical = ["ciudad", "segmento"]

preprocess = ColumnTransformer([
    ("skewed", Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("power", PowerTransformer(method="yeo-johnson")),
        ("scale", RobustScaler())
    ]), numeric_skewed),

    ("regular", Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("scale", StandardScaler())
    ]), numeric_regular),

    ("counts", Pipeline([
        ("imputer", SimpleImputer(strategy="constant", fill_value=0)),
        ("quantile", QuantileTransformer(output_distribution="normal"))
    ]), counts),

    ("cat", Pipeline([
        ("imputer", SimpleImputer(strategy="most_frequent")),
        ("onehot", OneHotEncoder(handle_unknown="ignore"))
    ]), categorical),
], remainder="drop")

model = Pipeline([
    ("prep", preprocess),
    ("reg", Ridge(alpha=1.0))
])

```

11.6 Validación de decisiones de EDA

Una decisión de preprocesamiento debe evaluarse en al menos tres planos:

- a) **estadístico**: ¿mejoró simetría, estabilidad de varianza o separación?
- b) **geométrico**: ¿cambió de manera útil la distancia o la estructura espectral?
- c) **predictivo**: ¿mejoró o estabilizó la métrica del modelo fuera de muestra?

11.7 Errores finales de integración

Checklist de errores antes de entrenar

1. Ajustar escaladores e imputadores antes del split.
2. Mezclar variables de distinta granularidad en la misma fila.
3. Aplicar la misma transformación a todo predictor numérico sin distinguir soporte.
4. No registrar la justificación de una winsorización.
5. Hacer target encoding fuera de validación cruzada interna.
6. Estandarizar composiciones en lugar de llevarlas primero al espacio log-ratio.

Síntesis del capítulo

El EDA profesional produce un pipeline auditable. Sin trazabilidad, el preprocesamiento es una colección de trucos; con trazabilidad, se convierte en un procedimiento científico reproducible.

Ejercicios teóricos

1. Explique por qué el preprocesamiento debe formar parte del pipeline y no ejecutarse aparte.
2. Diseñe una ficha de decisión para una variable de conteo con muchos ceros.
3. Dé un ejemplo donde la mejora de una métrica predictiva no justifique una transformación por pérdida de interpretabilidad.
4. Discuta qué partes del EDA deberían restringirse al conjunto de entrenamiento en un problema temporal.

Actividades aplicadas

Actividad 1: bitácora reproducible

Implemente una bitácora de EDA para un proyecto real. Debe incluir fecha, variable, diagnóstico, tratamiento, justificación, evidencia y responsable.

Actividad 2: comparación de pipelines

Construya dos pipelines distintos para el mismo problema: uno ingenuo, con un escalador único para todas las variables numéricas; y otro diferenciado por tipo de dato. Compare desempeño y estabilidad fuera de muestra.

Navegación

[Volver al índice general](#)

[Ir al capítulo anterior: Variable objetivo, familias de modelos y métricas](#)

[Ir al siguiente capítulo: Casos integrales](#)

[Saltar al capítulo inicial](#)

Parte VI

Casos reales integrales

Mapa de los casos integrales

Este bloque aplicado no está pensado como una colección de viñetas decorativas. Cada caso fue seleccionado para representar una *clase distinta de decisión* dentro del DEA/EDA. El objetivo es que el lector no sólo vea transformaciones aisladas, sino que aprenda a reconocer **qué evidencia obliga a cada una y qué errores aparecen cuando se ignora la semántica del dato**. En ese sentido, los casos funcionan como un atlas metodológico.

12.1 Cómo leer esta parte del libro

Cada caso sigue una estructura homogénea:

1. identificación precisa del dataset y de la unidad observacional;
2. auditoría inicial de calidad y soporte;
3. lectura univariada variable por variable o por bloques;
4. lectura multivariada desde álgebra lineal y geometría de la matriz de datos;
5. explicitación del razonamiento mental de una persona analista senior;
6. decisiones dependientes de la familia de modelos posterior;
7. errores frecuentes y actividades de consolidación.

Lo importante es entender que el *mismo* hallazgo no implica siempre la *misma* acción. Una distribución sesgada a la derecha puede motivar un logaritmo si el modelo posterior es lineal o basado en distancia, pero puede no requerir ninguna transformación si se usará un ensamble de árboles. Una colinealidad fuerte puede conducir a PCA, a regularización, a eliminación de variables o a ninguna de las anteriores, según si la prioridad es predicción, interpretación, estabilidad numérica o parsimonia.

Principio de lectura

No lea los casos preguntándose únicamente “qué transformación se aplicó”. Léelos preguntando **qué evidencia descartó alternativas, qué semántica limitó las transformaciones admisibles y qué familia de modelos hizo preferible una representación sobre otra.**

12.2 Los cinco casos y su razón pedagógica

Caso	Tipo de problema	Decisiones pedagógicas centrales
Breast Cancer Wisconsin Diagnostic	Clasificación binaria de alta dimensión	Escalamiento, colinealidad, PCA, Mahalanobis
Wine Recognition	Clasificación multiclase quimiométrica	Escala, sesgo positivo, PCA en covarianza vs correlación
Fair Affairs	Respuesta semicontinua con masa en cero	Ordinalidad, cero-inflación, transformación vs familia de modelo
STAR98	Conteos binomiales con denominador variable	Proporciones, logit empírico, heterocedasticidad, VIF
CO2 de Mauna Loa	Serie temporal semanal	Faltantes, tendencia, estacionalidad, codificación temporal

Tabla 12.1: Catálogo de casos incluidos en el libro. Cada uno enfatiza un patrón distinto de soporte, distribución y estructura multivariada.

12.2.1 Caso I: Breast Cancer Wisconsin Diagnostic

El primer caso es un problema biomédico de clasificación binaria con 30 predictores numéricos positivos o semipositivos. La lección central no es “aplicar PCA porque hay muchas columnas”, sino reconocer que **la escala, la redundancia geométrica y la proximidad entre variables derivadas de la misma forma física** distorsionan cualquier método sensible a distancias si no se trabaja sobre una representación adecuada.

12.2.2 Caso II: Wine Recognition

El segundo caso es quimiométrico y multiclase. Está diseñado para mostrar una distinción fundamental: **PCA sobre covarianza y PCA sobre correlación** no son análisis equivalentes. Cuando las unidades físicas son heterogéneas, la covarianza cruda puede estar dominada por variables de gran magnitud, de modo que la estructura latente visible no describe el fenómeno químico sino la escala de medición.

12.2.3 Caso III: Fair Affairs

El tercer caso es deliberadamente incómodo. La variable de interés tiene una gran masa exacta en cero y una cola positiva extremadamente pesada entre quienes sí registran tiempo en aventuras extramatrimoniales. Aquí el punto crucial es que **no toda variable con ceros y cola derecha debe tratarse como conteo**. El caso fuerza a distinguir soporte observado, soporte teórico y semántica sustantiva.

12.2.4 Caso IV: STAR98

El cuarto caso enseña una idea que suele ignorarse: una proporción no es una variable continua ordinaria cuando su denominador cambia mucho entre observaciones. La varianza de una proporción estimada depende del tamaño muestral; por tanto, ignorar el denominador equivale a ignorar una fuente principal de heterocedasticidad. Además, el dataset incluye interacciones preconstruidas que muestran de manera extrema cómo la ingeniería de variables puede destruir la condicionamiento numérico si se hace sin centrado ni control de colinealidad.

12.2.5 Caso V: CO2 de Mauna Loa

El último caso resuelve un malentendido muy extendido: en series temporales, **transformar la escala** y **transformar la dependencia** son operaciones conceptualmente diferentes. Una serie positiva con tendencia y estacionalidad puede requerir poca o ninguna transformación marginal, pero sí exigir interpolación documentada, diferenciación, codificación cíclica y partición temporal estricta.

12.3 Mapa de decisiones cruzadas

Los cinco casos pueden leerse como respuesta a una batería de preguntas recurrentes del DEA/EDA profesional.

Pregunta de decisión	Caso principal	Hallazgo detonante	Decisión que se entrena
¿Debo transformar por sesgo o escalar por geometría?	Breast / Wine	colas moderadas más escalas muy heterogéneas	distinguir compresión marginal de reponderación geométrica.
¿Tiene sentido hacer PCA?	Breast / Wine	bloques de colinealidad y dominancia de magnitud	decidir entre covarianza, correlación, regularización o selección.
¿Qué hago con una masa grande en cero?	Fair	mezcla de cero estructural y cola pesada positiva	separar incidencia de intensidad; descartar recetas automáticas.
¿Cuándo una proporción necesita logit?	STAR98	acotamiento en $(0, 1)$ y denominadores desiguales	modelar con respeto al soporte binomial y a la heteroscedasticidad.
¿La transformación relevante es de escala o temporal?	CO2	tendencia, estacionalidad y faltantes en la serie	diferenciar nivel, diferencias, estacionalidad y codificación periódica.

12.4 Qué debe aprender el lector al terminar esta parte

Al cerrar el bloque aplicado, el lector debería ser capaz de hacer explícito un razonamiento de este tipo:

Razonamiento senior esperado

“Primero identifico la unidad observacional y el soporte matemático de cada variable. Después separo problemas de calidad, problemas de forma marginal y problemas geométricos. Si encuentro sesgo y cola pesada pregunto si la transformación mejora un supuesto sustantivo o sólo reduce la sensibilidad de un algoritmo concreto. Si encuentro colinealidad pregunto si quiero conservar interpretabilidad, construir ejes latentes o sólo estabilizar una optimización. Si la variable objetivo está acotada, inflada en ceros o depende de una exposición, no la trato como si fuera un continuo libre. Toda decisión la documento como parte del pipeline y la ajusto sólo con entrenamiento.”

12.5 Enlaces internos a los casos

- [Caso I. Diagnóstico oncológico con variables morfométricas](#)
- [Caso II. Clasificación quimiométrica de vinos](#)
- [Caso III. Respuesta semicontinua con masa en cero](#)
- [Caso IV. Éxitos binomiales, proporciones y denominadores variables](#)
- [Caso V. Serie temporal semanal de CO2](#)

Actividades de orientación

Actividad 1: seleccionar el caso análogo

Para un dataset propio, responda cuál de los cinco casos es el más cercano a su situación actual y justifique la analogía. La respuesta debe referirse a: soporte, presencia o ausencia de ceros, tipo de objetivo, relevancia de la escala, dependencia temporal y riesgo de colinealidad.

Actividad 2: hipótesis de decisiones

Antes de leer los casos, escriba para cada uno una hipótesis preliminar sobre qué transformaciones o escaladores esperaría usar. Después de leer el capítulo correspondiente, compare sus hipótesis con las decisiones finalmente justificadas.

Navegación

[Volver al índice general](#)
[Ir al Caso I](#)
[Saltar al Caso V](#)

Caso I. Diagnóstico oncológico con variables morfométricas

Este caso utiliza el dataset *Breast Cancer Wisconsin (Diagnostic)*, una colección clásica de observaciones biomédicas en la que cada fila representa una muestra tumoral y cada columna resume propiedades morfométricas derivadas de imágenes digitalizadas de núcleos celulares. La versión empleada aquí contiene 569 observaciones, 30 predictores numéricos y una respuesta binaria *malignant/benign* [19]. El interés pedagógico del caso no reside sólo en clasificar tumores, sino en mostrar cómo un DEA/EDA serio distingue tres planos distintos: **forma marginal**, **escala** y **geometría multivariada**.

13.1 La pregunta analítica correcta

Una lectura superficial diría: “hay 30 columnas numéricas, hagamos PCA y luego una regresión logística”. Esa decisión es metodológicamente débil. La pregunta correcta es otra:

Pregunta guía

¿La representación cruda de las variables ya preserva la estructura relevante del problema, o está sesgada por colas, escalas heterogéneas y redundancias geométricas que vuelven inestable cualquier método sensible a distancia o penalización?

Este cambio de pregunta es esencial. La persona analista senior no empieza el caso pensando en una receta, sino en qué estructura del fenómeno quiere preservar: tamaño global del tumor, irregularidad de borde, heterogeneidad local y relación entre medidas promedio, error y peor región observada.

13.2 Ficha técnica del dataset

Elemento	Descripción
Observaciones	569
Predictores	30
Tipo de respuesta	Clasificación binaria
Clases	malignant / benign
Valores faltantes	0
Soporte dominante	Variables continuas positivas y semipositivas con escalas muy heterogéneas
Pregunta central	¿Conviene transformar algunas variables o el problema principal es la escala y la redundancia?

Tabla 13.1: Ficha técnica resumida del caso Breast Cancer Wisconsin Diagnostic.

La clase está moderadamente desbalanceada: 212 casos malignos frente a 357 benignos. Ese desbalance no es extremo, pero sí basta para recordar que la exactitud global no debe ser la única métrica de evaluación. Desde EDA esto importa porque la separación visual entre clases puede ser buena en proyecciones bidimensionales y aun así ocultar regiones de solapamiento relevantes para sensibilidad y especificidad.

13.3 Semántica de la matriz de datos

Las 30 variables se organizan en tres familias: *mean*, *error* y *worst*. Esa estructura semántica ya anticipa una geometría multibloque:

1. las variables *mean* resumen la morfología central de la lesión;
2. las variables *error* capturan variabilidad o incertidumbre local;
3. las variables *worst* registran la porción más extrema o agresiva del patrón.

La implicación metodológica es inmediata: si varias columnas miden la misma magnitud física en distintas escalas o resúmenes funcionales, **la colinealidad no es un accidente**. Es consecuencia de la forma en que el fenómeno fue construido.

Lectura profesional

Cuando varias variables son radios, perímetros y áreas derivados de la misma geometría, correlaciones de 0.97 o 0.99 no indican “malos datos”. Indican que el dataset contiene varias proyecciones del mismo eje latente de tamaño tumoral. La decisión no es si eso es un problema en abstracto, sino si el modelo posterior necesita variables desacopladas, interpretación directa o pura capacidad predictiva.

13.4 Auditoría inicial de calidad

El dataset no contiene faltantes y sus variables son positivas o casi positivas. Eso elimina un conjunto de problemas, pero no resuelve otros más sutiles:

- algunas variables tienen magnitudes cercanas a 0.01 mientras otras superan 1000;
- las familias *error* presentan colas largas y alta asimetría;
- las variables geoméricamente ligadas generan bloques de dependencia casi determinista.

Por tanto, la ausencia de faltantes no implica que la matriz sea directamente utilizable para cualquier algoritmo. El principal riesgo aquí no es de limpieza básica, sino de **geometría mal calibrada**.

13.5 Diagnóstico univariado: forma marginal, soporte y colas

La inspección univariada revela que las variables de tamaño y error no comparten la misma forma. Algunas son relativamente simétricas en el rango operativo de la muestra, mientras otras muestran sesgo pronunciado y curtosis extrema.

variable	skew	kurtosis	decisión sugerida
area error	5.447	49.209	evaluar log si se usa modelo lineal sensible a colas
concavity error	5.110	48.861	evaluar log; magnitud y cola dominan
fractal dimension error	3.924	26.281	evaluar log; señal de irregularidad localizada
perimeter error	3.444	21.402	mantener o log suave según algoritmo
radius error	3.089	17.687	mantener; revisar con robust scaling
smoothness error	2.314	10.470	mantener
symmetry error	2.195	7.896	mantener
compactness error	1.902	5.106	mantener

Tabla 13.2: Variables con mayor asimetría absoluta y curtosis en el caso Breast Cancer.

Dos observaciones son críticas:

1. **area error** exhibe una asimetría de 5.447 y curtosis de 49.209;
2. **concavity error** también muestra una cola derecha muy intensa.

Estas cifras no deben leerse como una invitación automática a “normalizar todo”. Deben interpretarse desde el significado de cada variable. Una cola extrema en una medida de error o irregularidad puede representar casos biológicamente plausibles de alta agresividad. El punto no es borrar esa señal, sino decidir si conviene *reexpresarla* para que ciertos modelos lineales o métricos no queden dominados por unos pocos valores.




Figura 13.1: Distribución de una variable de área antes y después de aplicar $\log 1p$. La transformación no cambia el orden, pero comprime la cola derecha y reduce el dominio de los valores extremos.

13.5.1 Qué decide una analista senior ante esta evidencia

La decisión profesional no es binaria entre “transformar todo” y “no transformar nada”. El razonamiento correcto es condicional:

Decisión condicional

Si el modelo posterior será una regresión logística penalizada, una SVM, un kNN o cualquier método cuyo criterio dependa de distancias o penalizaciones por magnitud, entonces conviene evaluar una transformación suave en las variables con colas más largas, seguida de estandarización. Si el modelo posterior será un ensamble de árboles, la transformación marginal es mucho menos urgente; en ese escenario la prioridad puede ser sólo documentar la asimetría y reservar la transformación para fines de visualización o estabilidad interpretativa.

La razón es estadística y algebraica. Sea X la matriz de datos. En métodos basados en distancia, una observación con una o dos coordenadas extremadamente grandes puede alterar $\|x_i - x_j\|$, el gradiente de la función objetivo o la orientación de los vectores propios de $X^\top X$. Un logaritmo suave sobre variables de cola muy pesada reduce esa dominancia sin destruir el orden relativo.

13.5.2 Separación por clase en los márgenes

El diagnóstico no termina con sesgo y curtosis. También importa si la distribución cambia entre clases. En este caso, las mayores diferencias estandarizadas entre benignos y malignos se concentran en variables ligadas a radio, perímetro, área y puntos cóncavos. Eso sugiere un eje biológico consistente: los tumores malignos tienden a presentar mayor tamaño efectivo y mayor irregularidad de borde. Esa regularidad es importante porque justifica que la compresión logarítmica sea *moderada*: no queremos aplastar un eje discriminante real por una obsesión con la simetría.

13.6 Diagnóstico multivariado: redundancia, escala y geometría

La matriz de correlaciones deja claro que la redundancia estructural es una propiedad central del dataset.

var1	var2	corr
mean radius	mean perimeter	0.998
worst radius	worst perimeter	0.994
mean radius	mean area	0.987
mean perimeter	mean area	0.987
worst radius	worst area	0.984
worst perimeter	worst area	0.978
radius error	perimeter error	0.973
mean perimeter	worst perimeter	0.970
mean radius	worst radius	0.970
mean perimeter	worst radius	0.969

Tabla 13.3: Pares de variables con mayor correlación absoluta.




Figura 13.2: Bloque de correlaciones del caso Breast Cancer. Los ejes asociados a tamaño y borde generan subestructuras muy densas.

Las correlaciones de 0.998 entre radio y perímetro medios, o de 0.987 entre radio y área, no son meramente “altas”: son casi relaciones unidimensionales. Desde álgebra lineal, esto significa

que varias columnas viven muy cerca del subespacio generado por una sola dirección latente. Si el objetivo es interpretación causal o explicación parsimoniosa, esta redundancia obliga a elegir entre variables representativas, regularización o construcción de factores latentes. Si el objetivo es sólo predicción con árboles, la redundancia puede tolerarse mucho más.

13.6.1 La pregunta PCA no es “sí o no”, sino “sobre qué geometría”

Uno de los aprendizajes más importantes del caso es que el resultado de PCA cambia de forma radical según se trabaje sobre la matriz de covarianza o sobre la matriz de correlaciones.

Componente	Var. explicada cruda	Var. explicada estandarizada	Acum. cruda	Acum. estandarizada
1	0.982	0.443	0.982	0.443
2	0.016	0.190	0.998	0.632
3	0.002	0.094	1.000	0.726
4	0.000	0.066	1.000	0.792
5	0.000	0.055	1.000	0.847

Tabla 13.4: Varianza explicada por PCA con datos crudos y con variables estandarizadas.




Figura 13.3: Comparación entre PCA cruda y PCA con estandarización. La PCA cruda queda dominada por las variables de mayor magnitud; la PCA sobre variables estandarizadas revela una geometría más informativa para fines exploratorios y clasificatorios.

La primera componente principal sobre datos crudos explica aproximadamente el 98,2 % de la varianza total. Esa cifra, lejos de ser una gran noticia, es una advertencia: no significa que el problema sea realmente unidimensional, sino que la matriz de covarianza está dominada por unas pocas variables de gran escala. Al estandarizar, la primera componente baja a 44,3 % y la segunda aporta alrededor de 19,0 %. Ese cambio prueba que la escala estaba imponiendo una jerarquía geométrica artificial.

Razonamiento senior

Si el objetivo de PCA es descubrir estructura latente comparable entre todas las variables, la estandarización es obligatoria aquí. Si el objetivo fuera cuantificar variabilidad absoluta

en unidades físicas y esas unidades fueran comparables en significado, entonces la covarianza cruda podría ser defendible. Pero en este dataset mezclar área, perímetro, textura y errores locales sin reescalado equivale a confundir magnitud de medida con importancia científica.

13.6.2 Distancia de Mahalanobis y rareza multivariada

La rareza multivariada no puede evaluarse sólo con boxplots marginales. La distancia de Mahalanobis

$$d_M(x_i) = \sqrt{(x_i - \mu)^\top \Sigma^{-1} (x_i - \mu)}$$

considera la covarianza conjunta y detecta observaciones alejadas del elipsoide multivariado central [15]. En este caso, incluso usando covarianza empírica estandarizada, un número no trivial de observaciones supera umbrales χ^2 teóricos.

Umbral	Chi-cuadrado	Observaciones por encima
95 %	43.773	92
97.5 %	46.979	83
99 %	50.892	71

Tabla 13.5: Número de observaciones por encima de distintos umbrales de distancia de Mahalanobis.

La lectura correcta no es “hay que eliminar 92 outliers”. En un dataset oncológico, las observaciones extremas pueden ser precisamente las más informativas. Lo que sí debe concluirse es que los modelos muy sensibles a covarianza empírica y normalidad elíptica merecen precaución; si se persigue un análisis robusto conviene contrastar con estimadores resistentes de dispersión [8, 16].

13.7 Qué transformar, qué escalar y qué no tocar

A partir del diagnóstico anterior, la estrategia no es única. A continuación se explicita un protocolo razonable según objetivo analítico.

13.7.1 Escenario A: regresión logística penalizada, SVM o kNN

1. seleccionar variables con colas muy pesadas susceptibles de compresión suave;
2. aplicar $g(x) = \log(1 + x)$ sólo en variables estrictamente no negativas donde la cola domine la geometría;
3. centrar y escalar todas las variables continuas con z-score;
4. evaluar colinealidad residual y considerar regularización o PCA estandarizada;
5. entrenar y validar usando el pipeline completo ajustado sólo con entrenamiento.

13.7.2 Escenario B: árboles, random forest o boosting

1. documentar sesgo y colas, pero no asumir que deben corregirse;
2. preservar unidades originales si favorecen interpretabilidad clínica;
3. vigilar outliers sólo para descartar errores de medición manifiestos;
4. usar transformación logarítmica únicamente si la métrica, la estabilidad o la visualización lo justifican.

13.7.3 Escenario C: visualización, compresión y análisis exploratorio de estructura

Aquí sí es recomendable trabajar con variables estandarizadas y, si algunas colas son excepcionalmente largas, considerar compresión previa moderada. La PCA estandarizada ofrece una representación mucho más fiel de la estructura relacional que la PCA cruda. En cambio, hacer *min-max scaling* indiscriminado antes de auditar outliers sería un error: ese escalado depende de extremos y puede volver invisibles observaciones atípicas relevantes.

13.8 Errores frecuentes que este caso permite evitar

Errores frecuentes

1. creer que un 98 % de varianza explicada en PCA cruda es evidencia automática de baja dimensionalidad sustantiva;
2. usar kNN o SVM con los datos crudos porque “todas las variables son numéricas”;
3. eliminar observaciones con gran distancia de Mahalanobis sin revisar si representan tumores malignos auténticamente extremos;
4. interpretar cada variable altamente correlacionada como fuente de evidencia independiente;
5. aplicar min-max por costumbre y perder contraste entre región central y cola.

13.9 Protocolo operativo recomendado

Pipeline sugerido

1. Separar entrenamiento y validación.
2. Auditar soporte, colas y valores extremos por bloque de variables.
3. Marcar candidatas a $\log 1p$ entre medidas de error/área muy sesgadas.
4. Ajustar escalador sólo en entrenamiento.

5. Comparar al menos dos representaciones: (i) sólo z-score y (ii) log $1p$ selectivo más z-score.
6. Evaluar un modelo lineal penalizado y un modelo basado en árboles para identificar qué parte del beneficio proviene de la representación y cuál del algoritmo.
7. Documentar si la PCA se usa para visualización, reducción efectiva o sólo diagnóstico.

Actividades aplicadas

Actividad 1: justificar PCA

Repita el análisis del caso y construya dos biplots: uno con PCA cruda y otro con PCA estandarizada. Escriba una nota técnica de dos páginas respondiendo cuál de los dos describe mejor la estructura biomédica y por qué.

Actividad 2: sensibilidad a la representación

Entrene una regresión logística penalizada o una SVM bajo tres representaciones: datos crudos, z-score y log $1p$ selectivo más z-score. Compare desempeño, coeficientes o vectores soporte y discuta qué cambió realmente.

Actividad 3: rareza multivariada

Calcule distancias de Mahalanobis sobre variables estandarizadas y revise las observaciones más extremas. Determine si corresponden mayoritariamente a una clase y explique por qué eliminarlas ciegamente sería metodológicamente pobre.

Navegación

[Volver al índice general](#)
[Volver al índice de casos](#)
[Ir al Caso II](#)

Caso II. Clasificación quimiométrica de vinos

Este caso utiliza el dataset *Wine*, originalmente recopilado para clasificar muestras de vino provenientes de tres cultivares distintos a partir de 13 mediciones fisicoquímicas [1]. La versión usada aquí contiene 178 observaciones y una respuesta multiclase. Es un caso ideal para entender un punto que en la práctica profesional suele ignorarse: **en presencia de unidades heterogéneas, la principal transformación necesaria puede no ser marginal sino geométrica.**

14.1 Pregunta analítica

Un error habitual consiste en tratar este dataset como si el desafío central fuera “corregir la asimetría” de algunas variables. Esa lectura es incompleta. El verdadero problema es más fino:

Pregunta guía

¿La estructura latente del espacio de variables describe diferencias químicas entre cultivares, o está secuestrada por las magnitudes absolutas de unas pocas mediciones que viven en una escala muy superior a las demás?

Aquí el DEA/EDA no busca imponer normalidad por estética. Busca determinar si la matriz de covarianza cruda refleja ciencia del vino o simplemente unidades de medida incomparables.

14.2 Ficha técnica

Elemento	Descripción
Observaciones	178
Predictores	13
Tipo de respuesta	Clasificación multiclase
Clases	class_0 / class_1 / class_2
Valores faltantes	0
Soporte dominante	Variables continuas positivas con magnitudes muy distintas
Pregunta central	¿La estructura multivariada refleja química del vino o sólo diferencias de escala?

Tabla 14.1: Ficha técnica del caso Wine Recognition.

Las tres clases presentan tamaños 59, 71 y 48 observaciones, respectivamente. El desbalance es leve y no domina la exploración. Lo determinante es que las variables tienen soportes positivos, pero escalas muy dispares: magnitudes como *proline* operan en centenares o miles, mientras *hue* y ciertos fenoles viven cerca de la unidad.

14.3 Semántica del problema

En quimiometría, la coexistencia de variables muy distintas en escala no es un error de captura: es parte de la realidad instrumental. Algunas mediciones son concentraciones, otras absorbancias, otras intensidades relativas o descriptores químicos derivados. Precisamente por eso el analista debe decidir qué geometría quiere usar:

- la **covarianza** enfatiza variabilidad absoluta en unidades originales;
- la **correlación** pone todas las variables en pie de igualdad relativa;
- una transformación marginal previa puede corregir asimetría, pero no resuelve por sí sola la desigualdad de escalas.

Idea clave

En datasets instrumentales, que una variable tenga mayor varianza no implica que sea científicamente más importante. A veces sólo significa que fue medida en unidades más grandes.

14.4 Diagnóstico univariado

La exploración univariada muestra sesgo positivo moderado en varias variables, especialmente *magnesium*, *malic acid*, *color intensity* y *proline*.

variable	skew	kurtosis	decisión sugerida
magnesium	1.098	2.105	revisar; posible transformación suave o robust scaling
malic acid	1.040	0.299	revisar; sesgo positivo claro
color intensity	0.869	0.382	revisar; posible log si objetivo es linealizar
proline	0.768	-0.248	revisar; escala domina en PCA cruda
proanthocyanins	0.517	0.555	mantener
nonflavanoid phenols	0.450	-0.637	mantener
OD280/OD315	-0.307	-1.086	mantener
alcalinity of ash	0.213	0.488	mantener

Tabla 14.2: Variables con mayor asimetría absoluta en el caso Wine.

Obsérvese que los niveles de asimetría son bastante menores que en el caso oncológico. Ninguna variable alcanza los valores extremos de curtosis vistos en **area error**. Por tanto, aquí un logaritmo puede ser útil en algunos márgenes, pero no es el núcleo de la decisión. El eje central del análisis está en cómo la escala afecta la estructura conjunta.




Figura 14.1: Distribución de *proline* en escala original y tras transformación logarítmica. La compresión de cola es visible, pero la lección principal del caso sigue siendo la dominancia de escala en el análisis multivariado.

14.4.1 Cuándo sí considerar transformación marginal

Una analista senior podría considerar un logaritmo suave sobre *proline* o *color intensity* si:

1. desea aproximar relaciones multiplicativas o estabilizar varianza para un modelo lineal;
2. necesita disminuir la influencia de la cola alta en distancias euclidianas;
3. busca mejorar la separación visual o la forma condicional dentro de clases.

Pero esa decisión es secundaria frente a otra más importante: incluso sin transformar estas variables, **la estandarización cambia drásticamente la lectura de la matriz de datos**.

14.5 Diagnóstico multivariado: correlación química y dominancia de escala

La estructura de correlaciones ya sugiere ejes químicos coherentes.

var1	var2	corr
total phenols	flavanoids	0.865
flavanoids	OD280/OD315	0.787
total phenols	OD280/OD315	0.700
flavanoids	proanthocyanins	0.653
alcohol	proline	0.644
total phenols	proanthocyanins	0.612
hue	OD280/OD315	0.565
malic acid	hue	-0.561
alcohol	color intensity	0.546
flavanoids	hue	0.543

Tabla 14.3: Pares de variables con mayor correlación absoluta en el caso Wine.




Figura 14.2: Mapa de correlaciones del caso Wine. Se observan bloques fenol-flavanoides y relaciones negativas con variables de color y acidez.

Las correlaciones elevadas entre *total phenols*, *flavanoids* y *OD280/OD315* sugieren un eje latente de composición fenólica. También aparecen tensiones entre acidez y ciertos indicadores

ópticos. Nada de eso es sorprendente químicamente. Lo importante es que esta estructura puede quedar oculta o sobreinterpretada si el análisis conjunto se hace sobre la covarianza cruda sin atender a la escala.

14.5.1 PCA cruda versus PCA estandarizada

Componente	Var. explicada cruda	Var. explicada estandarizada	Acum. cruda	Acum. estandarizada
1	0.998	0.362	0.998	0.362
2	0.002	0.192	1.000	0.554
3	0.000	0.111	1.000	0.665
4	0.000	0.071	1.000	0.736
5	0.000	0.066	1.000	0.802

Tabla 14.4: Varianza explicada por PCA cruda y PCA estandarizada.




Figura 14.3: Comparación entre PCA sobre covarianza cruda y PCA sobre variables estandarizadas. La PCA cruda queda casi completamente dominada por una sola variable de gran magnitud.

La diferencia es contundente: la primera componente principal sobre datos crudos explica aproximadamente el 99,8 % de la varianza total. Esto casi nunca debe celebrarse sin diagnóstico adicional. En este caso significa que la covarianza está esencialmente monopolizada por una combinación de variables de gran escala, con *proline* como protagonista. Después de estandarizar, la primera componente baja a 36,2 % y la segunda aporta 19,2 %, una distribución mucho más compatible con la idea de varios ejes químicos relevantes.

Decisión metodológica

Si el objetivo es explorar estructura latente, visualizar clases, clusterizar o alimentar un algoritmo sensible a distancias, este caso exige estandarización previa. La PCA cruda no es “incorrecta” matemáticamente; simplemente responde otra pregunta: cuál es la dirección de máxima varianza absoluta medida en unidades originales. Esa no es la pregunta más útil cuando las unidades son heterogéneas y no comparables.

14.5.2 Álgebra lineal de la decisión

Sea $X_c = HX$ la matriz centrada y sea D_s la diagonal de desviaciones estándar. Hacer PCA sobre covarianza equivale a diagonalizar

$$S = \frac{1}{n-1} X_c^\top X_c,$$

mientras hacer PCA sobre variables estandarizadas equivale a diagonalizar

$$R = \frac{1}{n-1} (X_c D_s^{-1})^\top (X_c D_s^{-1}).$$

La diferencia entre S y R no es cosmética: en S , columnas con gran varianza reciben mucho más peso. En R , cada variable aporta información relativa, no absoluta. Este caso enseña con nitidez que la *geometría elegida* es parte de la hipótesis exploratoria.

14.6 Qué haría una científica de datos senior

El razonamiento profesional en este caso podría escribirse así:

Razonamiento explícito

“Primero verifico que no se trate de composiciones ni de porcentajes con suma constante; son mediciones químicas independientes y continuas, así que el problema no es simplex sino escala. Veo asimetría moderada pero no extrema. Por ello no transformo por obsesión con la normalidad. Mi decisión principal es estandarizar para que la comparación entre variables sea justa. Después evalúo si un logaritmo suave sobre variables muy sesgadas mejora la linealidad intraclase o la robustez de las distancias. Si reduzco dimensión, lo hago sobre datos estandarizados y documento que la PCA cruda no es interpretable como estructura química general sino como dominancia de unidades grandes.”

14.7 Decisiones dependientes del modelo posterior

14.7.1 kNN, clustering, SVM con kernel RBF

Estos métodos son muy sensibles a distancias o productos internos. En consecuencia:

1. la estandarización es prácticamente obligatoria;
2. una compresión suave de colas puede mejorar estabilidad local;
3. PCA estandarizada es útil si se desea reducir ruido y redundancia antes de clusterizar.

14.7.2 Regresión lineal, logística multinomial o redes con regularización

Aquí también conviene estandarizar, especialmente si se usan penalizaciones L_1 o L_2 . Un predictor medido en magnitud mucho mayor podría dominar la penalización si se trabaja en

bruto.

14.7.3 Árboles y ensamblados

Los árboles son menos sensibles a escala. No obstante, la estandarización puede seguir siendo útil para etapas previas de visualización, detección de redundancia o comparación con métodos lineales. En un flujo serio, esa decisión se documenta como específica del *pipeline* analítico y no como necesidad universal.

14.8 Errores frecuentes

Errores metodológicos

1. interpretar una PCA cruda dominada al 99,8 % como evidencia de que “todo el problema está resuelto por una variable”;
2. aplicar min-max sin revisar qué extremos están fijando la escala;
3. transformar todo con logaritmo sólo porque las variables son positivas;
4. olvidar que una misma estandarización debe ajustarse sólo con entrenamiento y luego aplicarse a validación o test;
5. usar correlaciones y PCA crudas como si describieran relaciones químicas intrínsecas cuando en realidad describen magnitudes absolutas.

14.9 Protocolo operativo

Pipeline sugerido

1. auditar soporte positivo, escalas y sesgo marginal;
2. probar representación base con z-score;
3. comparar opcionalmente con log o log $1p$ selectivos en variables sesgadas;
4. calcular correlaciones y PCA sobre la representación estandarizada;
5. usar la representación final según modelo: PCA para visualización o compresión, variables originales estandarizadas para clasificación supervisada si la interpretabilidad química importa.

Actividades aplicadas

Actividad 1: covarianza vs correlación

Repita la PCA del caso usando covarianza y correlación. Explique, con argumentos de álgebra lineal, por qué los autovalores cambian tanto y cuál de las dos geometrías sería defendible para un artículo científico sobre clasificación de cultivares.

Actividad 2: efecto del logaritmo selectivo

Elija dos variables con sesgo positivo y construya un pipeline que compare: (i) sólo z-score y (ii) logaritmo selectivo más z-score. Analice si cambia la separación entre clases y si esa mejora justifica la pérdida de interpretabilidad en unidades originales.

Actividad 3: redundancia química

A partir de la matriz de correlaciones, proponga grupos de variables casi redundantes. Discuta si preferiría selección de variables, regularización o PCA, y cómo cambiaría su decisión si el objetivo principal fuera explicación química frente a predicción pura.

Navegación

[Volver al índice general](#)

[Volver al índice de casos](#)

[Ir al Caso III](#)

Caso III. Respuesta semicontinua con masa en cero

Este caso se construye a partir del dataset *Affairs*, usado por Ray Fair para estudiar la asignación del tiempo entre trabajo, tiempo con la pareja y tiempo invertido en relaciones extramatrimoniales [5]. La versión aquí utilizada, distribuida por `statsmodels`, contiene 6366 observaciones y ocho covariables socio-demográficas más una variable de interés llamada `affairs`, descrita como una *medida del tiempo dedicado a aventuras extramatrimoniales*. Esta descripción basta para encender una alarma metodológica: **la variable no es un conteo puro, aunque tenga cero y cola derecha**.

15.1 Por qué este caso es crucial

En la práctica aplicada es frecuente encontrar variables con muchísimos ceros y una cola positiva muy alargada. El error automático consiste en elegir entre dos opciones caricaturescas:

1. tratar la variable como un continuo y hacer una regresión lineal sobre el valor crudo;
2. tratarla como un conteo y usar Poisson o binomial negativa sin revisar la semántica.

Este caso enseña por qué ambas respuestas pueden ser insuficientes. La pregunta correcta es otra.

Pregunta guía

¿Qué estructura genera la masa en cero y qué estructura genera la intensidad positiva?
¿Ambas pertenecen al mismo mecanismo, o conviene separar la *incidencia* del evento de su *intensidad* condicional?

15.2 Ficha técnica

Elemento	Descripción
Observaciones	6366
Predictores	8
Variable de interés	affairs (masa en cero + cola derecha en positivos)
Valores faltantes	0
Soporte dominante	Mixto: ordinal, continuo, conteo simple y códigos ocupacionales
Pregunta central	¿Conviene tratar affairs como continuo, binario, o proceso de dos partes?

Tabla 15.1: Ficha técnica del caso Fair Affairs.

15.3 Auditoría semántica antes de cualquier transformación

Este caso es un excelente recordatorio de que los nombres de las columnas pueden inducir errores.

- `rate_marriage` es una variable ordinal de 1 a 5; no es continua euclidiana por defecto.
- `religious` también es ordinal.
- `occupation` y `occupation_husb` son códigos ocupacionales ordenados por nivel, pero la distancia entre categorías no tiene por qué ser lineal.
- `yrs_married` usa aproximaciones por intervalos; no representa un reloj continuo exacto.
- `children` presenta valores como 5.5, lo que indica agrupación o codificación coarsened; por tanto, tampoco debe tratarse ingenuamente como conteo exacto.

Esta auditoría cambia por completo el análisis. No estamos ante una matriz perfectamente continua. Estamos ante un **dataset mixto** en el que la semántica restringe las transformaciones admisibles.

Advertencia conceptual

Cuando una variable parece numérica pero en realidad es ordinal, agrupada o codificada, escalarla y centrarla como si fuera continua puede introducir una falsa geometría.

15.4 Diagnóstico univariado de la variable de interés

La respuesta `affairs` combina una gran masa exacta en cero con una cola derecha extremadamente pesada en el subconjunto positivo.

Métrica	Valor
Proporción exacta de ceros	0.678
Media global	0.705
Mediana global	0.000
Media en positivos	2.187
Skew positivos	5.808
Curtosis positivos	56.664
Máximo observado	57.600

Tabla 15.2: Resumen univariado de la variable **affairs**.

El 67,8 % de las observaciones toma exactamente el valor 0. Entre quienes tienen valor positivo, la media supera 2, la asimetría es de aproximadamente 5.81 y la curtosis rebasa 56.6. Estas cifras contienen un mensaje claro: **una sola transformación global no describe bien todo el soporte**. El cero y la cola positiva no cumplen el mismo papel.




Figura 15.1: Distribución de **affairs** en escala original y tras $\log(1+x)$. La transformación comprime la cola positiva, pero no resuelve el hecho de que casi dos tercios de la masa estén exactamente en cero.

15.4.1 Por qué $\log 1p$ no resuelve el problema por sí sola

La transformación $g(x) = \log(1+x)$ es útil para comprimir la cola y reducir la dominancia de valores muy grandes. Pero deja intacta la discontinuidad conceptual entre $x = 0$ y $x > 0$. Después de transformar, todos los ceros siguen en un único punto y la parte positiva continúa describiendo una intensidad condicional. Por ello, si el objetivo analítico distingue *tener o no tener aventura* de *cuánta intensidad hay una vez que existe*, conviene modelar ambas capas por separado.

15.5 Estructura de predictores y relaciones sustantivas

La relación entre satisfacción matrimonial y variable de respuesta ilustra bien la utilidad del EDA estratificado.

rating_matrimonio	n	tasa_con_alguna_aventura	media_affairs	mediana_affairs
1.000	99	0.747	1.202	0.727
2.000	348	0.635	1.616	0.522
3.000	993	0.551	1.371	0.212
4.000	2242	0.323	0.675	0.000
5.000	2684	0.181	0.348	0.000

Tabla 15.3: Frecuencia de **affairs** positiva según la calificación del matrimonio.




Figura 15.2: La probabilidad de presentar **affairs**>0 cae fuertemente al aumentar la calificación matrimonial.

La tasa de observaciones con aventura positiva cae de aproximadamente 74,7% cuando la calificación del matrimonio es 1 a sólo 18,1% cuando la calificación es 5. El mensaje metodológico es doble:

1. la parte en cero no es mero ruido; está estructurada por covariables sustantivas;
2. el soporte mixto sugiere dos mecanismos: uno de incidencia y otro de intensidad.

También se observan gradientes con religiosidad: a mayor nivel de religiosidad, menor frecuencia de valores positivos. Esto refuerza la idea de que un modelo de dos partes puede ser más interpretable que una única regresión sobre la escala cruda.

15.6 Diagnóstico multivariado

Las covariables numéricas y ordinales muestran dependencia considerable.

var1	var2	corr
age	yrs_married	0.894
yrs_married	children	0.773
age	children	0.674
educ	occupation	0.382
occupation	occupation_husb	0.201
educ	occupation_husb	0.184
rate_marriage	affairs	-0.178
age	occupation_husb	0.163

Tabla 15.4: Correlaciones más altas entre predictores y respuesta en el caso Fair.




Figura 15.3: Mapa de correlaciones del caso Fair. Destacan las dependencias entre edad, años de matrimonio y presencia de hijos, así como la asociación negativa entre evaluación del matrimonio y *affairs*.

Las correlaciones entre *age* y *yrs_married* ($\approx 0,894$), entre *yrs_married* y *children* ($\approx 0,773$) y entre *age* y *children* ($\approx 0,674$) son suficientemente altas para anticipar problemas de interpretabilidad en modelos lineales con todos los términos incluidos sin regularización ni centramiento. En otras palabras, **la incidencia de la variable respuesta no sólo depende de un predictor, sino de una constelación de predictores correlacionados entre sí.**

15.6.1 No toda rareza es outlier

Los valores grandes de *affairs* pueden parecer atípicos en histograma, pero no son necesariamente errores. Forman parte de la cola positiva del fenómeno. El trabajo del DEA/EDA no es

truncarlos mecánicamente, sino decidir si:

1. pertenecen a la intensidad sustantiva que el modelo debe explicar;
2. exigen una familia de pérdida robusta;
3. deben separarse en una etapa de modelado condicional sobre positivos.

15.7 El razonamiento mental de una analista senior

Este caso permite hacer explícita una secuencia profesional de decisión.

Razonamiento explícito

“Primero verifico la semántica: **affairs** es una medida de tiempo, no un conteo exacto. Luego observo una masa muy grande en cero y una cola intensa en positivos. Concluyo que una sola escala continua no resume bien el fenómeno. Construyo entonces dos problemas: incidencia ($Y > 0$) e intensidad ($Y \mid Y > 0$). Después reviso que varios predictores son ordinales o códigos agrupados; por tanto no los fuerzo a una geometría lineal sin justificarla. Si voy a usar un modelo lineal, centro y escalo sólo las variables verdaderamente continuas y trato las ordinales con prudencia. Si necesito una transformación de la respuesta para el modelo de intensidad, considero $\log 1p$ o una familia log-normal/Gamma sobre el subconjunto positivo. No uso Poisson por reflejo porque el soporte observado no corresponde a un conteo puro.”

15.8 Decisiones de transformación y representación

15.8.1 Representación de la respuesta

Existen al menos cuatro opciones razonables, cada una respondiendo a una pregunta distinta:

1. **Binarización** $Y^* = \mathbf{1}\{Y > 0\}$: pregunta por incidencia.
2. **Modelo de intensidad positiva** sobre $Y \mid Y > 0$: pregunta por severidad condicional.
3. **Modelo de dos partes** (hurdle o two-part): separa incidencia e intensidad.
4. **Modelo continuo único sobre** $\log 1p(Y)$: útil para una síntesis exploratoria, pero conceptualmente menos fiel al soporte mixto.

15.8.2 Tratamiento de predictores

- **age** puede mantenerse continua, quizá centrada.
- **yrs_married** conviene tratarla como duración agrupada; centrar ayuda si se usarán interacciones.

- `rate_marriage` y `religious` deben considerarse ordinales; codificarlas como métricas lineales es una aproximación útil pero no neutra.
- `occupation` y `occupation_husb` requieren más cuidado; si se persigue interpretación robusta, puede ser preferible tratarlas como categorías ordinales o incluso nominales según el objetivo.

15.8.3 ¿Escalar o no escalar?

Escalar todas las columnas ciegamente sería un error porque varias son ordinales o códigos. En cambio, si se usa un método sensible a magnitud y se decide conservar una representación casi lineal, puede ser razonable centrar y escalar sólo variables verdaderamente continuas. El principio es simple: **la estandarización no debe inventar una métrica donde la semántica no la garantiza.**

15.9 Qué familias de modelo se vuelven plausibles

1. **Logística binaria** para $Y^* = 1\{Y > 0\}$, si interesa la probabilidad de ocurrencia.
2. **Regresión log-normal, Gamma o Gaussian sobre $\log 1p(Y)$** para la intensidad positiva.
3. **Modelos de dos partes** cuando se desea separar explícitamente la generación del cero y la magnitud positiva.
4. **Modelos robustos** si la cola positiva sigue dominando incluso tras la transformación.

El punto pedagógico es que la transformación correcta de la respuesta depende de la pregunta científica. Si el foco es política pública o sociología de la conducta, tal vez interese más explicar la *probabilidad* de algún affair que la intensidad exacta. Si el foco es cuantificar severidad condicional, el modelo debe privilegiar la cola positiva.

15.10 Errores frecuentes

Errores frecuentes

1. usar Poisson o binomial negativa sólo porque hay muchos ceros y una cola derecha, sin revisar que la variable no es un conteo puro;
2. transformar con $\log 1p$ y concluir que el problema quedó resuelto, ignorando la discontinuidad entre cero y positivo;
3. estandarizar códigos ordinales y ocupacionales como si fueran medidas continuas homogéneas;
4. interpretar coeficientes de variables muy correlacionadas sin revisar colinealidad;
5. tratar valores positivos grandes como errores sin evidencia adicional.

15.11 Protocolo operativo recomendado

Pipeline sugerido

1. auditar soporte y semántica de cada predictor;
2. construir una variable binaria $Y^* = \mathbf{1}\{Y > 0\}$;
3. analizar por separado la distribución de $Y \mid Y > 0$;
4. decidir si la pregunta exige incidencia, intensidad o ambas;
5. centrar/escalar sólo predictores con métrica continua defendible;
6. documentar el tratamiento de variables ordinales y agrupadas;
7. comparar un modelo de una parte sobre $\log 1p(Y)$ con un modelo de dos partes.

Actividades aplicadas

Actividad 1: incidencia vs intensidad

Construya dos modelos separados: uno para $Y^* = \mathbf{1}\{Y > 0\}$ y otro para $\log(1 + Y)$ en el subconjunto positivo. Compare qué predictores parecen relevantes en cada problema y explique por qué no tienen por qué coincidir.

Actividad 2: semántica y soporte

Escriba un informe corto argumentando por qué **affairs** no debe tratarse automáticamente como conteo. La argumentación debe usar soporte observado, documentación del dataset y consecuencias sobre la elección del modelo.

Actividad 3: ordinalidad

Repita un modelo de incidencia bajo dos codificaciones de **rate_marriage**: (i) como entero lineal y (ii) como conjunto de dummies ordenadas. Compare el efecto sobre ajuste e interpretación.

Navegación

[Volver al índice general](#)
[Volver al índice de casos](#)
[Ir al Caso IV](#)

Caso IV. Éxitos binomiales, proporciones y denominadores variables

El cuarto caso utiliza el dataset *STAR98* distribuido por `statsmodels` a partir del ejemplo de Jeff Gill sobre modelos lineales generalizados [6]. Cada fila representa un distrito escolar unificado en California y la respuesta observada se expresa mediante dos conteos: `NABOVE` y `NBELOW`, que corresponden al número de estudiantes por encima y por debajo de la mediana nacional en la prueba de matemáticas. La lección central del caso es decisiva para cualquier científica o científico de datos: **una proporción no debe analizarse como si fuera un continuo ordinario cuando el denominador cambia de forma sustancial entre observaciones.**

16.1 La pregunta correcta

Una persona analista poco cuidadosa podría construir la proporción

$$\hat{p}_i = \frac{\text{NABOVE}_i}{\text{NABOVE}_i + \text{NBELOW}_i}$$

y seguir con una regresión lineal sobre $\hat{p}_i$. El problema es que dos distritos con $\hat{p} = 0,60$ no tienen la misma precisión si uno se estima con 50 estudiantes y otro con 5000. La varianza binomial de la proporción depende de n_i :

$$\text{Var}(\hat{p}_i | p_i) = \frac{p_i(1 - p_i)}{n_i}.$$

Por tanto, **ignorar n_i es ignorar una fuente estructural de heteroscedasticidad.**

Pregunta guía

¿La representación adecuada del objetivo es la proporción cruda, un logit empírico o directamente el par éxito-fracaso que respeta la naturaleza binomial del dato?

16.2 Ficha técnica

Elemento	Descripción
Observaciones	303
Predictores	20
Respuesta original	NABOVE éxitos y NBELOW fracasos; proporción derivada SUCCESS_RATE
Valores faltantes	0
Soporte dominante	Conteos binomiales, proporciones 0-100 e interacciones derivadas
Pregunta central	¿Se debe modelar la proporción como continuo simple o respetar el denominador binomial?

Tabla 16.1: Ficha técnica del caso STAR98.

16.3 Semántica del dataset

La unidad observacional es el distrito escolar. El objetivo no es una medida individual, sino un resumen agregado sobre un conjunto de estudiantes. Esta sola frase ya impone varias obligaciones metodológicas:

- el resultado es una realización de un proceso binomial agregado, no un continuo libre;
- la heteroscedasticidad no es un accidente residual, sino una propiedad matemática del objetivo;
- algunas covariables son porcentajes, otras promedios, otras interacciones construidas artificialmente a partir de las primeras.

Adicionalmente, el dataset incluye términos de interacción ya fabricados, como PERMINTE_AVYRSEXP o AVYRSEXP_AVSALE. Este diseño es útil pedagógicamente porque muestra el costo de introducir productos sin centrar ni reparametrizar: la colinealidad se dispara.

16.4 Diagnóstico univariado del objetivo

Métrica	Valor
Media de éxito	0.437
Desv. éxito	0.184
Mínimo éxito	0.076
Máximo éxito	0.928
Media del total examinado	883.205
Mediana del total examinado	445.000
Máximo del total examinado	38852.000

Tabla 16.2: Resumen de la respuesta derivada SUCCESS_RATE y del tamaño muestral total por distrito.

La tasa media de éxito es cercana a 0,437, con valores entre 0,076 y 0,928. Pero el elemento decisivo del resumen es el denominador total: la media del número de estudiantes evaluados

supera 883, la mediana es 445 y el máximo rebasa 38 000. La amplitud de esta variación hace inviable interpretar todas las proporciones con la misma precisión.




Figura 16.1: Proporción de éxito en escala original y tras logit empírico. La transformación despega los valores de los bordes, pero no elimina la necesidad de respetar el denominador binomial.

16.4.1 Logit empírico como herramienta exploratoria

Cuando se trabaja con proporciones acotadas en $(0, 1)$, una herramienta exploratoria útil es el logit empírico

$$\text{elogit}(y, n) = \log \left(\frac{y + \frac{1}{2}}{n - y + \frac{1}{2}} \right),$$

que evita problemas en los bordes y puede linealizar relaciones. Sin embargo, incluso esta transformación **no reemplaza** un modelo que incorpore el denominador si la inferencia o la predicción deben respetar la precisión diferencial entre distritos.

16.5 Diagnóstico univariado de covariables

El conjunto de predictores incluye porcentajes demográficos, proporciones institucionales y términos de interacción. Varias covariables muestran asimetría y curtosis muy altas.

variable	skew	kurtosis	decisión sugerida
PCTCHRT	9.247	97.804	tratar como porcentaje acotado; revisar cero estructural
PERBLACK	3.581	18.566	revisar concentración y colas por composición demográfica
PERASIAN	2.932	10.767	revisar composición demográfica
PERMINTE AVYRSEXP AVSAL	2.490	7.773	no interpretar sin centrar; es interacción derivada
PERMINTE AVYRSEXP	2.318	6.843	no interpretar sin centrar; es interacción derivada
PCTYRRND	2.295	4.658	mantener
PERMINTE AVSAL	2.143	5.919	mantener
PERMINTE	2.028	5.480	mantener

Tabla 16.3: Variables con mayor asimetría absoluta en el caso STAR98.

Dos patrones destacan:

1. PCTCHRT presenta un sesgo muy alto, coherente con muchos distritos con proporción nula

o muy baja de escuelas charter;

2. varias interacciones muestran colas pronunciadas porque heredan y amplifican la escala de sus factores componentes.

Esto obliga a una lectura semántica. No tiene sentido transformar a ciegas todas las interacciones; primero hay que preguntarse si esas interacciones deberían existir en esa forma o si conviene re-crear el diseño con variables centradas.

16.6 Relaciones bivariadas instructivas

Una de las relaciones más potentes del caso aparece entre porcentaje de estudiantes de bajos ingresos (LOWINC) y tasa de éxito. La correlación lineal ronda $-0,83$, una asociación fuerte y sustantivamente comprensible. En cambio, la proporción de escuelas charter (PCTCHRT) tiene correlación simple cercana a cero con la tasa de éxito, lo que enseña otra lección importante: **no todo predictor políticamente llamativo muestra señal marginal directa.**




Figura 16.2: Relación entre LOWINC y la proporción de éxito. La pendiente negativa es marcada, pero la dispersión vertical también sugiere heteroscedasticidad dependiente del tamaño muestral.

16.7 Diagnóstico multivariado: colinealidad e interacciones

El aspecto más pedagógico del caso es la colinealidad extrema que introducen las interacciones preconstruidas.

var1	var2	corr
PERMINTE AVYRSEXP	PERMINTE AVYRSEXP AVSAL	0.993
PERMINTE	PERMINTE AVSAL	0.992
PERMINTE AVYRSEXP	PERMINTE AVSAL	0.985
PERMINTE AVSAL	PERMINTE AVYRSEXP AVSAL	0.981
PERMINTE	PERMINTE AVYRSEXP	0.979
PCTAF	PERSPEN PTRATIO PCTAF	0.972
PCTAF	PTRATIO PCTAF	0.970
PERSPEN PCTAF	PERSPEN PTRATIO PCTAF	0.969
PERMINTE	PERMINTE AVYRSEXP AVSAL	0.961
PTRATIO PCTAF	PERSPEN PTRATIO PCTAF	0.957

Tabla 16.4: Pares de variables con mayor correlación absoluta en STAR98.

variable	VIF
AVYRSEXP AVSAL	12563.676
AVSALK	12349.364
PTRATIO	12268.245
PERSPEN PTRATIO	11790.070
AVYRSEXP	11572.195
PTRATIO PCTAF	11040.920
PCTAF	10500.722
PERSPEN PTRATIO PCTAF	9977.117
PERMINTE AVSAL	9827.124
PERSPENK	9674.122

Tabla 16.5: Variables con mayor factor de inflación de la varianza (VIF).




Figura 16.3: Mapa de correlaciones en STAR98. Los bloques de interacción muestran dependencia casi determinista con sus factores base.

Varios VIF superan con holgura 9000 e incluso 12000. Estos valores no son un detalle técnico menor; implican que un modelo lineal con todos esos términos en bruto tendrá coeficientes extremadamente inestables y muy sensibles a pequeñas perturbaciones. Desde el punto de vista algebraico, la matriz de diseño está mal condicionada: algunas columnas se acercan demasiado a combinaciones lineales de otras.

16.7.1 Lo que una analista senior ve en estos VIF

El mensaje no es “hay que eliminar variables hasta que el VIF baje”. La lectura profesional es más rica:

Lectura profesional

Si las interacciones fueron construidas sin centrar las variables base, la colinealidad es esperable. Por tanto, antes de descartar términos debo preguntar si la especificación se puede reparametrizar. Muchas veces centrar las variables continuas o porcentuales antes de formar productos disminuye drásticamente la dependencia lineal y hace más interpretable el intercepto y los efectos principales.

16.8 Qué hacer con la respuesta: tres niveles de decisión

16.8.1 Nivel 1: exploración rápida

Para gráficos y correlaciones preliminares puede usarse $\hat{p}$ o logit empírico. Esto permite visualizar relaciones y detectar asimetrías cerca de los bordes.

16.8.2 Nivel 2: modelado respetando el denominador

Si la meta es inferencia o predicción seria, la forma más natural es modelar directamente el vector $(y_i, n_i - y_i)$ o usar pesos n_i en un modelo adecuado. Esto respeta la varianza binomial y la distinta precisión de cada distrito [6].

16.8.3 Nivel 3: ingeniería de predictores

Antes de ajustar cualquier GLM conviene revisar si las interacciones deben mantenerse, re-crearse tras centrar o sustituirse por una estructura más parsimoniosa. De lo contrario, la multicolinealidad puede dominar la varianza de los estimadores.

16.9 Transformaciones y escalamiento de predictores

No todas las covariables requieren el mismo tratamiento.

1. **Porcentajes acotados entre 0 y 100.** Conviene reexpresarlos en escala 0-1 y decidir después si se justifica logit u otra transformación. Si contienen muchos ceros estructurales, la corrección debe ser cuidadosa.
2. **Promedios y montos.** Pueden centrarse y escalarse si se usarán regularización o interacciones nuevas.
3. **Interacciones preconstruidas.** Lo preferible es rehacerlas a partir de variables centradas para reducir colinealidad.

Decisión principal

En este caso la transformación más importante no es de las covariables, sino de la *representación del objetivo*. El cambio de escala adecuado para la respuesta es el que respeta el denominador binomial. Una vez resuelto eso, el segundo problema central es reparametrizar o regularizar la matriz de diseño.

16.10 Heteroscedasticidad: por qué aparece incluso con buenos datos

Supongamos dos distritos con la misma probabilidad verdadera $p = 0,45$. Si uno tiene $n = 100$ y otro $n = 10\,000$, la desviación estándar de la proporción estimada difiere por un factor

de diez. Esto significa que la nube de puntos $(x_i, \hat{p}_i)$ mostrará inevitablemente abanicos de dispersión distintos según el tamaño del distrito. Ese patrón no desaparece porque “el dato esté sucio”; es inherente a la generación binomial. Por eso el DEA/EDA debe identificarlo antes de que se confunda con una heteroscedasticidad residual genérica.

16.11 Errores frecuentes

Errores frecuentes

1. tratar la proporción de éxito como continuo ordinario sin usar el denominador;
2. reportar sólo una regresión lineal sobre $\hat{p}$ y llamar a eso “análisis suficiente”;
3. construir o usar interacciones sin centrar las variables base;
4. min-max escalar todas las columnas y perder de vista qué variables son proporciones, montos o productos;
5. interpretar VIF extremos como mera curiosidad sin reconocer el problema de condicionamiento de la matriz de diseño.

16.12 Protocolo operativo

Pipeline sugerido

1. crear $n_i = \text{NABOVE}_i + \text{NBELOW}_i$ y $\hat{p}_i = \text{NABOVE}_i/n_i$;
2. explorar $\hat{p}_i$ y logit empírico para visualización, no como única representación;
3. auditar asimetría de covariables y bloques de interacción;
4. re-crear interacciones a partir de variables centradas si el modelo las necesita;
5. ajustar modelo binomial o estrategia ponderada que respete n_i ;
6. comparar estabilidad de coeficientes con y sin reparametrización o regularización.

Actividades aplicadas

Actividad 1: por qué el denominador importa

Tome dos subconjuntos de distritos con tamaños muy distintos y simule el efecto de ignorar n_i . Muestre numéricamente cómo cambia la varianza de la proporción y explique por qué eso invalida una lectura homogénea del error.

Actividad 2: rehacer interacciones

Recree las interacciones del dataset a partir de variables centradas. Compare VIF y estabilidad de coeficientes entre la matriz original y la reparametrizada.

Actividad 3: modelo continuo vs binomial

Ajuste un modelo lineal sobre la proporción y compárelo con un modelo binomial que respete el denominador. Analice residuos, inferencia y estabilidad. Escriba una nota de decisión donde justifique cuál de los dos es conceptualmente más adecuado.

Navegación[Volver al índice general](#)[Volver al índice de casos](#)[Ir al Caso V](#)

Caso V. Serie temporal semanal de CO₂

El último caso utiliza la serie semanal de concentraciones atmosféricas de CO₂ en Mauna Loa, Hawái, un registro clásico de la ciencia del clima difundido por Keeling y Whorf [12]. En la versión usada aquí se dispone de 2284 observaciones semanales entre 1958 y 2001, con 59 valores faltantes. La importancia de este caso para el DEA/EDA es profunda: obliga a distinguir entre **transformar la escala de la variable** y **transformar la dependencia temporal**. En series temporales, esa diferencia metodológica es decisiva.

17.1 La pregunta correcta

La variable `co2` es positiva y relativamente suave. A primera vista podría parecer otro candidato para logaritmo o estandarización. Pero esa intuición falla si ignora la estructura temporal. Aquí la pregunta adecuada es:

Pregunta guía

¿El principal obstáculo analítico es la distribución marginal de `co2`, o la combinación de tendencia, estacionalidad, dependencia serial y faltantes que hace que observaciones vecinas no sean intercambiables?

En este caso, la respuesta es clara: la dificultad dominante está en la estructura temporal. La distribución marginal importa, pero está subordinada a la dependencia.

17.2 Ficha técnica

Elemento	Descripción
Observaciones	2284
Variable principal	co2 (ppm)
Valores faltantes	59
Horizonte temporal	1958-03-29 a 2001-12-29
Soporte dominante	Serie temporal positiva con tendencia y estacionalidad
Pregunta central	¿Transformar la escala o transformar la dependencia temporal?

Tabla 17.1: Ficha técnica del caso CO₂ de Mauna Loa.

17.3 Auditoría inicial: el tiempo como parte de la semántica

Cada fila representa una semana. Eso significa que el orden es sustantivo, no accidental. Si permutáramos las filas, destruiríamos el fenómeno. Esta observación aparentemente obvia tiene varias consecuencias:

- no pueden mezclarse libremente entrenamiento y validación como si las observaciones fueran i.i.d.;
- los faltantes no son simples celdas vacías, sino *huecos en una trayectoria*;
- tendencia y estacionalidad pueden hacer no estacionaria la serie, incluso si la distribución marginal parece estable.

17.4 Valores faltantes y régimen de observación

El primer paso serio no consiste en imputar automáticamente. Consiste en entender la estructura del faltante.

start	end	length
1964-01-25 00:00:00	1964-05-23 00:00:00	18
1958-09-13 00:00:00	1958-11-01 00:00:00	8
1958-05-31 00:00:00	1958-06-28 00:00:00	5
1984-03-31 00:00:00	1984-04-21 00:00:00	4
1962-08-25 00:00:00	1962-09-08 00:00:00	3
1966-07-16 00:00:00	1966-07-30 00:00:00	3
1964-06-13 00:00:00	1964-06-20 00:00:00	2
1967-01-21 00:00:00	1967-01-28 00:00:00	2

Tabla 17.2: Rachas más largas de valores faltantes en la serie semanal.




Figura 17.1: Serie temporal de CO₂ con marcado de faltantes. El problema no es la cantidad aislada de vacíos, sino la existencia de rachas consecutivas.

La racha faltante más larga cubre 18 semanas consecutivas en 1964. Esto cambia la decisión de imputación. Cuando los faltantes son aislados, la interpolación temporal suele ser defensible como operación exploratoria. Cuando aparecen rachas largas, la incertidumbre crece y conviene distinguir entre imputación para visualización, imputación para modelado y análisis restringido a segmentos observados.

Razonamiento senior

La primera pregunta no es “¿con qué método relleno los faltantes?”, sino “¿qué inferencia quedaría sesgada si reemplazo un hueco temporal por una trayectoria suavizada?”. En un gráfico exploratorio, interpolar puede ser razonable. En una estimación de dinámica fina, podría ser inaceptable.

17.5 Diagnóstico univariado: la escala no es el problema dominante

Una vez interpolados temporalmente los faltantes con fines descriptivos, la distribución marginal del nivel de CO₂ resulta relativamente moderada.

Serie	Media	Desv.	Skew	Curtosis
Nivel interpolado	339.652	17.104	0.248	-1.201
Primera diferencia	0.024	0.488	-0.369	0.625
Diferencia estacional (52)	1.292	0.778	0.307	0.340

Tabla 17.3: Resumen comparativo entre la serie en nivel interpolado y dos transformaciones temporales simples.

La serie en nivel presenta asimetría baja y curtosis negativa moderada. Esto ya desactiva una tentación frecuente: aplicar logaritmo por costumbre. A diferencia de variables económicas muy sesgadas, aquí la distribución marginal no exige una compresión drástica. El verdadero

problema es que la media cambia en el tiempo y existe una oscilación estacional clara.




Figura 17.2: Comparación visual entre la serie en nivel, la primera diferencia y la diferencia estacional. Las transformaciones temporales alteran la dependencia mucho más que la escala marginal.

17.5.1 Transformar la dependencia no es lo mismo que transformar la escala

Cuando se toma una primera diferencia,

$$\nabla X_t = X_t - X_{t-1},$$

o una diferencia estacional,

$$\nabla_{52} X_t = X_t - X_{t-52},$$

no se está buscando normalizar márgenes en el sentido clásico. Se está intentando remover tendencia o estacionalidad para acercar la serie a una dinámica más estable alrededor de una media aproximadamente constante. Estas operaciones son transformaciones del *proceso*, no meramente de la escala.

17.6 Estacionalidad y codificación cíclica

La serie semanal exhibe una oscilación anual clara. Un resumen por calendario semanal o mensual hace visible esa periodicidad.




Figura 17.3: Perfil estacional medio por semana del año. La periodicidad anual es una propiedad estructural de la serie.

La existencia de periodicidad implica que, si el objetivo posterior es modelado supervisado con covariables temporales, conviene codificar el tiempo con componentes cíclicas:

$$x_{\sin,t} = \sin\left(2\pi \frac{t}{52}\right), \quad x_{\cos,t} = \cos\left(2\pi \frac{t}{52}\right).$$

Esta representación respeta la cercanía entre semanas vecinas al cierre del ciclo anual y es mucho más adecuada que usar el número de semana como entero lineal.

17.7 Qué ve una analista senior en este caso

Una lectura profesional de la serie podría escribirse así:

Razonamiento explícito

“La variable es positiva, pero su asimetría marginal es baja. Por tanto, el logaritmo no es la prioridad. El diagnóstico principal es temporal: tendencia creciente de largo plazo, estacionalidad anual y huecos de observación. Antes de cualquier modelo debo decidir cómo tratar faltantes, qué partición temporal usar y si mi representación debe ser en niveles, diferencias o diferencias estacionales. Si el objetivo es predicción a corto plazo, necesito lags y estacionalidad explícita. Si el objetivo es visualizar la tendencia climática, quizá preserve el nivel original e interpole sólo para continuidad gráfica, documentando claramente esa decisión.”

17.8 Decisiones de representación según la tarea

17.8.1 Tarea A: visualización histórica

- preservar la serie en niveles;
- interpolar faltantes de forma transparente sólo para continuidad del gráfico;

- no aplicar logaritmo si no aporta lectura sustantiva;
- resaltar tendencia y estacionalidad como propiedades del fenómeno.

17.8.2 Tarea B: modelado de dinámica de corto plazo

- trabajar con lags;
- evaluar primeras diferencias o diferencias estacionales;
- incorporar codificación cíclica o índices de calendario;
- separar entrenamiento, validación y prueba respetando el orden temporal.

17.8.3 Tarea C: aprendizaje supervisado con variables temporales

Si la serie se usa como parte de un problema más amplio, es esencial diferenciar:

1. fecha absoluta;
2. edad desde un evento;
3. componente cíclica;
4. tendencia secular;
5. rezagos observados.

Una sola columna `date` no contiene directamente todas esas estructuras; deben construirse de manera consciente.

17.9 Univariado y multivariado en series temporales

En series temporales, el análisis multivariado puede aparecer incluso con una sola variable original, porque al construir lags ($X_{t-1}, X_{t-2}, \dots$), dummies estacionales o transformaciones cíclicas, la matriz de diseño se vuelve multivariada. La dependencia serial crea correlación fuerte entre columnas lagged, y por tanto reaparecen problemas de colinealidad, regularización y selección de dimensión. Este es un excelente recordatorio de que el DEA/EDA temporal no es un mundo separado del álgebra lineal; simplemente aplica esa álgebra a una matriz construida desde la dependencia del tiempo.

17.10 Por qué la normalización estándar puede ser insuficiente

Aplicar un z-score a la serie en nivel puede ser útil para que un algoritmo compare magnitudes. Pero esa operación no resuelve:

- tendencia no estacionaria;

- estacionalidad anual;
- fuga temporal si el escalador se ajusta con toda la muestra;
- pérdida de interpretación física si se destruye la escala en ppm sin necesidad.

Esto ilustra una lección general: **estandarizar no sustituye al modelado de dependencia**. En problemas temporales, la transformación esencial suele ser la que actúa sobre el índice temporal, no sobre el histograma marginal.

17.11 Errores frecuentes

Errores frecuentes

1. mezclar observaciones futuras en el ajuste del escalador o del imputador;
2. imputar rachas largas de faltantes sin distinguir entre uso exploratorio y uso inferencial;
3. aplicar logaritmo por rutina, aun cuando el problema principal sea tendencia y estacionalidad;
4. usar el número de semana como entero lineal y olvidar la circularidad;
5. evaluar el modelo con validación aleatoria en vez de partición temporal.

17.12 Protocolo operativo

Pipeline sugerido

1. convertir la fecha a índice temporal verificando frecuencia semanal;
2. mapear faltantes y documentar rachas;
3. decidir si la imputación será sólo para visualización o también para modelado;
4. explorar la serie en nivel, primera diferencia y diferencia estacional;
5. construir variables temporales cíclicas y rezagos según la tarea;
6. separar entrenamiento y validación por bloques temporales;
7. ajustar cualquier transformación usando sólo el segmento histórico disponible en entrenamiento.

Actividades aplicadas

Actividad 1: escala vs dependencia

Construya dos pipelines distintos: uno que sólo aplique z-score a la serie en nivel y otro que trabaje con diferencias y variables cíclicas. Explique cuál de los dos captura mejor la dinámica temporal y por qué.

Actividad 2: faltantes temporales

Seleccione una racha faltante de varias semanas y compare tres estrategias: eliminar el tramo, interpolar linealmente y usar imputación basada en estacionalidad vecina. Discuta qué usos del dato hacen defendible cada opción.

Actividad 3: partición temporal

Diseñe un experimento de validación temporal para predecir el siguiente trimestre de la serie. Justifique por qué la validación aleatoria induciría fuga de información.

Navegación

[Volver al índice general](#)
[Volver al índice de casos](#)
[Ir al apéndice de fórmulas](#)

Compendio de fórmulas útiles

A.1 Centrado y escalamiento

$$X_c = HX, \quad H = I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$$

$$Z_{\text{z-score}} = X_c D_s^{-1}$$

$$Z_{\text{rob}} = (X - \text{med}(X)) / \text{IQR}(X)$$

$$Z_{\text{whiten}} = X_c \Sigma^{-1/2}$$

A.2 Transformaciones

$$\log 1p(x) = \log(1 + x)$$

$$g_\lambda^{\text{Box-Cox}}(x) = \begin{cases} \frac{x^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log x, & \lambda = 0 \end{cases}$$

$$g_\lambda^{\text{Yeo-Johnson}}(x) = \begin{cases} \frac{(x+1)^\lambda - 1}{\lambda}, & x \geq 0, \lambda \neq 0, \\ \log(x+1), & x \geq 0, \lambda = 0, \\ -\frac{(-x+1)^{2-\lambda} - 1}{2-\lambda}, & x < 0, \lambda \neq 2, \\ -\log(-x+1), & x < 0, \lambda = 2 \end{cases}$$

$$\text{asinh}(x) = \log\left(x + \sqrt{x^2 + 1}\right)$$

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

A.3 Medidas robustas

$$\text{IQR} = Q_3 - Q_1$$

$$\text{MAD} = \text{med}(|x_i - \text{med}(x)|)$$

$$z^{\text{rob}} = 0,6745 \frac{x - \text{med}(x)}{\text{MAD}}$$

A.4 Dependencia y multivariado

$$S = \frac{1}{n-1} X_c^\top X_c$$

$$R = D_s^{-1} S D_s^{-1}$$

$$d_M(x) = \sqrt{(x - \mu)^\top \Sigma^{-1} (x - \mu)}$$

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

$$\text{clr}(x)_i = \log\left(\frac{x_i}{g(x)}\right), \quad g(x) = \left(\prod_{i=1}^D x_i\right)^{1/D}$$

Navegación

[Volver al índice general](#)

[Volver a casos integrales](#)

[Ir a la matriz de decisión rápida](#)

Matriz de decisión rápida para EDA

B.1 Checklist operativo

Si observa...	Pregúntese...	Acción probable
Sesgo fuerte a la derecha	¿la variable es positiva y multiplicativa?	log, Box–Cox, Yeo–Johnson, o modelo coherente con soporte.
Muchos ceros en un conteo	¿hay exceso de ceros o baja exposición?	separar exposición, considerar Poisson/NegBin/ZIP, usar log1p sólo para exploración.
Escalas muy distintas	¿el algoritmo usa distancias o regularización?	z-score o robust scaling.
Outliers extremos	¿son errores o eventos raros reales?	corregir, excluir o robustecer; no eliminar por reflejo.
Porcentajes que suman 100	¿son composiciones?	clr/alr/ilr antes de correlacionar o hacer PCA.
Hora del día o día del año	¿hay circularidad?	seno/coseno, lags o ventanas.
Categorías con pocos casos	¿la rareza es señal o ruido?	agrupar, regularizar, codificar con cautela.
Target desbalanceado	¿qué métrica representa el costo real?	pesos, remuestreo, PR, calibración.

B.2 Preguntas mínimas antes de aplicar cualquier transformación

1. ¿Qué representa exactamente la variable?
2. ¿Cuál es su soporte matemático?

3. ¿Qué distribución marginal sugiere el EDA?
4. ¿Qué estructura conjunta revela con otras variables?
5. ¿Qué algoritmo consumirá la representación final?
6. ¿La transformación preserva la semántica necesaria?
7. ¿La operación se ajustó sólo con entrenamiento?
8. ¿La decisión quedó documentada?

Navegación

[Volver al índice general](#)

[Ir al compendio de fórmulas](#)

[Volver al capítulo de pipeline reproducible](#)

Proyectos integradores y rúbricas de evaluación

Este apéndice propone proyectos de curso, seminario o laboratorio diseñados para obligar al estudiante a justificar decisiones de transformación, escalamiento y representación. No basta con producir gráficos: la evaluación debe recuperar el *por qué* de cada decisión, la semántica de los datos y la compatibilidad con el modelo posterior.

C.1 Objetivo pedagógico

Un proyecto integrador bien diseñado debe obligar a responder, como mínimo, las siguientes preguntas:

1. ¿Cuál es la unidad observacional y cuál es el proceso generador de datos?
2. ¿Qué variables presentan soporte, distribución o semántica que hacen inválida una transformación automática?
3. ¿Qué hallazgos univariados cambian el análisis multivariado?
4. ¿Qué decisiones dependen de la familia de modelos posterior y cuáles son independientes de ella?
5. ¿Qué errores comunes se evitaron y cómo quedó documentada la trazabilidad del pipeline?

C.2 Proyecto 1: Clasificación biomédica de alta dimensión

Consigna

Usar un dataset biomédico con al menos 20 predictores numéricos y respuesta binaria. Exigir análisis de colinealidad, PCA en covarianza y correlación, y comparación entre un clasificador sensible a escala y un ensamble de árboles.

Entregables mínimos:

1. auditoría semántica de variables;
2. tabla de asimetría, curtosis y soporte;
3. justificación de transformación o no transformación de cada bloque de variables;
4. comparación entre modelo con datos crudos y modelo con pipeline documentado;
5. sección crítica sobre interpretabilidad y estabilidad.

C.3 Proyecto 2: Conteos, tasas y exposición

Consigna

Seleccionar un problema con conteos y exposición (salud pública, logística, tráfico, eventos web). Comparar análisis sobre conteo bruto, tasa y modelo que respete la exposición.

Preguntas obligatorias:

1. ¿Qué información se pierde al usar sólo la tasa?
2. ¿Qué información se distorsiona al usar sólo el conteo?
3. ¿Cómo cambia la heteroscedasticidad al respetar el denominador?

C.4 Proyecto 3: Datos composicionales

Consigna

Trabajar con composiciones reales: nutrientes, presupuestos, participación de mercado, mezclas geoquímicas o perfiles microbiológicos. Comparar correlaciones y PCA sobre porcentajes crudos frente a log-ratios.

Entregables mínimos:

1. demostración de la restricción de suma constante;
2. discusión de ceros estructurales y pseudoconteos;
3. comparación de biplots y matrices de correlación;
4. reflexión sobre interpretabilidad de coordenadas clr o ilr.

C.5 Proyecto 4: Serie temporal multiescala

Consigna

Usar una serie temporal con tendencia y estacionalidad. La evaluación debe distinguir entre transformar la escala de la variable y transformar la dependencia temporal.

Componentes mínimos:

1. faltantes y régimen de observación;
2. descomposición de tendencia y estacionalidad;
3. comparación entre nivel, diferencia y diferencia estacional;
4. análisis del riesgo de fuga temporal durante la validación.

C.6 Rúbrica sugerida

Criterio	Peso	Qué se espera
Comprensión semántica del dataset	20 %	Definición correcta de unidad observacional, variable objetivo y proceso generador de datos.
Diagnóstico univariado	15 %	Uso correcto de soporte, sesgo, curtosis, cuantiles, medidas robustas y justificación de transformaciones.
Diagnóstico multivariado	20 %	Correlaciones, redundancia, estructura latente, dependencia no lineal y lectura geométrica.
Decisiones metodológicas	20 %	Elección argumentada de escalamiento, normalización, reducción de dimensión y tratamiento de faltantes/outliers.
Reproducibilidad	15 %	Pipeline, separación entrenamiento-validación, control de fuga e implementación replicable.
Discusión crítica	10 %	Limitaciones, supuestos, riesgos y comparación de alternativas.

C.7 Lista de verificación docente

Preguntas de revisión

1. ¿El estudiante distinguió entre *transformar por distribución* y *transformar por algoritmo*?
2. ¿La decisión sobre estandarización fue compatible con la familia de modelos elegida?
3. ¿Se evitó escalar variables binarias, dummies o categorías arbitrarias como si fueran continuas?
4. ¿Se documentó si los outliers fueron error, rareza genuina o cambio de régimen?
5. ¿Las decisiones se ajustaron sólo con el conjunto de entrenamiento?

Navegación

[Volver al índice general](#)
[Volver a los casos biométricos](#)
[Ir al capítulo de pipeline reproducible](#)

Bibliografia

- [1] Stefan Aeberhard and Massimo Forina. Wine [dataset]. UCI Machine Learning Repository, 1991.
- [2] John Aitchison. *The Statistical Analysis of Compositional Data*. Chapman and Hall, London, 1986. doi: 10.1007/978-94-009-4109-0.
- [3] George E. P. Box and David R. Cox. An analysis of transformations. *Journal of the Royal Statistical Society. Series B (Methodological)*, 26(2):211–252, 1964. doi: 10.1111/j.2517-6161.1964.tb00553.x.
- [4] Juan José Egozcue, Vera Pawlowsky-Glahn, Glòria Mateu-Figueras, and Carles Barceló-Vidal. Isometric logratio transformations for compositional data analysis. *Mathematical Geology*, 35(3):279–300, 2003. doi: 10.1023/A:1023818214614.
- [5] Ray C. Fair. A theory of extramarital affairs. *Journal of Political Economy*, 86(1):45–61, 1978. doi: 10.1086/260646.
- [6] Jeff Gill. *Generalized Linear Models: A Unified Approach*. SAGE, Thousand Oaks, CA, 2001.
- [7] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, New York, 2 edition, 2009.
- [8] Peter J. Huber and Elvezio M. Ronchetti. *Robust Statistics*. Wiley, Hoboken, NJ, 2 edition, 2009.
- [9] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, New York, 2 edition, 2021.
- [10] Ian T. Jolliffe. *Principal Component Analysis*. Springer, New York, 2 edition, 2002.
- [11] Ian T. Jolliffe and Jorge Cadima. Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065):20150202, 2016. doi: 10.1098/rsta.2015.0202.
- [12] Charles D. Keeling and Timothy P. Whorf. Monthly atmospheric CO2 records from sites in the SIO air sampling network. Carbon Dioxide Information Analysis Center, 2004.
- [13] Max Kuhn and Kjell Johnson. *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press, Boca Raton, FL, 2019.

-
- [14] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley, Hoboken, NJ, 3 edition, 2020. doi: 10.1002/9781119482260.
 - [15] Prasanta Chandra Mahalanobis. On the generalised distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1):49–55, 1936.
 - [16] Ricardo A. Maronna, R. Douglas Martin, Victor J. Yohai, and Matías Salibián-Barrera. *Robust Statistics: Theory and Methods (with R)*. Wiley, Hoboken, NJ, 2 edition, 2019.
 - [17] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA, 1977. ISBN 9780201076165.
 - [18] Stef van Buuren. *Flexible Imputation of Missing Data*. CRC Press, Boca Raton, FL, 2 edition, 2018.
 - [19] William Wolberg, Olvi Mangasarian, Nick Street, and W. Street. Breast cancer wisconsin (diagnostic) [dataset]. UCI Machine Learning Repository, 1993.
 - [20] In-Kwon Yeo and Richard A. Johnson. A new family of power transformations to improve normality or symmetry. *Biometrika*, 87(4):954–959, 2000. doi: 10.1093/biomet/87.4.954.

Cierre

Una buena exploración no es un prólogo decorativo del modelado. Es el momento metodológico en el que se decide qué estructura del dato merece ser preservada, qué artefactos deben corregirse, qué transformaciones son admisibles y qué representaciones son incompatibles con la semántica del problema. Cuando esas decisiones se toman de forma explícita, el modelado posterior deja de ser un experimento ciego y pasa a ser una continuación natural del análisis.