

Especificación oficial de cinco trabajos de laboratorio de DEA/EDA

Curso: Ciencia de Datos – Corte 1

Profesor	Omar Portilla
Programa	Ingeniería de Sistemas
Universidad	Universidad de Pamplona
Periodo académico	2026-1
Dataset oficial	<code>eda_laboratorio_clientes_v1.csv</code>
Modalidad	Trabajo por equipos con socialización y enseñanza entre pares
Enfoque	EDA completo + pipeline reproducible + foco metodológico dominante

Este documento reemplaza la versión anterior de la guía.

La nueva especificación reduce ambigüedad, fija un protocolo común, acota las tareas obligatorias y facilita una calificación verificable por cumplimiento.

Base conceptual: capítulos 4 a 11 del *Manual avanzado de DEA/EDA para ciencia de datos*.

Índice general

1. Marco de diseño de los trabajos	2
1.1. Fundamento conceptual del libro y mapeo a los cinco trabajos	2
1.2. Perfil del dataset oficial	3
1.3. Balance de carga entre trabajos	3
2. Protocolo experimental común y formato de entrega	4
2.1. Reglas comunes para todos los equipos	4
2.2. Formato obligatorio de razonamiento	4
2.2.1. Plantilla mínima de la bitácora de decisiones	5
2.3. Estructura obligatoria del informe	5
2.4. Archivos exactos que debe entregar cada equipo	6
2.5. Rúbrica única para los cinco trabajos	6
2.5.1. Regla de puerta de entrada a la rúbrica	6
3. Trabajo 1: Transformaciones de variables numéricas	8
3.1. Capítulos base del libro	8
3.2. Variables obligatorias del trabajo	8
3.3. Alcance exacto y restricciones	8
3.4. Productos analíticos obligatorios	9
3.4.1. Tablas obligatorias	9
3.4.2. Figuras obligatorias	9
3.5. Razonamientos obligatorios	9
3.6. Socialización obligatoria	10
3.7. Lista de verificación de cumplimiento	10
4. Trabajo 2: Escalamiento, estandarización y geometría	11
4.1. Capítulos base del libro	11
4.2. Variables obligatorias del trabajo	11

4.3.	Alcance exacto y restricciones	11
4.4.	Productos analíticos obligatorios	12
4.4.1.	Tablas obligatorias	12
4.4.2.	Figuras obligatorias	12
4.5.	Razonamientos obligatorios	12
4.6.	Socialización obligatoria	13
4.7.	Lista de verificación de cumplimiento	13
5.	Trabajo 3: Dependencia, correlación y estructura multivariada	14
5.1.	Capítulos base del libro	14
5.2.	Variables obligatorias del trabajo	14
5.2.1.	Pares obligatorios para análisis de asociación	14
5.2.2.	Bloque multivariado obligatorio	14
5.3.	Alcance exacto y restricciones	15
5.4.	Productos analíticos obligatorios	15
5.4.1.	Tablas obligatorias	15
5.4.2.	Figuras obligatorias	15
5.5.	Razonamientos obligatorios	16
5.6.	Socialización obligatoria	16
5.7.	Lista de verificación de cumplimiento	16
6.	Trabajo 4: Tipo de dato, calidad y representación	17
6.1.	Capítulos base del libro	17
6.2.	Variables obligatorias del trabajo	17
6.2.1.	Bloque de representación por tipo de dato	17
6.2.2.	Bloque de calidad obligatorio	17
6.3.	Alcance exacto y restricciones	18
6.4.	Productos analíticos obligatorios	18
6.4.1.	Tablas obligatorias	18
6.4.2.	Figuras obligatorias	18
6.5.	Razonamientos obligatorios	19
6.6.	Socialización obligatoria	19
6.7.	Lista de verificación de cumplimiento	19
7.	Trabajo 5: Variable objetivo, fuga de información y pipeline reproducible	20
7.1.	Capítulos base del libro	20

7.2. Variables obligatorias del trabajo	20
7.2.1. Objetivo obligatorio	20
7.2.2. Predictores obligatorios	20
7.2.3. Variables prohibidas para el pipeline final	21
7.3. Alcance exacto y restricciones	21
7.4. Productos analíticos obligatorios	21
7.4.1. Tablas obligatorias	21
7.4.2. Figuras obligatorias	22
7.5. Razonamientos obligatorios	22
7.6. Socialización obligatoria	22
7.7. Lista de verificación de cumplimiento	22
A. Plantilla breve de control docente	24
B. Cierre	25

1 Marco de diseño de los trabajos

Esta guía adopta una decisión pedagógica deliberada: para el **Corte 1**, cada equipo desarrollará **un único trabajo** entre los cinco definidos en este documento, pero todos los trabajos exigen **EDA completo** y **pipeline reproducible**. Lo que cambia entre trabajos no es el estándar de rigor, sino el **foco dominante** del razonamiento.

Esta arquitectura responde a cuatro necesidades docentes:

1. evitar trabajos demasiado abiertos, donde cada equipo hace cosas incomparables;
2. convertir la calificación en verificación de cumplimiento más juicio técnico, no en adivinación de intenciones;
3. balancear la dificultad entre equipos;
4. asegurar que la socialización permita al resto del curso aprender teoría, práctica y criterio aplicado.

1.1 Fundamento conceptual del libro y mapeo a los cinco trabajos

Los cinco trabajos se construyen sobre los capítulos que se definieron al inicio del curso como base conceptual del laboratorio: capítulos 4, 5, 6–7, 8–9 y 10–11. La lógica es la siguiente:

Trabajo	Capítulos base	Eje conceptual dominante
Trabajo 1	Capítulo 4, con conexión a 10 y 11	Transformaciones numéricas según soporte, colas, signo, semántica y objetivo.
Trabajo 2	Capítulo 5, con conexión a 7 y 11	Escalamiento, métrica, geometría del espacio y sensibilidad algorítmica.
Trabajo 3	Capítulos 6 y 7	Dependencia, asociación, colinealidad, estructura latente y outliers multivariados.
Trabajo 4	Capítulos 8 y 9, con conexión a 11	Tipo de dato, operaciones válidas, calidad de datos, faltantes y representación.
Trabajo 5	Capítulos 10 y 11	Variable objetivo, métricas, fuga de información y pipeline reproducible de extremo a extremo.

1.2 Perfil del dataset oficial

El dataset oficial del laboratorio tiene 10,090 filas y 34 columnas. Cada fila representa un **snapshot de cliente** en una fecha de corte `snapshot_date`; la variable objetivo es `future_spend_60d`, gasto futuro en una ventana posterior de 60 días. El dataset contiene, de forma intencional, variables nominales, ordinales, positivas sesgadas, conteos, proporciones, composiciones, variables cíclicas, una variable con signo y colas pesadas, faltantes con mecanismos distintos, duplicados por `customer_id` y variables de posible fuga `post_window_*`.

Regla de decisión: El dataset es el mismo para todos los equipos. El objeto de evaluación no es “quién encontró un mejor dataset”, sino quién razona mejor sobre el mismo dataset.

1.3 Balance de carga entre trabajos

Para que la dificultad sea comparable, los cinco trabajos se ajustan a la misma estructura de carga académica.

Trabajo	Tablas oblig.	Figuras oblig.	Experimer	Preguntas de razonamiento	Socialización
Trabajo 1	3	4	2 comparaciones modelísticas	5	15 min + 5 min
Trabajo 2	3	4	2 comparaciones geométrico-predictivas	5	15 min + 5 min
Trabajo 3	3	4	2 comparaciones de estructura/modelo	5	15 min + 5 min
Trabajo 4	3	4	2 comparaciones de representación/modelo	5	15 min + 5 min
Trabajo 5	3	4	3 formulaciones del objetivo + 1 auditoría de fuga	5	15 min + 5 min

Condición crítica: No se permite ampliar arbitrariamente el alcance. La dificultad está balanceada porque todos los trabajos tienen productos mínimos equivalentes. El material adicional sólo cuenta si los mínimos están completos y correctos.

2 Protocolo experimental común y formato de entrega

2.1 Reglas comunes para todos los equipos

1. El archivo oficial de trabajo es `eda_laboratorio_clientes_v1.csv`. No se permite mezclar otro dataset.
2. Para cualquier experimento predictivo, el equipo debe construir una versión modelable del dataset **deduplicando por `customer_id`** y conservando el registro con **fecha más reciente** en `snapshot_date`. Debe reportar cuántas filas se removieron.
3. La variable derivada común para clasificación es:

$$\text{spend_positive} = \mathbb{I}\{\text{future_spend_60d} > 0\}.$$

4. Las columnas `record_id` y `customer_id` no pueden usarse como predictores.
5. Las columnas `post_window_retention_call` y `post_window_discount_amount` están **prohibidas** en cualquier pipeline final. Sólo pueden usarse en el Trabajo 5 para auditoría explícita de fuga de información.
6. Para todos los trabajos con modelado se debe usar el mismo esquema de partición: 60 % entrenamiento, 20 % validación, 20 % prueba, con **`random_state = 2026`** y **estratificación por `spend_positive`**.
7. La prueba se usa una sola vez: sólo para reportar el desempeño del modelo final elegido. Todas las comparaciones intermedias se hacen sobre validación.
8. Cualquier imputación, escalamiento, transformación, codificación o reducción de dimensión debe ajustarse **sólo con entrenamiento** y aplicarse luego a validación y prueba dentro de un `Pipeline/ColumnTransformer` o estructura equivalente.
9. Cada decisión relevante debe registrarse en una **bitácora de decisión**.

2.2 Formato obligatorio de razonamiento

En los cinco trabajos, toda decisión metodológica importante debe redactarse con la misma estructura. Esta estructura no es opcional; hace parte de la calificación porque permite verificar si el equipo razonó o sólo ejecutó comandos.

Regla de decisión: Toda decisión debe presentarse bajo la secuencia: **Hallazgo empírico** → **lectura de soporte/semántica/PGD** → **riesgo metodológico** → **decisión** → **validación**.

2.2.1 Plantilla mínima de la bitácora de decisiones

Cada equipo debe entregar un archivo CSV o Markdown con las siguientes columnas mínimas:

Campo	Contenido mínimo
Variable o bloque	Nombre de la variable o grupo de variables.
Tipo y soporte	Continua positiva, conteo, proporción, ordinal, composición, cíclica, etc.
Hallazgo empírico	Sesgo, colas, faltante, colinealidad, rareza, dependencia no lineal, etc.
Riesgo metodológico	Qué se distorsiona si no se actúa o si se actúa mal.
Alternativas consideradas	Al menos dos cuando aplique.
Decisión final	Qué se hizo finalmente.
Justificación	Argumento breve, técnico y verificable.
Validación	Evidencia estadística, geométrica o predictiva que respalda la decisión.

2.3 Estructura obligatoria del informe

Todo informe debe usar exactamente las siguientes secciones, en este orden:

1. Resumen ejecutivo.
2. Pregunta rectora del trabajo.
3. Variables obligatorias y justificación de su relevancia.
4. Protocolo experimental común aplicado al dataset.
5. Resultados obligatorios.
6. Razonamientos obligatorios.
7. Decisión final del equipo.
8. Errores que el trabajo evita.
9. Conclusión para enseñar al curso.
10. Referencias.

2.4 Archivos exactos que debe entregar cada equipo

El docente evaluará con mayor rapidez si el formato es uniforme. Por tanto, cada equipo debe subir una carpeta con esta estructura, cambiando sólo el número del trabajo:

```
/WX_apellidos_equipo/
informe_WX.pdf
informe_WX.tex (opcional si lo escriben en LaTeX)
bitacora_WX.csv
socializacion_WX.pdf
handout_WX_1pagina.pdf
codigo_WX/ (scripts o notebook reproducible)
README_WX.md
salidas_WX/ (tablas y figuras finales)
```

Donde WX se reemplaza por W1, W2, W3, W4 o W5.

2.5 Rúbrica única para los cinco trabajos

Criterio	Peso	Qué se espera
Comprensión semántica y lectura del problema	15 %	La unidad observacional se define correctamente, se reconoce el soporte de las variables y se evita una lectura ingenua del dataset.
Rigor del diagnóstico base	15 %	El equipo usa medidas descriptivas y robustas, identifica calidad, distribución y estructura con evidencia suficiente.
Profundidad en el foco del trabajo	20 %	El eje temático asignado se desarrolla con comparación de alternativas, no como receta única.
Calidad del razonamiento escrito	15 %	Las decisiones siguen la secuencia hallazgo → interpretación → riesgo → decisión → validación.
Pipeline reproducible y control de fuga	20 %	La implementación es replicable, evita fuga de información y respeta el protocolo experimental común.
Socialización y enseñanza a pares	15 %	La exposición enseña teoría, muestra práctica aplicada y deja aprendizajes transferibles al resto del curso.

2.5.1 Regla de puerta de entrada a la rúbrica

La rúbrica sólo se aplica completamente si el equipo cumple los **mínimos no negociables**. Si falta alguno de estos ítems, el trabajo entra automáticamente al rango de cumplimiento insuficiente, aunque tenga partes técnicamente correctas.

- No usó variables `post_window_*` en el pipeline final.
- Deduplicó por `customer_id` para el modelado y reportó el número de filas removidas.
- Usó la partición 60/20/20 con `random_state = 2026` y estratificación por `spend_positive`.
- Ajustó transformadores sólo sobre entrenamiento.
- Entregó bitácora de decisiones.
- Respondió las cinco preguntas de razonamiento obligatorio del trabajo asignado.

3 Trabajo 1: Transformaciones de variables numéricas

Pregunta rectora: ¿Qué transformaciones están justificadas para este dataset y cuáles serían metodológicamente incorrectas si se considera soporte, sesgo, colas, semántica y uso posterior del objetivo?

3.1 Capítulos base del libro

Capítulo 4 completo, con conexión mínima a 10.2, 10.7, 11.4 y 11.6.

3.2 Variables obligatorias del trabajo

El equipo debe trabajar obligatoriamente con estas variables:

- `monthly_income_est`
- `recency_days`
- `transactions_90d`
- `gross_revenue_90d`
- `balance_change_30d`
- `future_spend_60d`

Puede incluir hasta dos variables adicionales, pero sólo después de completar las seis obligatorias.

3.3 Alcance exacto y restricciones

1. Debe construir una tabla de soporte y transformación candidata para las seis variables obligatorias.
2. Debe comparar exactamente las siguientes alternativas:
 - para `monthly_income_est`: sin transformar vs $\log(1 + x)$;
 - para `recency_days`: sin transformar vs $\log(1 + x)$;

- para `transactions_90d`: sin transformar vs $\sqrt{x}$ vs $\log(1+x)$;
 - para `gross_revenue_90d`: sin transformar vs $\log(1+x)$;
 - para `balance_change_30d`: sin transformar vs $\operatorname{asinh}(x)$ vs Yeo–Johnson.
3. Debe mostrar, antes y después, **sesgo, curtosis, mediana, IQR y percentil 95**.
 4. Debe construir dos experimentos predictivos sobre el mismo split común:
 - Experimento A: clasificación de `spend_positive` con regresión logística penalizada, comparando versión base vs versión transformada.
 - Experimento B: regresión positiva sobre $\log(1 + \text{future_spend_60d})$ usando sólo los casos con gasto futuro positivo, comparando versión base vs versión transformada.
 5. Debe dejar explícito, variable por variable, si la transformación final se adopta, se rechaza o se reserva sólo para un tipo de modelo.

Condición crítica: No se acepta transformar por costumbre. Si el equipo aplica logaritmo a `balance_change_30d` o trata `transactions_90d` como continuo libre sin justificar, el trabajo queda conceptualmente comprometido.

3.4 Productos analíticos obligatorios

3.4.1 Tablas obligatorias

1. **Tabla W1.1:** variable, soporte, patrón observado, transformaciones candidatas, decisión final.
2. **Tabla W1.2:** comparación antes–después de sesgo, curtosis, mediana, IQR y P95.
3. **Tabla W1.3:** métricas del Experimento A y del Experimento B en validación y prueba final.

3.4.2 Figuras obligatorias

1. **Figura W1.1:** distribución de `monthly_income_est` antes y después.
2. **Figura W1.2:** distribución de `transactions_90d` bajo las tres alternativas.
3. **Figura W1.3:** distribución de `balance_change_30d` antes y después.
4. **Figura W1.4:** distribución de `future_spend_60d` y de su subconjunto positivo.

3.5 Razonamientos obligatorios

Estas cinco preguntas deben responderse en una sección titulada exactamente **Razonamientos obligatorios**. Cada respuesta debe apoyarse en evidencia del dataset.

1. ¿Por qué `monthly_income_est` y `gross_revenue_90d` admiten $\log(1+x)$ y qué cambia en la interpretación de un efecto lineal después de transformar?

2. ¿Por qué `balance_change_30d` no admite logaritmo simple y qué preservan $\text{asinh}(x)$ y Yeo–Johnson que el logaritmo perdería?
3. ¿Por qué `transactions_90d` sigue siendo un conteo aunque se transforme, y qué implicación tiene eso sobre el tipo de modelo posterior?
4. ¿Por qué `future_spend_60d` no debe tratarse como un continuo aproximadamente gaussiano único?
5. Mencione una variable de las obligatorias para la cual **no transformar** sea una decisión defendible y justifique por qué.

3.6 Socialización obligatoria

La presentación del equipo debe seguir esta estructura exacta:

1. 4 minutos de teoría: soporte, sesgo, colas y familias de transformación.
2. 7 minutos de evidencia empírica sobre las seis variables obligatorias.
3. 2 minutos de comparación de pipelines y métricas.
4. 2 minutos finales con tres reglas docentes para el resto del curso.

Además, el equipo debe entregar un **handout de una página** titulado *Mapa de decisión de transformaciones para este dataset*.

3.7 Lista de verificación de cumplimiento

- ☐ Usó exactamente las seis variables obligatorias.
- ☐ Comparó las transformaciones prescritas, sin omitir ninguna.
- ☐ Reportó sesgo, curtosis, mediana, IQR y P95 antes y después.
- ☐ Separó el análisis del objetivo de la regresión positiva condicional.
- ☐ Comparó versión base y versión transformada sobre el mismo split.
- ☐ Respondió las cinco preguntas de razonamiento.
- ☐ Entregó **handout docente de una página**.

4 Trabajo 2: Escalamiento, estandarización y geometría

Pregunta rectora: ¿Cómo cambia la geometría del espacio de variables cuando se trabaja en escala cruda, z-score o robust scaling, y qué consecuencias tiene eso sobre PCA y métodos sensibles a distancia?

4.1 Capítulos base del libro

Capítulo 5 completo, con apoyo puntual en 7.9, 11.5 y 11.6.

4.2 Variables obligatorias del trabajo

El bloque numérico obligatorio es el siguiente:

- `age`
- `tenure_days`
- `recency_days`
- `sessions_90d`
- `gross_revenue_90d`
- `monthly_income_est`
- `credit_limit_est`
- `monetary_value_score`
- `debt_to_income_ratio`
- `balance_change_30d`

No se permite reemplazar este bloque por otro.

4.3 Alcance exacto y restricciones

1. Debe comparar exactamente tres representaciones del bloque: cruda, z-score y robust scaling.

2. Debe analizar **rango, desviación estándar e IQR** de cada variable antes de escalar.
3. Debe ejecutar PCA sobre:
 - matriz cruda centrada;
 - variables estandarizadas con z-score.
4. Debe ejecutar un clasificador KNN con $k = 11$ sobre **spend_positive**, comparando exactamente: sin escalar, z-score y robust scaling.
5. Debe incluir una crítica explícita de min–max usando al menos una variable con colas o extremos relevantes.

Regla de decisión: La pregunta de este trabajo no es “qué escalador da mejor métrica” sino “qué geometría es coherente con la pregunta analítica y el algoritmo utilizado”.

4.4 Productos analíticos obligatorios

4.4.1 Tablas obligatorias

1. **Tabla W2.1:** rango, desviación estándar e IQR de las diez variables en escala original.
2. **Tabla W2.2:** varianza explicada acumulada de PCA cruda y PCA estandarizada para las primeras cinco componentes.
3. **Tabla W2.3:** desempeño del KNN en validación y prueba para las tres representaciones.

4.4.2 Figuras obligatorias

1. **Figura W2.1:** visualización comparativa de escalas originales (por ejemplo, boxplots o histogramas normalizados).
2. **Figura W2.2:** proyección PCA sobre escala cruda.
3. **Figura W2.3:** proyección PCA sobre variables estandarizadas.
4. **Figura W2.4:** comparación gráfica del desempeño del KNN y evidencia de por qué min–max es frágil en este dataset.

4.5 Razonamientos obligatorios

1. ¿Por qué escalar no corrige sesgo ni colas, aunque sí cambie de forma drástica la geometría euclidiana?
2. ¿Por qué una primera componente dominante en PCA cruda no debe interpretarse automáticamente como estructura sustantiva unidimensional?
3. ¿Qué hace robust scaling en presencia de **balance_change_30d** y **monthly_income_est** que z-score no hace igual de bien?
4. ¿Por qué min–max es especialmente frágil en este dataset?

5. ¿Por qué el escalamiento debe estimarse sólo con entrenamiento y no con todo el dataset?

4.6 Socialización obligatoria

1. 4 minutos de teoría: métrica, centrado, z-score, robust scaling y PCA.
2. 7 minutos de resultados sobre el bloque obligatorio.
3. 2 minutos de lectura geométrica del cambio raw $\rightarrow$ scaled.
4. 2 minutos con tres mensajes pedagógicos para el resto del curso.

El handout de una página debe titularse *Escalar es elegir una métrica*.

4.7 Lista de verificación de cumplimiento

- ☐ Usó exactamente las diez variables del bloque obligatorio.
- ☐ Comparó las tres representaciones pedidas.
- ☐ Ejecutó PCA cruda y PCA estandarizada.
- ☐ Ejecutó KNN con $k = 11$ y mismo split para las tres versiones.
- ☐ Incluyó crítica explícita de min-max.
- ☐ Respondió las cinco preguntas de razonamiento.
- ☐ Entregó handout docente de una página.

5 Trabajo 3: Dependencia, correlación y estructura multivariada

Pregunta rectora: ¿Qué relaciones son lineales, cuáles son sólo monotónicas, dónde hay redundancia direccional y qué cambia cuando la rareza se evalúa multivariadamente en lugar de hacerlo variable por variable?

5.1 Capítulos base del libro

Capítulos 6 y 7 completos, con apoyo puntual en 11.6.

5.2 Variables obligatorias del trabajo

5.2.1 Pares obligatorios para análisis de asociación

Deben analizarse exactamente estos cuatro pares:

1. `credit_limit_est` vs `monetary_value_score`
2. `transactions_90d` vs `gross_revenue_90d`
3. `promo_open_rate_90d` vs `behavioral_variability_index`
4. `satisfaction_score` vs `support_tickets_90d`

5.2.2 Bloque multivariado obligatorio

- `age`
- `tenure_days`
- `recency_days`
- `sessions_90d`
- `transactions_90d`
- `gross_revenue_90d`
- `credit_limit_est`

- `monetary_value_score`
- `balance_change_30d`

5.3 Alcance exacto y restricciones

1. Para cada uno de los cuatro pares obligatorios debe justificar qué medida de asociación usa y por qué. No se acepta usar una sola medida para todos por costumbre.
2. Debe calcular y discutir VIF sobre el bloque multivariado obligatorio.
3. Debe ejecutar PCA estandarizada sobre el bloque multivariado obligatorio.
4. Debe detectar outliers multivariados comparando exactamente:
 - distancia de Mahalanobis con covarianza empírica;
 - distancia robusta usando MCD o estimador equivalente.
5. Debe comparar tres diseños de regresión logística sobre `spend_positive`:
 - Diseño A: bloque completo estandarizado;
 - Diseño B: bloque reducido, removiendo exactamente `monetary_value_score` y `gross_revenue_90d`;
 - Diseño C: componentes principales suficientes para explicar al menos 80 % de la varianza.

Condición crítica: No se acepta interpretar correlación alta como prueba de causalidad ni eliminar outliers sin discutir si son rareza real o artefacto.

5.4 Productos analíticos obligatorios

5.4.1 Tablas obligatorias

1. **Tabla W3.1:** medidas de asociación para los cuatro pares obligatorios y su interpretación.
2. **Tabla W3.2:** VIF del bloque multivariado obligatorio.
3. **Tabla W3.3:** comparación de los diseños A, B y C en validación y prueba, más resumen de coincidencia/discrepancia entre Mahalanobis y MCD en los 15 casos más extremos.

5.4.2 Figuras obligatorias

1. **Figura W3.1:** dispersión de `promo_open_rate_90d` vs `behavioral_variability_index` con suavizado.
2. **Figura W3.2:** mapa de correlación del bloque multivariado obligatorio.
3. **Figura W3.3:** proyección PCA estandarizada del bloque obligatorio.
4. **Figura W3.4:** comparación gráfica de outliers multivariados por Mahalanobis y por MCD.

5.5 Razonamientos obligatorios

1. ¿Por qué el par `promo_open_rate_90d` vs `behavioral_variability_index` no puede resolverse sólo con Pearson?
2. ¿Cómo interpreta VIF desde la estabilidad de coeficientes y la redundancia geométrica del espacio columna?
3. ¿Por qué un outlier multivariado puede no ser un outlier univariado?
4. ¿Cuándo recomendaría PCA sobre eliminación de variables y cuándo haría lo contrario en este bloque?
5. Si el objetivo fuera explicación frente a predicción, ¿cuál de los diseños A, B o C sería preferible y por qué?

5.6 Socialización obligatoria

1. 4 minutos de teoría: asociación, VIF, PCA y outliers multivariados.
2. 7 minutos de evidencia con los pares y el bloque obligatorios.
3. 2 minutos sobre la diferencia entre explicar y predecir en presencia de colinealidad.
4. 2 minutos finales con tres advertencias metodológicas para la clase.

El handout de una página debe titularse *La dependencia no es un número único*.

5.7 Lista de verificación de cumplimiento

- ☐ Analizó exactamente los cuatro pares obligatorios.
- ☐ Justificó la medida de asociación usada en cada par.
- ☐ Calculó y discutió VIF en el bloque multivariado obligatorio.
- ☐ Comparó Mahalanobis y MCD.
- ☐ Comparó los diseños A, B y C de regresión logística.
- ☐ Respondió las cinco preguntas de razonamiento.
- ☐ Entregó handout docente de una página.

6 Trabajo 4: Tipo de dato, calidad y representación

Pregunta rectora: ¿Qué operaciones son válidas o inválidas según el tipo de dato de cada variable y cómo cambia la calidad del modelo cuando se representa el dato de forma semánticamente coherente en lugar de hacerlo con una codificación ingenua?

6.1 Capítulos base del libro

Capítulos 8 y 9 completos, con conexión puntual a 11.4 y 11.5.

6.2 Variables obligatorias del trabajo

6.2.1 Bloque de representación por tipo de dato

- Nominales: `region`, `plan_type`
- Ordinales: `education_level`, `loyalty_tier`, `satisfaction_score`
- Proporción: `promo_open_rate_90d`
- Composición: `share_web`, `share_mobile`, `share_store`, `share_partner`
- Cíclica: `peak_hour_local`

6.2.2 Bloque de calidad obligatorio

- `customer_id` para auditoría de duplicados
- `avg_order_value_90d`
- `education_level`
- `satisfaction_score`
- `promo_open_rate_90d`

6.3 Alcance exacto y restricciones

1. Debe construir una **matriz de tipo de dato y operaciones válidas** para todas las variables obligatorias de este trabajo.
2. Debe analizar y justificar el mecanismo de ausencia más plausible para:
 - `avg_order_value_90d`;
 - `education_level`;
 - `satisfaction_score`;
 - `promo_open_rate_90d`.
3. Para `avg_order_value_90d`, debe demostrar con evidencia si el faltante es estructural respecto a `transactions_90d`.
4. Debe comparar las correlaciones de las composiciones **antes y después** de una transformación CLR con pseudoconteo cuando sea necesario.
5. Debe mostrar por qué `peak_hour_local` no debe entrar como entero crudo si se quiere preservar circularidad.
6. Debe comparar dos pipelines de clasificación logística sobre `spend_positive`:
 - Pipeline ingenuo: nominales codificadas como enteros, composiciones crudas, variable cíclica como entero, imputación simple sin indicadores.
 - Pipeline semánticamente coherente: one-hot en nominales, ordinales tratadas como ordinales, CLR para composición, codificación seno/coseno para `peak_hour_local`, e indicadores de faltante cuando aplique.

Regla de decisión: Este trabajo no evalúa sólo “limpieza”. Evalúa si el equipo sabe reconocer que un número puede no comportarse como continuo euclidiano aunque esté almacenado como número.

6.4 Productos analíticos obligatorios

6.4.1 Tablas obligatorias

1. **Tabla W4.1:** matriz de tipo de dato, soporte, riesgo y operación válida/ inválida.
2. **Tabla W4.2:** evidencia sobre faltantes, hipótesis de mecanismo y tratamiento propuesto para las cuatro variables obligatorias de calidad.
3. **Tabla W4.3:** comparación de desempeño entre pipeline ingenuo y pipeline semánticamente coherente.

6.4.2 Figuras obligatorias

1. **Figura W4.1:** frecuencias de `region` y `plan_type`, señalando rareza categórica cuando aplique.

2. **Figura W4.2:** comparación de correlaciones o biplot composicional antes y después de CLR.
3. **Figura W4.3:** ilustración de la corrección cíclica de `peak_hour_local` (entero crudo vs seno/coseno).
4. **Figura W4.4:** evidencia del mecanismo de faltante de `avg_order_value_90d` y/o comparación gráfica de desempeño entre los dos pipelines.

6.5 Razonamientos obligatorios

1. ¿Por qué `region` y `plan_type` no pueden tratarse como variables ordinales arbitrarias?
2. ¿Cuándo una variable ordinal puede conservarse como entero ordenado y cuándo conviene otra representación?
3. ¿Por qué las variables `share_web`, `share_mobile`, `share_store` y `share_partner` forman una composición, y qué error se comete al correlacionarlas crudas como si fueran independientes?
4. ¿Por qué `peak_hour_local` debe representarse cíclicamente si importa cercanía temporal?
5. ¿Qué evidencia le permite afirmar que el faltante de `avg_order_value_90d` es estructural y no aleatorio, y cómo cambia eso la imputación?

6.6 Socialización obligatoria

1. 4 minutos de teoría: tipo de dato, operaciones válidas, faltantes y composición.
2. 7 minutos de evidencia sobre el bloque obligatorio.
3. 2 minutos de comparación entre pipeline ingenuo y pipeline coherente.
4. 2 minutos finales con tres errores frecuentes que la clase debe evitar.

El handout de una página debe titularse *No todo número es una variable continua*.

6.7 Lista de verificación de cumplimiento

- ☐ Construyó la matriz de tipo de dato y operaciones válidas.
- ☐ Analizó los cuatro mecanismos de faltante exigidos.
- ☐ Demostró el carácter estructural de `avg_order_value_90d` respecto a `transactions_90d`.
- ☐ Comparó composición cruda vs CLR.
- ☐ Codificó `peak_hour_local` con seno/coseno en el pipeline coherente.
- ☐ Comparó pipeline ingenuo vs pipeline coherente.
- ☐ Respondió las cinco preguntas de razonamiento.
- ☐ Entregó handout docente de una página.

7 Trabajo 5: Variable objetivo, fuga de información y pipeline reproducible

Pregunta rectora: ¿Qué cambia cuando el objetivo se formula como incidencia, intensidad condicional o regresión ingenua de una variable semicontinua, y cómo se documenta un pipeline reproducible sin fuga de información?

7.1 Capítulos base del libro

Capítulos 10 y 11 completos.

7.2 Variables obligatorias del trabajo

7.2.1 Objetivo obligatorio

- `future_spend_60d`
- `spend_positive` (derivada obligatoria)

7.2.2 Predictores obligatorios

- `region`
- `plan_type`
- `loyalty_tier`
- `age`
- `recency_days`
- `active_days_90d`
- `sessions_90d`
- `transactions_90d`
- `gross_revenue_90d`

- `monthly_income_est`
- `balance_change_30d`

7.2.3 Variables prohibidas para el pipeline final

- `post_window_retention_call`
- `post_window_discount_amount`

7.3 Alcance exacto y restricciones

1. Debe construir un perfil completo del objetivo: tasa de ceros, media positiva, mediana positiva, percentil 95 positivo, sesgo y relación con `plan_type` y `loyalty_tier`.
2. Debe comparar exactamente tres formulaciones:
 - Formulación A: clasificación de `spend_positive` con regresión logística.
 - Formulación B: regresión positiva condicional sobre $\log(1 + \text{future_spend_60d})$ usando sólo casos positivos.
 - Formulación C: regresión ingenua de una sola etapa sobre $\log(1 + \text{future_spend_60d})$ con todos los casos.
3. Debe construir una auditoría de fuga repitiendo la Formulación A con las dos variables `post_window_*` incluidas, sólo para mostrar la inflación artificial de desempeño.
4. Debe construir un **pipeline final reproducible** para la formulación que el equipo considere metodológicamente más defendible.
5. Debe reportar el desempeño de todas las formulaciones en validación y el desempeño del pipeline final sólo una vez en prueba.

Condición crítica: Si el equipo usa las variables `post_window_*` en el modelo final, el trabajo queda automáticamente inválido por fuga de información.

7.4 Productos analíticos obligatorios

7.4.1 Tablas obligatorias

1. **Tabla W5.1:** perfil estadístico del objetivo y tasas de positividad por `plan_type` y `loyalty_tier`.
2. **Tabla W5.2:** comparación de métricas para las formulaciones A, B y C en validación, y métrica final en prueba para la formulación elegida.
3. **Tabla W5.3:** auditoría de fuga, comparando Formulación A válida vs Formulación A con `post_window_*`.

7.4.2 Figuras obligatorias

1. **Figura W5.1:** distribución de `future_spend_60d` en escala original y/o separada por positivos.
2. **Figura W5.2:** curva ROC o PR de la Formulación A.
3. **Figura W5.3:** diagnóstico de la Formulación B sobre positivos (por ejemplo, observado vs predicho o residuales en log-escala).
4. **Figura W5.4:** comparación visual del desempeño válido vs con fuga.

7.5 Razonamientos obligatorios

1. ¿Por qué `future_spend_60d` es un objetivo semicontinuo y qué pregunta responde cada una de las formulaciones A, B y C?
2. ¿Por qué las métricas de clasificación y las métricas de regresión no deben compararse como si midieran exactamente lo mismo?
3. ¿Qué hace que las variables `post_window_*` sean fuga de información y no “buenos predictores” legítimos?
4. ¿Qué partes del análisis pueden inspeccionarse con todo el dataset y cuáles deben ajustarse sólo con entrenamiento?
5. ¿Cuál formulación recomienda como pipeline final para este curso y bajo qué criterio de decisión la defendería ante una organización real?

7.6 Socialización obligatoria

1. 4 minutos de teoría: variable objetivo, función de pérdida, métricas y fuga.
2. 7 minutos de comparación de las tres formulaciones y de la auditoría de fuga.
3. 2 minutos de explicación del pipeline final reproducible.
4. 2 minutos finales con tres reglas para no contaminar evaluación fuera de muestra.

El handout de una página debe titularse *La variable objetivo cambia todo*.

7.7 Lista de verificación de cumplimiento

- ☐ Construyó el perfil completo del objetivo.
- ☐ Comparó exactamente las formulaciones A, B y C.
- ☐ Ejecutó auditoría explícita de fuga con `post_window_*`.
- ☐ Reportó validación para comparación y prueba sólo para el modelo final.
- ☐ Entregó pipeline reproducible de extremo a extremo.
- ☐ Respondió las cinco preguntas de razonamiento.

☐ Entregó handout docente de una página.

A Plantilla breve de control docente

Esta plantilla puede imprimirse y usarse como hoja de verificación rápida durante la revisión.

Ítem de control	Sí / No	Observación
El equipo usó el dataset oficial y el trabajo asignado.		
Aplicó el protocolo experimental común.		
Deduplicó por <code>customer_id</code> y reportó cuántas filas removió.		
No usó <code>post_window_*</code> en el pipeline final.		
Entregó bitácora de decisiones.		
Respondió los cinco razonamientos obligatorios.		
Incluyó las tres tablas obligatorias.		
Incluyó las cuatro figuras obligatorias.		
El pipeline corre de extremo a extremo.		
La exposición enseña teoría y práctica.		

B Cierre

La función de esta guía no es volver los trabajos “más fáciles”, sino **más verificables, más justos y más formativos**. Cada trabajo obliga al equipo a razonar sobre el mismo dataset desde un foco metodológico distinto, pero todos comparten el mismo estándar: identificar estructura, evitar automatismos, documentar decisiones y enseñar al resto del curso qué aprendieron y por qué.

Cuando un trabajo cumple esta guía, el docente no necesita adivinar qué quiso hacer el equipo: puede verificar si hizo lo pedido, si entendió el tema y si logró convertir el análisis en conocimiento transferible.