

Cero a Experto: Trabajo 4

Todo lo que necesitas saber, entender y decir para sustentar el proyecto con total seguridad. Explicado visualmente con analogías.

Estudiante: Anderson González

Documento exclusivo para estudio y preparación oral.

Índice de Estudio


- 01 Introducción: ¿Qué demonios estamos haciendo?
- 02 Diccionario de Supervivencia (Vocabulario Básico)
- 03 El Problema de los Faltantes (No todo nulo es igual)
- 04 La Trampa Matemática (Tipos de Datos)
- 05 El "Pipeline": El Ingenuo vs. El Coherente
- 06 Las Métricas: ¿Cómo sabemos si ganamos?
- 07 Simulador de Sustentación (Preguntas Trampa)

1. ¿Qué demonios estamos haciendo?

Imagina que eres el dueño de una tienda. Tienes una lista enorme (10,090 filas) de todos los clientes que han pasado por tu negocio. Tienes datos sobre su edad, cuánto han comprado, desde qué canal llegaron (web, móvil) y a qué hora suelen comprar.

El Objetivo del Trabajo: Tu profesor quiere que construyas un modelo predictivo (una bola de cristal estadística) para responder a una sola pregunta: ¿Este cliente específico va a gastar dinero en los próximos 60 días? Sí o No.

Pero el profesor puso una trampa (la Pregunta Rectora del trabajo). La trampa es ver si le vas a entregar la información a la "bola de cristal" a lo bruto (Pipeline Ingenuo), o si vas a ser inteligente y vas a darle la información explicándole qué significa cada número (Pipeline Coherente).




El flujo general: Transformamos datos en la predicción final `'spend_positive'`.

2. Diccionario de Supervivencia


Si te pones nervioso y olvidas un término técnico, aquí está la traducción mental que debes hacer:

- **Target (Variable Objetivo):** Es lo que intentamos predecir. En nuestro caso se llama `spend_positive`. Es 1 si el cliente gastó dinero, 0 si no gastó.
- **Deduplicación (Paso 0):** Resulta que en nuestra base de datos, el mismo cliente (`customer_id`) aparecía varias veces porque le tomaron "fotos" (snapshots) en diferentes días. Si metes clientes repetidos, el modelo hace trampa porque "se aprende" al cliente. Por eso, nos quedamos solo con la "foto" más reciente y borramos 90 filas repetidas.
- **Data Leakage (Fuga de Información):** Es hacer trampa leyendo el futuro. Imagina apostar en un partido de fútbol sabiendo el resultado final. En nuestro trabajo, las variables `post_window_retention_call` y `post_window_discount` ocurren en el futuro. Si el modelo las ve, saca 100% de nota, pero en la vida real no serviría para nada. Las tuvimos que eliminar desde el inicio.



Data Leakage: Predecir el futuro usando información del futuro anula el experimento.

- **El Split (60/20/20):** Nunca le muestras todo al modelo. Coges tus clientes y los divides en tres cajas seguras:



3. El Problema de los Datos Faltantes (NaN)

A veces faltan datos en nuestra tabla. Aparece un feo `NaN` o "Nulo". Pero no todos los nulos significan lo mismo. Si te preguntan por los "Mecanismos de Faltantes", debes responder con esta analogía médica de 4 niveles:

1. MCAR (Missing Completely At Random) - "Al azar"

Analogía: El tubo de sangre se cayó al piso por accidente. Faltó el dato por pura mala suerte. (Variable `promo_open_rate_90d`). Se puede rellenar con la media.

2. MAR (Missing At Random) - "Faltante Condicionado"

Analogía: A los abuelos se les olvida llenar la casilla "Tipo de Sangre" porque no ven bien. El dato falta, pero la culpa la tiene su edad (otra variable de la tabla). (Variable `education_level`). Podemos adivinarlo mirando otras variables.

3. MNAR (Missing Not At Random) - "Por Vergüenza"

Analogía: Gente de +120 kilos no responde la pregunta de su peso. ¡El dato falta JUSTAMENTE por el valor que falta! (Variable `satisfaction_score`: Los clientes más furiosos no contestan encuestas). Rellenarlo con el promedio ("cliente feliz") es un error gravísimo. Hay que añadir una bandera de advertencia.

4. Estructural - "No Aplica"

Analogía: Le preguntas a un calvo "qué marca de champú usa". La respuesta es "No Aplica". (Variable `avg_order_value_90d`). Un cliente con cero compras no puede tener "promedio de compras". Se rellena con cero y bandera binaria.



Diferencia de tratamiento empírico frente a la naturaleza del Nulo.

4. La Trampa de los Tipos de Datos

Esta es la carnita del trabajo. Tienes que convencer al profesor de que no puedes tratar a todos los números igual.

A. Variables Cíclicas (Ej. La hora del día)

Nuestra variable `peak_hour_local` va de 0 a 23 horas.

El error: Meterle el número de 0 a 23 al computador. Si un cliente compra a las 23:00 y otro compra a las 00:00, en la vida real solo hay una hora de diferencia. Pero en matemáticas de colegio, 23 y 0 están a 23 números de distancia. El modelo pensará que son clientes opuestos.

La solución: Seno y Coseno. Coges la línea de tiempo y la doblas formando un reloj circular. Así, la hora 23 y la hora 0 quedan una al lado de la otra.

B. Variables Composicionales (Ej. Share Web, Mobile...)

Esta es la parte más avanzada. Tienes 4 canales de venta que suman el 100% de las compras de un cliente (web + app + partner + tienda = 1). Esto se llama una **restricción Simplex**.

El error: Como suman 1, si un cliente usa un 90% la Web, obligatoriamente tiene que usar menos los otros canales para que la suma no pase de 100. Esto hace que el modelo crea que hay una "Correlación Negativa" (si uno sube, el otro baja). Pero no es un comportamiento del cliente, ¡es una ilusión matemática!

La solución: CLR (Centered Log Ratio). Usamos un logaritmo loco que destruye esa regla del "100%", liberando a los números para que el modelo pueda analizarlos sin ataduras geométricas.



CLR mapea datos del espacio restringido al espacio real donde Python sabe trabajar.

5. El Pipeline: Ingenuo vs. Coherente

Para probar todo lo anterior, construimos dos fábricas (pipelines) en Python y pasamos los mismos datos por ambas.

Característica	Pipeline Ingenuo (Lo Incorrecto)	Pipeline Coherente (Tu Trabajo)
Categorías (Región)	Label Encoding (Números 1, 2, 3...)	One-Hot Encoding (Indicadores 1 o 0)
Canales (Shares)	Se metieron crudos, engañando al modelo	Se transformaron con CLR
La hora del día	Se dejó como número lineal (0 al 23)	Se dobló en un círculo con Seno y Coseno
Faltantes (NaN)	Se rellenó TODO con el promedio.	Se usaron modelos predictivos para MAR, y ceros con banderas para los Estructurales.

6. Las Métricas (ROC-AUC)

La métrica que más le importa a tu profesor es el ROC-AUC (Área Bajo la Curva de la Característica Operativa del Receptor).

¿Qué rayos es el ROC-AUC en español?

Imagina que el modelo hace una lista de clientes ordenados del que más probabilidad tiene de comprar al que menos. El ROC-AUC califica qué tan perfecto es ese ordenamiento.

- 0.50 significa que el modelo lanza una moneda al aire. (Basura).
- 1.00 significa que el modelo es Dios y jamás se equivoca. (Imposible en la vida real).

El veredicto empírico: En el archivo `Tabla\_W4.3.csv`, vemos que el Pipeline Coherente sacó un ROC-AUC mejor que el Ingenuo. Demostramos matemáticamente que **tratar bien a los datos, los hace más predecibles**.

7. Simulador de Sustentación (Preguntas Trampa)

Siéntate, respira y memoriza estas respuestas. Si el profesor te hace alguna de estas preguntas, tendrás la respuesta de un ingeniero senior.

Profesor: "Anderson, ¿por qué no metió la variable ``post_window_discount_amount`` si era tan buena para predecir?"

Tu respuesta: "Porque es una variable del futuro, profe. Ocurre después de los 60 días. Si la incluyo cometo un *Data Leakage* masivo. Sería como adivinar qué equipo ganó el partido leyendo el periódico de mañana. El modelo tendría un accuracy de 99% pero en producción sería totalmente inútil."

Profesor: "Si un cliente tiene un ``avg_order_value_90d`` nulo, ¿por qué simplemente no le pusiste la media de compra de todos los demás?"

Tu respuesta: "Porque no es un faltante estadístico, profe. Es un faltante **estructural**. Comprobé cruzando variables que el 100% de esos nulos tenían cero transacciones (`transactions == 0`). Si le imputo la media, le estoy inyectando ingresos falsos a la empresa provenientes de clientes que no nos compran. Eso arruinaría las predicciones de ventas. Lo correcto fue ponerle 0 y añadir un indicador binario al modelo."

Profesor: "¿Qué es eso de CLR y por qué se lo aplicaste a los shares de la web y el móvil?"

Tu respuesta: "Porque las variables de porcentaje ('shares') forman una composición matemática; siempre suman 1. Esa restricción de sumar 1 hace que no sean independientes y genera correlaciones negativas falsas. La transformación CLR (Centered Log Ratio) usa logaritmos para romper esa restricción y mapear los datos al espacio real, donde los algoritmos sí pueden operar sin sesgos geométricos."

Profesor: *"¿Para qué hiciste la partición 60/20/20? ¿No era mejor hacerla solo 80/20?"*

Tu respuesta: "No, porque tenía que probar dos modelos diferentes (el ingenuo y el coherente). Los entrené con el 60% (Train). Luego, los hice pelear entre ellos usando el 20% (Validación). Cuando ya descubrí cuál era el ganador absoluto (el Coherente), le hice el examen final secreto con el último 20% (Prueba) para reportar la nota final del trabajo sin que el modelo pudiera sobreajustarse."

¡Con esto estás listo, Anderson! Sal y demuéstrales lo que sabes.