

Tipo de Dato, Calidad y Representación

Análisis Empírico de Modelos Predictivos

Anderson González

Ciencia de Datos - Corte 1

Evidencia Empírica de Representaciones

Cíclica

Composiciones CLR: Corregimos correlaciones espurias negativas forzadas por la restricción multicanal (Simplex).

Codificación Cíclica: Corregimos el error euclidiano del salto 2π $\rightarrow$ 0 mapeando al círculo trigonométrico.

Representación Semántica

Validación de Pipelines

Pipeline Ingenuo

- Label encoder arbitrario
- Variables en bruto
- Imputación global (media)

Pipeline Coherente

- One-Hot Encoding
- Sen/Cos + Transformación CLR
- Imputación condicionada + Indicadores Estructurales

Resultado: El pipeline coherente superó en ROC-AUC aislando los efectos semánticos de representación, garantizando robustez ante datos futuros.

Lecciones: Tres Errores a Evitar

1. **Imputar estructurales con la media:** Destruye señales lógicas. Es imposible y peligroso promediar órdenes financieras para clientes que no tienen transacciones previas.
2. **Data Leakage del futuro:** Incluir variables post-ventana (ej. `post_window_discount`) equivale a adivinar el futuro usando el periódico de mañana. Arruina la validación.
3. **Operar sobre distribuciones Simplex brutas:** Causa falsa colinealidad en canales compartidos que los modelos tradicionales no pueden gestionar sin la transformación de Logaritmo Centrado (CLR).

Centro de Mando (Anexos Técnicos)

Haga clic en cualquier recurso para acceder a los datos crudos y evidencia del trabajo.

Matrices y Tablas

W4.1 - Matriz de Tipos

W4.2 - Faltantes

W4.3 - ROC-AUC

Evidencia Visual (PNG)

Fig. 1 - Categorías

Fig. 2 - CLR

Fig. 4 - Faltantes

Auditoría y Decisiones

Registro minucioso de 9 decisiones metodológicas, incluyendo el reporte de los 90 duplicados removidos (Paso 0).

Abr

Recursos de Sustentación