

1. Nominales (Finitas sin orden)

Operaciones Válidas Igualdad ($==$), Moda

El Riesgo: Representarlos como enteros (1, 2, 3...) fuerza falsas nociones de distancia matemática.

Solución: One-Hot Encoding.

2. Ordinales (Finitas con orden)

Operaciones Válidas Desigualdad ($>$), Mediana

El Riesgo: Asumir distancias equidistantes entre rangos (ej. 1 a 2 = 4 a 5).

Solución: Preservar como enteros si la escala subyacente es lineal, o usar codificaciones ordinales monótonas.

3. Composicionales (Suma = 1)

Operaciones Válidas Log-Ratios (CLR/ALR)

El Riesgo: Correlaciones negativas espurias forzadas por la restricción de suma (un canal sube, el otro debe bajar).

Solución: Transformación Centered Log Ratio.

4. Cíclicas (Reloj, Calendario)

Operaciones Válidas Trigonometría (Seno/Cos)

El Riesgo: El salto artificial entre el fin y el inicio del ciclo (hora 23 y hora 0) crea distancias matemáticas máximas cuando en realidad son adyacentes.

Solución: Codificar en 2 dimensiones usando sen/cos.

Gestión Semántica de Faltantes

- Estructural: No falta, "no aplica". Ej: Valor de orden sin compras. Se debe crear indicador binario e imputar con constante cero.
- MNAR: Falta porque el usuario no quiere revelarlo (ej. muy insatisfecho). Agregar indicador binario es crucial.
- MAR/MCAR: Falta aleatoriamente o explicable por otras variables. Imputar con modelos (iterative) o tendencia central.