

CIENCIA DE DATOS - CORTE 1

Trabajo 4

Tipo de Dato, Calidad y Representación

Análisis empírico de operaciones válidas y su impacto en modelos predictivos

Estudiante: Anderson González

Profesor: Omar Portilla

Universidad de Pamplona · Periodo: 2026-1

| Índice

01	Resumen Ejecutivo	03
02	Pregunta Rectora	04
03	Variables Obligatorias	05
04	Protocolo Experimental	06
05	Resultados Obligatorios	07
06	Razonamientos Obligatorios	11
07	Decisión Final	13
08	Errores Evitados	14
09	Conclusión Didáctica	15
10	Referencias	16

1. Resumen Ejecutivo

Este trabajo demuestra empíricamente que tratar todos los números como escalares continuos y todos los valores nulos como ignorancia aleatoria destruye información predictiva valiosa.

A través del análisis del dataset `eda_laboratorio_clientes_v1.csv`, aplicamos un protocolo riguroso de deduplicación y partición para comparar un Pipeline Ingenuo contra un Pipeline Coherente. Al respetar la semántica de los datos (composiciones con CLR, cíclicas con seno/coseno) y modelar los mecanismos de faltantes (estructurales y explícitos), logramos un mejor rendimiento predictivo, elevando el ROC-AUC en validación al aislar las decisiones de representación.

2. Pregunta Rectora

¿Qué operaciones son válidas o inválidas según el tipo de dato de cada variable, y cómo cambia la calidad del modelo cuando se representa el dato de forma semánticamente coherente en lugar de hacerlo con una codificación ingenua?

Esta pregunta nos obliga a abandonar la comodidad computacional de "imputar todo con la media" o "pasar todo a entero", para adoptar un enfoque de diseño donde la estructura matemática de la variable dicta su representación.

| 3. Variables Obligatorias

El estudio se centra en dos bloques críticos:

- Representación: `region` , `plan_type` (Nominales); `education_level` , `loyalty_tier` , `satisfaction_score` (Ordinales); `promo_open_rate_90d` (Proporción); `share_*` (Composiciones); `peak_hour_local` (Cíclica).
- Calidad (Faltantes): `avg_order_value_90d` (Estructural); `education_level` (MAR); `satisfaction_score` (MNAR); `promo_open_rate_90d` (MCAR).

| 4. Protocolo Experimental

1. Deduplicación: Retención del registro más reciente por `customer_id` . Se removieron 90 filas.
2. Target: Creación de `spend_positive = 1 if future_spend_60d > 0 else 0` .
3. Partición: 60% Train, 20% Val, 20% Test, estratificado (`random_state=2026`).
4. Aislamiento: Transformadores entrenados exclusivamente en Train. Test preservado para el reporte final único.
5. Fuga de Información: Exclusión explícita de ``post_window_retention_call`` y ``post_window_discount_amount``.

5. Resultados Obligatorios

La evaluación empírica confirma nuestras hipótesis semánticas.




Figura W4.1: Distribución nominal y detección de rareza categórica.




Figura W4.2: Matriz de correlación espuria (izquierda) vs correlación corregida mediante CLR (derecha).




Figura W4.3: Codificación de variable cíclica eliminando el salto artificial de 23 a 0.




Figura W4.4: Auditoría de faltantes estructurales y mejora de ROC-AUC del pipeline coherente.

6. Razonamientos Obligatorios

1. ¿Por qué region y plan_type no pueden tratarse como variables ordinales arbitrarias?

Imponer un Label Encoding (ej. Norte=1, Sur=2) fuerza artificialmente al modelo a creer que "Sur es el doble que Norte", induciendo un sesgo geométrico sin respaldo en el dominio. Una regresión logística trazará una relación monótona falsa entre ellas.

2. ¿Cuándo conservar una ordinal como entero ordenado?

Si la distancia conceptual entre los niveles es razonablemente equidistante (ej. Nivel 1 a 2 es similar a 2 a 3), conservarlo como entero preserva la jerarquía paramétrica y ahorra grados de libertad. Si hay no-linealidades graves, es mejor relajar la asunción con splines discretos o one-hot.

3. Restricción Simplex en shares

Los canales forman una composición de suma=1. Si el uso Web sube, matemáticamente los otros deben bajar, creando correlaciones negativas espurias (Fig W4.2). Operar directamente con correlación de Pearson aquí viola la independencia. La transformación Centered Log Ratio (CLR) mapea estos datos al espacio real sin restricciones.

4. Codificación cíclica temporal

En el dominio entero $[0, 23]$, la distancia euclidiana entre 23 y 0 es 23. En el tiempo real es 1 hora. Codificando en proyecciones Seno y Coseno, mapeamos el tiempo a un círculo bidimensional, garantizando distancias temporales coherentes (Fig W4.3).

5. Faltante estructural de avg_order_value

La coincidencia exacta entre ``is_null(avg_order)`` y ``transactions_90d == 0`` demuestra que este "nulo" es lógico, no estadístico. Imputarlo con la media poblacional inventaría ingresos para clientes inactivos. Rellenar con 0 y agregar un indicador es la forma defensiva y lógicamente sensata de modelarlo.

| 7. Decisión Final

El Pipeline Coherente es nuestra decisión final unánime. Al implementar una gestión consciente de faltantes (imputación según MCAR/MAR/MNAR y estructural) y representaciones fidedignas (CLR, Cyclic, OHE), el modelo mejoró su capacidad de generalización superando al Pipeline Ingenuo en la validación, protegiendo al negocio de inferencias espurias.

| 8. Errores Evitados

- **Data Leakage:** Excluir `post_window_discount_amount` evitó que el modelo predeciera mágicamente usando el futuro.
- **Correlación Espuria Composicional:** Se evitaron coeficientes lineales engañosos en la distribución multicanal usando CLR.
- **Faltante Estructural como Aleatorio:** Evitamos inflar promedios artificialmente al reconocer los ceros estructurales de inactividad.

| 9. Conclusión Didáctica

Para todo científico de datos: Un `NaN` nunca es solo un `NaN`, y un número no siempre pertenece a $\mathbb{R}$. Interrogar la ontología del dato antes de aplicar transformadores `scikit-learn` es lo que separa a un operador de código de un modelador estadístico riguroso.

| 10. Referencias

- Documentación de Variables: `diccionario_datos_estudiante.csv`
- Guía de Trabajos EDA: `guia_trabajos_eda.pdf`
- Aitchison, J. (1982). The Statistical Analysis of Compositional Data.