

# Tipo de Dato, Calidad y Representación

---

## Sección 1 (4 min): Teoría y Ontología del Dato


- No todo número es un escalar continuo  $\mathbb{R}$ .
- Restricciones estructurales: Cíclicos (reloj), Composicionales (suma=1).
- Mecanismos de faltantes: MCAR, MAR, MNAR y Estructurales (no aplica).

# Evidencia Empírica de Representaciones

## Sección 2 (7 min): El impacto de la geometría

Composiciones CLR: Corregimos correlaciones espurias negativas forzadas por la restricción multicanal.

Codificación Cíclica: Corregimos el error euclidiano del salto 23h  $\rightarrow$  0h mapeando al círculo trigonométrico.



# Validación de Pipelines

---

## Sección 3 (2 min): Ingenuo vs Coherente

- Ingenuo: Label encoder arbitrario, numéricos crudos, media para todo.
- Coherente: OHE, Sen/Cos, CLR, Imputación Iterativa e indicadores.
- Resultado: El pipeline coherente superó en ROC-AUC aislando los efectos semánticos de representación.

# Tres Errores a Evitar

---

## Sección 4 (2 min): Lecciones para el curso

1. Imputar estructurales con la media: Destruye señales lógicas (no puedes promediar órdenes sin compras).
2. Data Leakage del futuro: Incluir `post_window_discount` predice el futuro con el futuro.
3. Operar sobre distribuciones Simplex brutas: Falsa colinealidad en canales compartidos.