

Tipo de Dato, Calidad y Representación

Análisis Empírico de Modelos Predictivos


Anderson González

Ciencia de Datos - Corte 1

Evidencia Empírica de Representaciones

Composiciones CLR: Corregimos correlaciones espurias negativas forzadas por la restricción multicanal (Simplex).

Codificación Cíclica: Corregimos el error euclidiano del salto 23h $\rightarrow$ 0h mapeando al círculo trigonométrico.



Representación Semántica

Validación de Pipelines

Pipeline Ingenuo

- Label encoder arbitrario
- Variables en bruto
- Imputación global (media)

Pipeline Coherente

- One-Hot Encoding
- Sen/Cos + Transformación CLR
- Imputación condicionada + Indicadores Estructurales

Resultado: El pipeline coherente superó en ROC-AUC aislando los efectos semánticos de representación, garantizando robustez ante datos futuros.

Lecciones: Tres Errores a Evitar

1. Imputar estructurales con la media: Destruye señales lógicas. Es imposible y peligroso promediar órdenes financieras para clientes que no tienen transacciones previas.
2. Data Leakage del futuro: Incluir variables post-ventana (ej. `post_window_discount`) equivale a adivinar el futuro usando el periódico de mañana. Arruina la validación.
3. Operar sobre distribuciones Simplex brutas: Causa falsa colinealidad en canales compartidos que los modelos tradicionales no pueden gestionar sin la transformación de Logaritmo Centrado (CLR).

Centro de Mando (Anexos Técnicos)

Haga clic en cualquier recurso para acceder a los datos crudos y evidencia del trabajo.

Matrices y Tablas

W4.1 - Matriz de Tipos

W4.2 - Faltantes

W4.3 - ROC-AUC

Evidencia Visual (PNG)

Fig. 1 - Categorías

Fig. 2 - CLR

Fig. 3 - Cíclica

Fig. 4 - Faltantes

Auditoría y Decisiones

Registro minucioso de 9 decisiones metodológicas, incluyendo el reporte de los 90 duplicados removidos (Paso 0).

[Abrir Bitácora Completa](#)

Lista de Verificación de Cumplimiento

Todos los requerimientos exigidos en la rúbrica han sido completados y documentados.

✓ Construyó la matriz de tipo de dato y operaciones válidas.

Ver Tabla W4.1

✓ Analizó los cuatro mecanismos de faltante exigidos.

Ver Tabla W4.2

✓ Demostró el carácter estructural de avg_order.

Ver Figura 4

✓ Comparó composición cruda vs CLR.

Ver Figura 2

✓ Codificó peak_hour con seno/coseno.

Ver Figura 3

✓ Comparó pipeline ingenuo vs pipeline coherente.

Ver Tabla W4.3

✓ Respondió las cinco preguntas de razonamiento.

Ver Informe Técnico

✓ Entregó handout docente de una página.

Ver Handout

Rúbrica de Evaluación